

ВЫЯВЛЕНИЕ ДЕСТРУКТИВНОГО КОНТЕНТА В СОЦИАЛЬНЫХ МЕДИА НА ОСНОВЕ МОДЕЛЕЙ МАШИННОГО ОБУЧЕНИЯ

В.А. Минаев, А.Д. Реброва, А.В. Симонов

В статье обсуждаются модели классификации текстового контента и методы его предварительной обработки с целью выявления деструктивных воздействий в социальных медиа. Показано, что основным источником деструктивного контента выступает профиль пользователей, характеризующийся набором личным данных, содержанием публикаций, параметрами сообщества, аккаунтов сети, сообщений и чатов. Говорится об актуальности автоматизированного сбора и анализа данных с помощью моделей прецедентного и дедуктивного обучения. Рассматриваются их основные разновидности и задачи, решаемые на их основе, включающие прогнозирование и типологизацию в аспекте деструктивного содержания текстов, снижение размерности признаков их описания. Исследованы и применены основные методы векторизации текстов: Bag of Words, TF_IDF, Word2vec. На практических корпусах текстов из социальной сети ВКонтакте решены задачи выявления деструктивного контента, связанного с радикальным исламом. Показано, что с помощью примененных моделей и методов все тексты, включающие деструктивный контент, классифицированы верно. Наиболее высокую точность (0,97) при решении задачи распознавания деструктивного контента дает системная интеграция алгоритма векторизации Bag of Words, метода главных компонент для снижения пространства признаков описания текстов и логистической регрессии или случайного леса как моделей обучения. Сделан вывод, что наборы данных, имеющие связь с исламским радикализмом, характеризуются достаточно четкими признаками, которые хорошо вычисляемы с помощью современных моделей, методов и алгоритмов, и могут эффективно применяться для автоматизированной классификации текстовых массивов с целью выявления их деструктивной направленности. Развитие направления, представленного в статье, связано с увеличением исследуемых корпусов документов, более детальным анализом текстов на основе сложных моделей распознавания латентной экстремистской пропаганды, в том числе – представленной в фото, аудио- и видеоформатах.

Ключевые слова: деструктивный текстовый контент, исламский радикализм, социальные медиа, распознавание негативного информационного воздействия, модель машинного обучения.

Введение

Социальные медиа (СМ) являются мощнейшим инструментом воздействия на общество. Они используются для общения и развлечений одними, в интересах торговли, продвижения товаров, изучения общественного мнения и влияния на него – другими [1]. В то же время, пользуясь доступностью и открытостью информационных ресурсов, активизировались злоумышленники, получив возможности манипулирования людьми с помощью деструктивного контента.

Под деструктивным понимается информационный контент в СМ с призывами к разжиганию национальной и религиозной розни, распространение через глобальную сеть Интернет информации о наркотических

и иных губительных для человека, особенно – молодежи, веществах материалов, содержащих порнографию, в том числе – с участием несовершеннолетних, а также пропаганду террористических, экстремистских и иных криминальных действий.

Сегодня СМ стали источником поддержки и развития преступных и среди них особенно опасных – террористических группировок, вербующих своих новых последователей через сеть Интернет [2]. Борьбаться эффективно с подобными явлениями, используя только ручную обработку материалов Сети, не представляется возможным в силу огромного объема данных, нуждающихся в проверке и контроле.

Поэтому и актуализировалась задача создания автоматизированных систем, способных выявлять деструктивный в СМ. Одним из современных инструментов, применяя который, создаются подобные системы, выступают модели машинного обучения. В настоящей статье рассматриваются указанные модели и алгоритмы обработки текстовых данных, ориентированные на выявление деструктивного контента в СМ.

Социальные медиа как источник деструктивного контента

Социальные медиа выступают источником сбора и анализа различных данных для маркетологов, социологов, экономистов и специалистов из многих других областей. Чем больше аудитория СМ, тем больше данных можно получить, и тем точнее будут результаты возможных исследований – от анализа тематики публикаций в популярных сообществах до изучения взаимосвязей пользователей из различных сообществ путем анализа данных, представленных в виде графов [3-6].

Разберемся, что можно получить из СМ, решая задачи выявления и распознавания деструктивного контента в огромных текстовых массивах.

Считается, что основным источником деструктивного контента выступает профиль пользователя, либо целого сообщества пользователей. Когда речь идет о профиле, мы имеем дело со следующими параметрами:

1) *набор личных данных* (год рождения, место жительства, фотографии), которые могут быть и не относящимися к реальной личности, а могут лишь частично указывать на реального человека, отраженного в профиле;

2) *данные о содержании публикаций* обладателя аккаунта СМ, который может не только общаться в чатах и участвовать в дискуссиях в ее сообществах, но и выкладывать деструктивный контент.

Соответствующие публикации содержат тексты, фотографии, видео- и аудиозаписи, которые сопровождаются “лайками”, отражающими отношение тех, кто просмотрел контент; комментариями, иногда с изображениями, и обязательно – со ссылкой на профиль прокомментировавшего; количеством просмотров. Все эти данные позволяют оценить содержание публикации, увлекающую ее аудиторию пользователей сети, качественный (положительная, негативная) и количественный (число отреагировавших) показатели реакции аудитории. Исследуя публикации, можно не только охарактеризовать сам профиль, но также исследовать, на кого оказывается влияние, какой отклик возникает. В случае, когда распространяется деструктивный контент, формируется информация о количестве единомышленников, характеристиках целевой аудитории;

3) *данные о сообществах*, в которых состоит пользователь. Эта информация может быть как реальной, так и искусственно сформированной, когда сообщества, на которые подписан пользователь, служат маской. Например, нацеленные на общение с несовершеннолетними, могут сопровождаться фотографиями, соответствующими целевой аудитории, могут быть подписанными на “нужные” сообщества, но не отличаться в них реальной активностью. Пользователи также могут иметь в своих подписках сообщества, служащие площадками для распространения деструктивного контента. Исследуя связи профиль-сообщество-профиль, возможно обнаруживать целые преступные группировки, если речь идет о продаже незаконных товаров и услуг через цепочки поставщиков и продавцов;

4) *данные о связанных с пользователем сети аккаунтах* – подписчиках, “друзьях”, подписках. Подписчики, это, как правило, пользователи, которые наблюдают за

действиями исследуемого аккаунта, его аудитория, о которой пользователь может и не знать. Подписки, наоборот, это те, за кем наблюдает сам пользователь, не представляя для них интереса. “Друзья” – это совокупность двух названных выше групп, принадлежность к которой означает взаимный информационный интерес пользователей друг к другу, возможно, наличие между ними реального знакомства;

5) *сообщения и чаты*. Обычно это закрытая информация, и социальные сети не предоставляют ее, так как диалоги конфиденциальны. Однако существуют способы получить данные о переписках, например, через создание чат-бота, который будет общаться с подозрительным аккаунтом. Из сообщений можно не только выявить характер переписок, но и наличие распространения деструктивного контента через тексты, изображения, аудио- или видеоданные.

Применительно к сетевому сообществу можно собрать следующую информацию:

1) название и описание сообщества, дату создания, место действия, ключевые тематики, профили администраторов. Эта метайнформация содержится у сообществ практически всех СМ, позволяя оперативно составить представление о том, с чем приходится иметь дело. Так как цель сообществ – собрать как можно больше интересующихся представленной тематикой, структура метайнформации дает ясное представление о том, какие интересы оно преследует. При этом нужно понимать, что, если речь идет о сообществе, распространяющем деструктивный контент, то эта информация, как правило, хорошо замаскирована, завуалирована для модераторов;

2) текстовые публикации, видео- и аудиоданные сообщества. В зависимости от типа СМ, публикации представлены по-разному, однако они объединены общей тематикой, новые публикации появляются регулярно, имея схожую структуру;

3) форумы, опросы, конкурсы. Множество участников, как правило, подписчиков сообщества, обсуждают одну проблему, и все мнения на этот счет сгруппированы в СМ. Используя опрос, можно набрать релевантные статистические данные о мнениях в удобном количественно-качественном виде. Исследование такой возможности позволяет определить пользователей, положительно отреагировавших на деструктивный контент, распространивших его;

4) участники сообщества. Исследуя связь участник-сообщество-участник, можно установить аудиторию деструктивного контента, а часто – и его авторов.

Конечно, все эти сведения можно собрать и обработать вручную. Однако для этого требуется много времени и большая команда. При этом результат анализа будет гораздо точнее, ведь только профессионально подготовленный человек способен разглядеть деструктивный контент в замаскированных под обычные публикации сообщениях.

Автоматизированные сбор и анализ данных проводится с использованием поисковых ботов-краулеров – специальных программ, алгоритмы которых ориентированы на анализ веб-страниц определенного типа [6].

Также существует более простой способ сбора данных, когда из СМ незащищенные данные выгружаются автоматически. С помощью таких опций можно быстро собрать базы данных об исследуемых пользователях, сообществах, публикациях, изображениях, видео- и аудиоматериалах [7-9]. Для исследования указанных баз данных разрабатываются модели машинного обучения (ММО).

Модели машинного обучения – это алгоритмы, которые позволяют автоматически распознавать информационные объекты того или иного класса. Их особенностью является то, что они требуют тренировочного обучения.

Такие алгоритмы работают со следующими типами описания [10]:

- *Признаковое описание* или матрица “объекты-признаки”, когда объекты описываются набором признаков. Так, аккаунт может быть описан через личные данные, количество публикаций, собранных лайков и т. д.

- *Матрица расстояний* между объектами, в которой каждый из них описывается расстояниями до всех остальных объектов обучающей выборки. После перевода характеристик объектов в показатели их близости используются специальные математические методы.

- *Временной ряд*, когда последовательность измерений представляется вектором – признаковым описанием в каждый момент времени.

Рассмотрим основные ММО, области их применения и способы реализации. Можно выделить два основных семейства моделей машинного обучения: обучающиеся по прецедентам с учителем и обучающиеся через дедукцию без учителя.

Обучение по прецедентам означает, что для классификации данных с помощью модели ее необходимо обучить на заранее отобранном наборе примеров, для каждого из которых целевая функция уже известна как имеющая отношение к определенному классу.

Алгоритм обучения через дедукцию ориентирован на признаки собранных объектов и определение их “расстояний” между собой. Когда карта признакового пространства создана, алгоритм “понимает” положение нового объекта на ней и предсказывает некоторые его признаки или класс, к которому он относится.

Оба семейства моделей применяются для решения задач [10]:

- *регрессии* – предсказания числовых значений признаков, например, будущих объемов комментариев или репостов на основании известных данных о внимании аудитории к аналогичным публикациям в прошлом;

- *классификации* – отнесения объекта к тому или иному известному классу, например, предсказания того, является ли контент деструктивным;

- *кластеризации* – разделения множества объектов на кластеры, т.е. типы, внутри которых объекты похожи между собой, например, разделения лиц с криминальным поведением на кластеры так, что внутри одного кластера оказывается одна преступная группировка;

- *снижения размерности* (задача сжатия исходных данных) – сведения большого числа признаков объектов к меньшему для удобства их последующей визуализации;

- *поиска аномалий* – нахождения редких, необычных объектов, существенно отличающихся от их основной массы, например, поиск подставных аккаунтов, когда взрослый злоумышленник в социальной сети пытается притвориться несовершеннолетним.

Охарактеризуем наиболее распространенные ММО.

Модели с прецедентным обучением

Особенность моделей с прецедентным обучением состоит в том, что классы объектов при обучении известны, и алгоритм находит основные признаки, по которым определяют, к какому классу относится объект:

- *Линейная и логистическая регрессии.* При применении этого метода обучение сводится к нахождению уравнения, состоящего из суммы произведений значений признаков на соответствующие весовые коэффициенты. Результат решения – целевая переменная, метка класса, к которому принадлежит объект. В случае линейной регрессии целевая переменная – различные положительные числовые значения, в случае логистической – вероятность принадлежности к классу, то есть значение от 0 до 1. Метод работает достаточно быстро для большого числа объектов и признаков. Однако, когда зависимость целевой переменной от параметров нелинейна, алгоритм снижает свою эффективность.

- *Метод ближайшего соседа* основан на сравнении векторов, описывающих объекты, для определения, к какому классу относится неизвестный вектор. Метод хорошо работает в случаях, когда признаков и данных немного. Однако при возрастании количества объектов и признаков сложность вычислений существенно возрастает, и эффективность метода снижается.

- *Метод опорных векторов* принадлежит семейству линейных классификаторов. Его достоинствами выступают скорость, единственность решения, отсутствие необходимости переобучения. К недостаткам относятся чувствительность к шумам, а также неприменимость в случаях, когда между классами не существует линейного разделения.

- *Деревья решений и случайные леса* отличаются от выше описанных методов тем, что целевая энтропийная функция рассчитывается для каждого признака, а не их совокупности. Приоритетными считаются признаки, разделение по которым дает наименьшую энтропию. Деревья позволяют работать как с дискретными (деревья классификации), так и с вещественными значениями (деревья регрессии).

Достоинствами деревьев решений является то, что результат их работы интерпретируется максимально понятно (например, если пользователь имеет пол мужской, возраст старше 25 лет, а выявлены его сетевые связи с пользователями женского пола младше 16, скорее всего, аккаунты нуждаются в особом контроле). Обучение происходит достаточно быстро, однако эффективность метода существенно зависит от характеристик выборки данных и изучаемых объектов, что может приводить к неточности предсказаний. Проблема решается через комбинирование решений нескольких деревьев, этот способ называется лесом [11].

Модели с дедуктивным обучением

Обучение без учителя применяется в задачах, когда известны признаки объектов и требуется найти зависимости между ними. В отличие от алгоритмов обучения с учителем, в данных методах классы неизвестны, а, значит, и качество решения измерить сложнее [10]. Данный подход используется для решения задач:

- *кластеризации* или разделения объектов на группы, внутри которых они схожи, а объекты из разных групп имеют существенные отличия;

- *поиска правил ассоциации*, когда ищут такое значение некоторых признаков объектов, которое встречается достаточно часто и не случайно;

- *заполнения недостающих значений*. При решении этой задачи имеется объект, похожий на объекты тренировочной выборки, но с отсутствующим признаком. Этот признак вычисляется, исходя из расстояния до других объектов тренировочной выборки;

- *сокращения размерности*, когда происходит переход к пространству признаков меньшей размерности, при этом отсекаются признаки, играющие незначительную роль при кластеризации.

Очевидно, что практически все модели с дедуктивным обучением так или иначе связаны с кластеризацией, когда первое, что интересует в исследуемых данных, это похожесть одних объектов на другие.

При кластеризации используются следующие основные меры расстояний [12]:

- 1) *евклидово расстояние* между векторами равно корню из суммы попарных разниц их координат, возведенных в квадрат;

- 2) *квадрат евклидова расстояния* используется, когда большее расстояние между векторами важнее, чем меньшее;

- 3) *расстояние городских кварталов* (манхэттенское расстояние) близко евклидову, однако при его использовании

влияние больших разниц отдельных координат, наоборот, уменьшается;

4) *расстояние Чебышева* как способ измерения расстояния подходит для случая, когда интересует наибольшая разница объектов по какой-то одной координате (одному признаку);

5) *степенное расстояние* применяется в случае, когда необходимо увеличить или уменьшить вес, относящийся к признакам, для которых соответствующие объекты сильно отличаются.

Алгоритмы кластеризации разделяются на

- *иерархические и плоские алгоритмы;*
- *алгоритмы четкого и нечеткого разделения.*

Иерархические алгоритмы исходят из того, что существует один кластер, содержащий все объекты, он делится на более мелкие кластеры снова и снова, пока дальнейшее разделение становится нецелесообразным.

Плоские алгоритмы, наоборот, строят разбиение на кластеры единовременно;

Алгоритмы четкого разделения присваивают объекту метку только одного кластера, в то время как алгоритмы нечеткого разделения определяют вероятности отношения объекта к разным кластерам.

В иерархических алгоритмах используется несколько методов объединения объектов в кластеры, исходя из расстояний от других объектов:

- *одиночная связь* (расстояние ближайшего соседа), когда расстояние между двумя кластерами определяется расстоянием между двумя наиболее близкими объектами (ближайшими соседями) в различных кластерах;

- *полная связь* (расстояние наиболее удаленных соседей), когда расстояние между кластерами определяется наибольшим расстоянием между двумя объектами в

различных кластерах (т.е. наиболее удаленными соседями);

- *невзвешенное попарное среднее* вычисляется как среднее расстояние между всеми парами объектов в кластерах;

- *взвешенное попарное среднее* схож как метод с предыдущим, при вычислениях число объектов, содержащихся в кластерах, используется в качестве весового коэффициента;

- *невзвешенный центроидный метод* определяет расстояние между центрами тяжести кластеров;

- *взвешенный центроидный метод* (медиана) идентичен предыдущему, однако при вычислениях для учета разницы между размерами кластеров используются веса.

Рассмотрим основные алгоритмы кластеризации.

- *Алгоритм иерархической кластеризации.* Среди них выделяются два основных типа: восходящие и нисходящие алгоритмы. Нисходящие алгоритмы работают по принципу “сверху-вниз”: как уже говорилось, сначала все объекты помещаются в один кластер, который затем разбивается на все более мелкие кластеры до разумного предела. Более распространены восходящие алгоритмы, которые сначала помещают каждый объект в отдельный кластер, а затем объединяют кластеры во все более крупные. Результаты работы таких алгоритмов обычно представляют в виде дерева – дендрограммы.

- *Метод k-средних.* Это распространенный метод имеет недостаток в виде необходимости изначального задания числа кластеров. Алгоритм работает по принципу выбора нескольких объектов, которые считаются центральными, собирая вокруг них кластеры. Если центр масс полученных кластеров не совпадает с выбранной точкой, происходит перерасчет, и так до тех пор, пока алгоритм не приходит к минимальным изменениям новой точки-центра.

- *Метод с-средних* оперирует вероятностями принадлежности кластеров к выбираемым центрам, что позволяет проводить нечеткую кластеризацию. Однако алгоритм не работает, когда заранее неизвестно число кластеров, либо необходимо однозначно отнести каждый объект к одному кластеру.

- *Графовые алгоритмы* представляют систему данных как граф, где узлы – объекты, а ребра – расстояния между ними. Основными среди них являются алгоритм выделения связанных компонент (определяется максимальное расстояние, при котором объекты считаются связанными), алгоритм построения минимального покрывающего (остовного) дерева (находится минимальный путь, по которому можно обойти все вершины, а затем удаляются самые большие ребра) и алгоритм послойной кластеризации (формируется последовательность подграфов основного графа, которые отражают иерархические связи между кластерами). Преимущества алгоритмов, применяющих методы теории графов, заключаются в наглядности построения кластеров.

Подготовка данных перед обучением

Самым распространенным типом данных в социальных медиа является текст. Он может выступать как отдельным информационным объектом (статья, сообщение), так и дополнением к другому (например, подпись к изображению). Исследуя тексты, не только как отдельные информационные объекты, но и как дополнение к другим объектам, можно различить в потоке публикаций аккаунта или сообщества деструктивные материалы, например, экстремистского характера.

Именно в текстовых данных может быть заложен паттерн, указывающий на тематику, принадлежность к определенной деструктивной группировке. Стиль письма, используемая лексика, пунктуация, все это может стать той “меткой”, которую

обученная модель может обнаружить через связь с уже известными ей экстремистскими текстами.

В эффективности обработки естественного языка заключается одна из самых сложных задач машинного обучения. Слова, их связь друг с другом, семантику не просто перевести в адекватную цифровую форму, необходимую для применения к набору данных эффективных математических алгоритмов.

Прежде, чем начать обучение модели машинного анализа текста, его представляют в виде числовых признаков, векторизуют [13]. Предложения, словосочетания, семантические связи, формы слов, всё это можно использовать для нужного преобразования текста в зависимости от целей его обработки. Например, если обрабатывается текст сообщений в чате, очень важно учитывать пунктуацию, так как различные смайлики или обилие восклицательных знаков может давать серьезную дополнительную информацию. Помимо этого, в работе с сообщениями имеет смысл тщательно проверять орфографию, чтобы алгоритм не принял слово с ошибкой за отдельную смысловую единицу. В то же время, если стоит задача обработки новостного потока, то для этих текстов пунктуация уже не столь важна, ею можно по сути пренебречь, как и проверкой орфографии. Потому, что, как правило, текст новостей хорошо проверен и вычитан перед опубликованием.

Если же делается попытка создания чат-бота или умных подсказок для поиска, при обучении модели крайне важен контекст слов, а, значит, их последовательность и связь. Здесь весьма важен анализ частей речи, предложений и словосочетаний.

В большинстве случаев, связанных с обработкой языка, стоит проблема размерности конечного словаря, который используется алгоритмом. Чем больше слов, тем больше словарь, и медленнее работает обученная модель.

Как правило, для решения этой проблемы текст нормализуют. Этот процесс состоит из следующих этапов:

- очищение текста от символов пунктуации, которые не представляют интереса для обучения;
- очищение текста от стоп-слов, часто встречающихся в языке, но не несущих никакой смысловой нагрузки для обучения. Как правило, это союзы, предлоги и частицы;
- приведение каждого слова к его начальной форме. Этот процесс называется лемматизацией, позволяя значительно сократить словарь модели. Особенно это полезно для текстов на русском языке, где существует множество форм почти для каждого слова [14].

В настоящей статье выявлялись деструктивные тексты экстремистского содержания, в которых имеются слова, обычно не встречающиеся в текстах другой тематики. Последовательность, пунктуация и орфография при этом незначительно влияют на результат, поскольку для алгоритма важнее определить, есть ли конкретные ключевые слова в исследуемом тексте или нет. Для сокращения словаря используется лемматизация.

Кроме того, для этого применяется *стемминг* как процесс приведения слова к его корню. Он позволяет сократить словарь еще больше, и устанавливает для алгоритма семантическую связь таких слов, как, например, «связавший» и «связать». Хотя эти слова разные, после лемматизации и стемминга оба выглядят как «связ». С одной стороны, это уменьшает словарь, с которым работает модель, что важно для скорости её работы, и объединяет множество слов, схожих по значению. С другой стороны, вместе с формой теряется значительная часть информации о слове, например, «связавшие» и «связанные» весьма значительно различаются по смыслу.

Чтобы решить возникающую проблему, используется подход, когда к корню добавляется метка, указывающая на часть речи. Примеры: «испуганный заяц» – испуг_ADJ заяц_NOUN; «испугать зайца» – испуг_VRB заяц_NOUN; «испугал зайцев» – испуг_VRB заяц_NOUN. Таким образом, сохраняется информации о частях речи, возвращая значительную часть смысла слова.

После того, как текст очищен и приведен к нормальной форме, его необходимо векторизовать, то есть перевести набор слов в тексте к числовой векторной форме. Существует несколько подходов к векторизации:

- *Bag of Words* или «мешок слов». Этот подход используется при обработке текстов, представляющих неупорядоченный набор слов. Векторизованный текст представляется в виде последовательности чисел, каждое из которых является частотой вхождения конкретного слова в текст. Недостатком подхода является то, что он не учитывает последовательность слов, их контекст и связь друг с другом.

• *TF_IDF* (аббревиатура от англ. Term Frequency-Inverse Document Frequency; *TF* – частотность вхождения термина, *IDF* – инвертированная частота документа) отражает статистическую меру, используемую для оценки важности слова в тексте, при котором он, как и в предыдущем подходе, представляется как вектор из частоты встречающихся в нем слов. При подходе *TF_IDF* частота слова рассчитывается как отношение встречаемости слова в документе к его встречаемости во всем корпусе документов, на которых обучена модель. *TF_IDF* используют, когда требуется организовать эффективный поиск по большому корпусу документов.

- *Word2vec* отличается от двух предыдущих тем, что векторизуется не сам текст, а слова. Представляет нейронную сеть,

которая, в отличие от Bag of Words и TF_IDF, хорошо работает с контекстом, позволяя находить синонимы. Модель имеет два режима обучения – Continuous Bag of Words (CBoW) и Skip-gram. Разница между ними заключается в следующем. Если CBoW предсказывает слово, исходя из контекста его окружения, то Skip-gram – наоборот, предугадывает окружение рассматриваемого слова.

Решение задач выявления деструктивного контента

В качестве моделей классификации текста с целью выявления деструктивного контента выберем три алгоритма: вычисление средних векторов, случайный лес и логистическая регрессия. Для векторизации текстов применим все три вышепересмотренных метода. При этом методы векторизации Bag of Words и TF_IDF будем применять вместе с методом главных компонент, позволяющим убрать малозначительные признаки (слова, которые практически не влияют на определение класса) до обучения основной модели.

Таким образом, проанализируем качество работы трех методов векторизации текста и трех моделей его классификации. То есть всего исследуем девять комбинаций и оценим полученные результаты классификации текстов, содержащих деструктивный контент. Для решения задач используем обучение с учителем, когда текстовые данные помечены заранее как содержащие экстремистские высказывания или не содержащие их.

Для того чтобы предсказания модели были наиболее точны, выборка должна быть как можно более разнообразной, а помеченные классами данные иметь достаточно сходств и различий. Иными словами, иметь признаки текста как деструктивного, так и признаки, которые

отличают текст с не деструктивным контентом [15]. В качестве деструктивных исследовались тексты, пропагандирующие радикальный исламизм как крайнее проявление политического ислама, применяющего насильственные методы ведения политической борьбы.

Так как тексты, пропагандирующие радикальный исламизм, существенно отличаются от обычных публикаций, в обучающую выборку с меткой «не содержит экстремистских высказываний» добавлены публикации с исламской проблематикой. Проверка осуществлялась для трех наборов тематик: один – из новостного сообщества, второй – из сообщества, посвященного исламской культуре, третий – из экстремистских текстов, не участвовавших в обучении. Всего для решения задачи использованы шесть датасетов – наборов данных (табл. 1).

Обработка текстов включала удаление пунктуации, стоп-слов, лемматизацию и стемминг, добавление к основе слова флага части речи. Последовательность работы с текстами включала восемь этапов:

- 1) сбор публикаций из социальной сети ВКонтакте;
- 2) нормализация текстов публикаций для обучения;
- 3) векторизация текстов публикаций для обучения моделей;
- 4) обучение моделей, создание трех корпусов документов для каждой из них, оценка точности на тестовых данных;
- 5) нормализация текстов классифицируемых публикаций;
- 6) векторизация классифицируемых текстов;
- 7) классификация текстов обученными моделями;
- 8) сравнение результатов.

Таблица 1

Наборы данных для машинного обучения

Наборы данных для обучения			Наборы данных для проверки		
Датасет1	Датасет2	Датасет3	Датасет4	Датасет5	Датасет6
Публикации без определенной тематики.	Публикации об исламе, не имеющие экстремистской направленности.	Публикации о радикальном исламе. Много редких слов.	Новостные публикации, ориентированные на молодежь и близкие оппозиционным взглядам.	Публикации, включающие новости и их обсуждение с точки зрения проблематики и ислама.	Публикации о радикальном исламе. Много редких слов.

В процессе обучения модели использован язык программирования Python, обеспеченный простыми в использовании библиотеками для работы с векторами, большими массивами, таблицами и моделями.

Для нормализации текстов использовались:

- `nlk` – лингвистическая библиотека [16], реализующая возможности очистки пунктуации, наборы стоп-слов для различных языков, а также стеммер для приведения слова к его корню;

- `rumorphy2` – библиотека [17], позволяющая определять нормальную форму слов и слово как часть речи.

Далее осуществляется векторизация с помощью библиотеки `sklearn` [18], которая включает:

- `CountVectorizer` – алгоритм Bag of Words, с помощью которого можно векторизовать любой новый текст.

- `TfidfVectorizer` – алгоритм TF-IDF, работающий как и `CountVectorizer`.

- `RandomForestClassifier` – модель случайного леса. Используется со стандартными настройками, для обучения необходим набор тренировочных данных и их метки.

- `LogisticRegression`, представляющий модель логистической регрессии.

- `PCA`, представляющий метод главных компонент для снижения размерности данных с минимальной потерей информации.

Набор алгоритмов `Word2Vec` представлен в библиотеке `Gensim` [19], а алгоритм вычисления и сравнения средних векторов написан авторами.

В табл. 2 приведены результаты сравнения точности девяти комбинаций модель-метод на обучающей выборке.

Из анализа табл. 2 следует, что наилучшими результатами (0,97) по точности характеризуются комбинации “логистическая регрессия – Bag of Words” и “случайный лес – Bag of Words”; немного ниже точность (0,94) комбинаций “логистическая регрессия – Bag of Words”, “логистическая регрессия – Word2vec” и “случайный лес – TF-IDF”; довольно высока точность комбинации “случайный лес – Word2vec”; весьма средней точностью (0,64) отличается комбинация “вычисление средних векторов – TF-IDF; независимо от методов векторизации (Bag of Words и Word2vec) весьма низки точности модели вычисления средних векторов – 0,015 и 0,19, соответственно.

Как итог исследования, проанализированы тексты, не использованные при обучении модели и не имеющие меток. Для этого применены датасеты 4, 5, 6 из табл. 1. На указанных наборах данных классификационная модель вычисления средних векторов при векторизации методом Bag of Words характеризуется самыми низкими

показателями точности, однако показывает наиболее высокие результаты для моделей случайного леса и логистической регрессии. Это связано с тем, что, в отличие от TF-IDF, указанный метод не уменьшал веса слов, которые часто встречались в тренировочном наборе с меткой «экстремистские высказывания».

Таблица 2

Точность моделей в зависимости от метода векторизации текста обучающих выборок

Метод векторизации Модель классификации	Bag of Words с применением метода главных компонент	TF-IDF с применением метода главных компонент	Word2vec, текст как средний вектор всех входящих в него слов
Средние вектора	0.015	0.64	0.19
Случайный лес	0.97	0.94	0.89
Логистическая регрессия	0.97	0.94	0.94

В то же время модели классификации случайного леса и логистической регрессии с применением метода векторизации Word2vec оказались по точности хуже: предсказания менее точны и на тестовых, и на других публикациях. Однако на модели классификации с вычислением средних векторов этот метод проявил себя достаточно убедительно.

Выводы

1. С помощью примененных современных моделей и методов все тексты, включающие деструктивный контент, классифицированы верно. Наиболее высокую точность при решении задачи распознавания деструктивного контента дает системная интеграция алгоритма векторизации Bag of Words, метода главных компонент для снижения пространства признаков описания текстов и логистической регрессии или случайного леса как моделей обучения.

2. Для решения задачи выявления деструктивного контента в социальных медиа хорошие результаты дают модели машинного обучения: случайного леса и логистической регрессии для текстовых данных, векторизованных через алгоритмы TF-IDF; несколько хуже результаты для Word2vec, если векторизовать классифицируемый текст как средний вектор всех входящих в него слов.

3. Способы обработки и векторизации текстов имеют следующие достоинства и недостатки с точки зрения задачи выявления деструктивного контента. При применении Bag of Words – два преимущества: алгоритм учитывает крайне важный параметр – высокий вес для слов, часто встречающихся в текстах и могущих быть ключевыми. Недостатки заключаются в том, что веса для слов могут быть высокими и в том случае, если слова являются часто употребляемыми в языке, что приводит к созданию шума в векторизованных данных. В случае

использования алгоритма TF_IDF имеются те же преимущества, что и при выборе Bag of Words, однако веса для часто встречающихся слов в документах пропорционально снижаются. Набор алгоритмов Word2vec имеет недостаток – векторное описание слов, не интерпретируемое человеком.

4. Используемые наборы данных, имеющих связь с исламским радикализмом, характеризуются достаточно четкими признаками, которые хорошо вычисляемы с помощью современных моделей, методов и алгоритмов, и могут эффективно применяться для автоматизированной классификации текстовых массивов с целью выявления их деструктивной направленности.

5. Развитие направления, представленного в статье [20-23], связано с увеличением исследуемых корпусов документов, более детальным анализом текстов на основе сложных моделей распознавания латентной экстремистской пропаганды, в том числе – представленной в фото, аудио- и видео форматах.

Список литературы

1. Андромонова В.В. Социальные сети в контексте развития современного общества // Современные проблемы науки и образования. 2015. № 2. С.17–22.
2. Yang C. C., Ng T. D. Terrorism and Crime Related Weblog Social Network: Link, Content Analysis and Information Visualization / In the Proceedings of the International Conference IEEE Intelligence and Security Informatics. 2007. May 23–24. New Brunswick, NJ. Pp. 55-58.
3. Басараб М. А., Иванов И. П. Колесников А.В., Матвеев В.А. Обнаружение противоправных действий в киберпространстве на основе анализа социальных сетей: алгоритмы, методы и средства (обзор) // Вопросы кибербезопасности. 2016. № (4)17. С. 11-19.
4. Титов Н.Г., Чапурин Е.Ю., Москалева Е.А., Бочаров М.И., Борисов В.И. Методы мониторинга социальных сетей, их развитие и применение в контексте обеспечения их информационной безопасности // Информация и безопасность. 2019. Том 22. № 3(4). С. 305–324.
5. Malathi A., Radha D. Analysis and Visualization of Social Media Networks / International Conference on Computation System and Information Technology for Sustainable Solutions (CSITSS). 2016. 6-8 October. Bengaluru, India. Pp. 58-63.
6. Hassanzadeh R., Nayak R., Stebila D. Analyzing the Effectiveness of Graph Metrics for Anomaly Detection in Online Social Networks / Web Information Systems Engineering - WISE 2012. Lecture Notes in Computer Science, Vol. 7651. Springer, Berlin, Heidelberg. Pp. 624-630.
7. Bonchi F. Influence Propagation in Social Networks: A Data Mining Perspective // IEEE Intelligent Informatics Bulletin. 2011. No12(1). Pp. 8-16.
8. Суханов А. А., Маратканов А. С. Анализ способов сбора социальных данных из сети Интернет // International Scientific Review. 2017. №1 (32). – С. 22-25.
9. Chi-In Wong, Kin-Yeung Wong, Kuong-Wai Ng, Wei Fan, Kai-Hau Yeung. Design of a Crawler for Online Social Networks Analysis // WSEAS Transactions on Communications. 2014. Vol. 13. – Pp. 263-274.
10. Воронина В. В., Михеев А. В., Ярушкина Н. Г., Святков К. В. Теория и практика машинного обучения: Учебное пособие. Ульяновск: УлГТУ, 2017. – 290 с.
11. Чистяков С.П. Случайные леса. // Труды Карельского Научного центра РАН. 2013. №1. – С.117-136.
12. Ершов К.С., Романова Т.Н. Анализ и классификация алгоритмов кластеризации // Новые информационные технологии в автоматизированных системах. 2016. № 19. – С. 274-279.
13. Bird S., Klein E., Loper E. Natural Language Processing with Python. Sebastopol: O'Reilly Media, US, 2009. – 482 p.
14. Жардева М.В., Артюшенко В. М. Стемминг и лемматизация в Lucene.net // Лесной вестник. Forestry Bulletin. 2016. № 20(3). – С. 131-134.

15. Кафтанников И.Л., Парасич А. В. Проблемы формирования обучающей выборки в задачах машинного обучения // Вестник ЮУрГУ. Серия “Компьютерные технологии, управление, радиоэлектроника”. 2016. №3. С.15-24.
16. Документация библиотеки NLTK. URL: <https://www.nltk.org/>. Дата обращения 31.12.2020.
17. Документация библиотеки Rymorphy2. URL: <https://pymorphy2.readthedocs.io/en/latest/user/guide.html>. (дата обращения: 31.12.2020).
18. Документация библиотеки Scikit Learn. URL: <https://www.sklearn.org/documentation.html> (дата обращения 31.12.2020).
19. Документация библиотеки Gensim. URL: https://radimrehurek.com/gensim/auto_examples/index.html. (дата обращения 31.12.2020).
20. Киракосян А.Э., Минаев В.А., Сычев М.П. Моделирование информационного противоборства в социальных медиа. М.: Наука, 2020. 154 с.
21. Андреев А.А., Бондарь К.М., Минаев В.А. Терроризм и экстремизм: моделирование информационного противодействия. Хабаровск: ДВЮИ МВД России, 2020. 248 с.
22. Минаев В. А. Информационное противоборство в социальных сетях: модели и методы исследования // Информация и безопасность. 2020. Т. 23. Вып. 4. С. 477-496.
23. Минаев В. А., Корячко А. В., Симонов А. В. Особенности распознавания экстремистского контента “А.У.Е.” в социальных сетях / Материалы XXV Юбилейной всеросс. науч.-техн. конф. студентов, молодых ученых и специалистов “Новые информационные технологии в научных исследованиях”. 18-20 ноября. Рязань: РГТРУ им. В. Ф. Уткина, 2020. С. 36-37.

Московский государственный технический университет им. Н. Э. Баумана
Bauman Moscow State Technical University

Поступила в редакцию 20.01.2021

Информация об авторах

Минаев Владимир Александрович – д-р техн. наук, профессор, профессор кафедры защиты информации, Московский государственный технический университет им. Н. Э. Баумана, e-mail: mlva@yandex.ru.

Реброва Алена Дмитриевна – студентка кафедры защиты информации, Московский государственный технический университет им. Н. Э. Баумана, e-mail: scahann@yandex.ru.

Симонов Александр Викторович – аспирант кафедры защиты информации, Московский государственный технический университет им. Н. Э. Баумана, e-mail: scahann@yandex.ru.

DETECTION DESTRUCTIVE CONTENT IN SOCIAL MEDIA BASED ON MACHINE LEARNING MODELS

V.A. Minaev, A.D. Rebrova, A.V. Simonov

The article discusses models of classification of text content and methods of its pre-processing in order to identify destructive influences in social media. It is shown that the main source of destructive content is the user profile, which is characterized by a set of personal data, the content of publications, community parameters, network accounts, messages and chats. Automated data collection and analysis using case-based and deductive learning models is discussed. We consider their main varieties and the tasks solved on their basis, including forecasting and typology in the aspect of the destructive content of texts, reducing the dimension of the features of their description. The main methods of text vectorization are investigated and applied: Bag of Words, TF_IDF, Word2vec. The tasks of identifying

destructive content related to Islamic radicalism are solved on the practical corpus of texts from the social network VKontakte. It is shown that using the applied models and methods, all texts that include destructive content are classified correctly. The highest accuracy (0.97) in solving the problem of recognizing destructive content is provided by the system integration of the Bag of Words vectorization algorithm, the principal component method for reducing the feature space of text descriptions, and logistic regression or random forest as learning models. It is concluded that the data sets associated with Islamic radicalism are characterized by sufficiently clear features that are well calculated using modern models, methods and algorithms, and can be effectively used for automated classification of text arrays in order to identify their destructive orientation. The development of the direction presented in the article is associated with an increase in the studied corpus of documents, a more detailed analysis of texts based on complex models for recognizing latent extremist propaganda, including those presented in photo, audio and video formats.

Keywords: destructive text content, Islamic radicalism, social media, recognition of negative information impact, machine learning model.

Submitted 20.01.2021

Information about the authors

Vladimir A. Minaev – Dr. Sc. (Technical), Professor, Professor of the Department of Information Security, Bauman Moscow State Technical University, e-mail: m1va@yandex.ru.

Alena D. Rebrova – Student of the Department of Information Security, Bauman Moscow State Technical University, e-mail: scahann@yandex.ru.

Alexander V. Simonov – Post-graduate Student of the Department of Information Security, Bauman Moscow State Technical University, e-mail: scahann@yandex.ru.