

## КОЛИЧЕСТВЕННАЯ ОЦЕНКА ДЕСТРУКТИВНОСТИ БОЛЬШИХ ТЕКСТОВЫХ МАССИВОВ В СОЦИАЛЬНЫХ МЕДИА

В.А. Минаев, А.В. Симонов

Цель исследования состоит в разработке методики, позволяющей выявлять деструктивность больших текстовых массивов в социальных медиа. Проведен анализ существующих подходов к определению деструктивного характера текстовых данных, дано описание их преимуществ и недостатков. Описан метод определения деструктивности текста с использованием векторных представлений слов. Рассмотрено формирование векторных представлений слов и оценена возможность их применения при решении задач идентификации текстового контента. Обосновано применение алгоритмов Word2vec и FastText. Предложены ключевые слова и выражения векторных представлений слов, определяющих три класса текстов: реабилитация нацизма, радикальный ислам, антисемитизм. Реализованы модели выявления деструктивности контента больших текстовых массивов с использованием нейтральных новостных корпусов текстов и текстов, содержащих возможный деструктивный контент. Произведена интерпретация результатов анализа текстовых массивов и обоснована Word2vec как наиболее подходящая модель векторного представления слов. Сделан вывод о направлениях использования полученных результатов в аналитической деятельности государственных органов, общественных организаций и социальных медиа для выявления противоправного контента.

Ключевые слова: информационная безопасность, социальные медиа, деструктивный контент, мониторинг, идентификация.

### Введение

Социальные медиа сегодня выступают неотъемлемой частью в системе коммуникаций практически каждого человека. Доступность чужой информации вместе с простотой обмена своей делают их наиболее популярными источниками различных материалов.

В то же время, названные достоинства социальных медиа используются не только для обмена позитивной информацией. Нарастающие проблемы качественной онлайн-фильтрации сетевого контента в соответствии с четкими критериями позволяют распространять и деструктивный контент.

К деструктивному контенту, запрещенного к распространению в Российской Федерации и преследуемого по закону, относятся:

– возбуждение ненависти либо вражды, а равно унижение человеческого достоинства (ст. 20.3.1 КоАП РФ, ст. 282 УК РФ);

– реабилитация нацизма (ст. 354.1 УК РФ);

– публичные призывы к осуществлению экстремистской деятельности (ст. 20.3.2 КоАП РФ, ст. 280 УК РФ).

Такого рода контент направлен на оказание негативного информационно-психо-логического воздействия на различные слои общества.

В соответствии с Доктриной информационной безопасности Российской Федерации, утвержденной Указом Президента Российской Федерации от 05.12.2016 № 646, воздействие такого рода является одной из основных информационных угроз безопасности государства и представляет опасность для развития страны в целом [1].

В связи с этим задачи выявления и пресечения распространения деструктивного контента в социальных медиа являются одними из актуальных и приоритетных в рамках обеспечения безопасности российского государства.

Поиском, идентификацией и нейтрализацией деструктивных материалов занимаются как государственные структуры [2] (Генеральная Прокуратура, МВД, ФСБ, Роскомнадзор), так и общественные организации [3], а с недавних пор – и сами социальные медиа [4].

### **Анализ предметной области**

Методы выявления деструктивного контента делятся на три группы:

- полностью автоматизированные;
- ручные, выполняющиеся силами экспертов;
- комбинированные.

Автоматизированные методы, в свою очередь, подразделяются на две подгруппы: статистические и методы, основанные на машинном обучении.

Основным принципом работы *статистических методов* является поиск в текстах наиболее популярных (частотных) или ключевых (уникальных) слов, находящихся в Федеральном списке экстремистских материалов, составленном Министерством Юстиции РФ на основе судебных решений [5].

Основным недостатком таких методов является отсутствие возможности анализа семантической составляющей при исследовании ключевых слов и тональности текстов, в связи с чем высока вероятность возникновения ложного срабатывания – ошибки 2-го рода.

Например, если сравнивать два книги, одна из которых осуждает действия А. Гитлера, а другая прямо восхваляет эту личность, то в частотном соотношении они обе могут быть отнесены к деструктивным.

Однако существуют круг задач, когда применение данных методов является единственно возможным. К таковым, например, относится настройка систем предотвращения утечек данных в организациях (Data Leak Protection, DLP) в целях выявления недобросовестных сотрудников [6].

*Методы, основанные на машинном обучении.* Их основное отличие при решении задач классификации текста – это предварительная обработка текста.

Предобработка текста, как правило, состоит из трех этапов:

1. Удаление символов и слов, не несущих смысловой нагрузки (стоп-слова).
2. Лемматизация – приведение каждого слова к его основной словарной форме, лемме. В некоторых случаях в целях ускорения процесса предобработки используют стемминг – алгоритм нахождения основы слова [7].
3. Кодировка полученных лемм.

После представления текста в виде набора кодов или векторов дальнейшие шаги сводятся к типовому решению задачи машинного обучения [8].

Использование методов машинного обучения в решении задач классификации текста показывает достаточно высокие результаты [9-11]. Однако нельзя не отметить высокую зависимость результатов от характеристик обучающей выборки.

Например, если модель обучается только на двух корпусах текстов (нейтральном и деструктивном), то она будет хорошо различать именно эти два класса.

Поэтому в реальном случае, когда при машинном анализе попадет текст, по тематике находящийся ближе всего к деструктивному типу, но не являющийся деструктивным, то происходит ложная реакция системы распознавания.

*Ручной контентный анализ.* Преимуществом перед автоматизированными методами такого подхода является снижение до минимума ошибки 2-го рода. Ведь эксперту по выявлению противоправного контента несложно идентифицировать деструктивный твит или публикацию в два-три предложения.

Однако сложность возникает при ручном анализе больших текстовых массивов. Более того, как показывает практика, юридическое признание экстремистскими таких текстов затягивается на долгие месяцы.

Если десяток лет назад этот метод являлся основным при выявлении деструктивного контента, в настоящее время его использование нецелесообразно. Причина – огромный рост публикаций в социальных медиа.

По данным исследования компании Brand Analytics ежемесячно в различных социальных медиа России появляется около 1,2 миллиарда публикаций [12]. Их распределение по основным медиа представлено на рис.1.

Очевидно, что проведение анализа такого количества публикаций ручным способом просто невозможно. Поэтому активно применяются комбинированные методы [13]: сначала используются автоматизированные методы, а в пограничных случаях, когда велика вероятность ложного определения деструктивности контента, производится его анализ силами экспертов.

Пограничным, например, считается случай, когда автоматизированная система признала анализируемый контент деструктивным, но вероятность деструктивности которого не выше некоторого заданного порогового значения.




Рис. 1. Распределение публикаций в социальных медиа в течение месяца, млн.

Комбинированные методы позволяют эффективно исследовать небольшие публикации, например, посты в социальной сети или материалы, основанные на изображениях. Эксперту не составляет труда бегло прочитать публикацию, оценить фото

или видео изображение для идентификации деструктивности материала.

Принцип работы комбинированных методов при выявлении деструктивности текстовых публикаций представлен на рис. 2.

Однако в то же время, крайне непросто производить неавтоматизированным образом анализ многостраничных текстовых материалов. Риск неточной идентификации при этом сравним с простыми автоматизированными методами, что опять же заставляет прибегать к труду экспертов при анализе текстов.




Рис.2. Блок-схема работы комбинированных методов выявления деструктивного контента

### Задача анализа больших текстовых массивов

Итак, существующие методы выявления деструктивного контента характеризуются проблемой, связанной с обработкой больших текстовых массивов, которая приводит к росту ошибок первого или второго рода (в зависимости от заданного порога) и повышения нагрузки на экспертов.

Целью статьи является обоснование и пилотное изучение метода, который позволил бы экспертам производить анализ больших текстовых данных с приемлемой скоростью, сопоставимой с анализом коротких сообщений, комментариев и подписей к различным аудио/видео материалам.

Для достижения названной цели метод должен обладать следующими свойствами:

- трудозатраты при анализе текстовых данных большого объема сопоставимы с анализом коротких сообщений;
- интуитивная понятность, не требующая для освоения специальных знаний и подготовки;
- универсальность применительно к текстам с любой деструктивностью.

### Метод решения задачи

Предлагаемое решение заключается в том, что вместо оценки экспертами больших объёмов текстовых данных производится автоматизированная оценка сходства семантически близких слов с ключевыми словами деструктивного контента. Поиск семантически близких слов осуществляется за счет векторного представления каждого слова и последующего вычисления косинусного сходства между словами.

Косинусное сходство – это мера сходства между двумя векторами, отражающая косинус угла между ними [14] и изменяющаяся в диапазоне от 0 до 1. Вычисляется по формуле:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \cdot B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \cdot \sqrt{\sum_{i=1}^n (B_i)^2}} \quad (1)$$

Данный подход позволяет:

- свести анализ большого текстового

массива к оценке семантической близости 10-15 слов к ключевому для формирования оценки деструктивности текста;

- подобрать ключевые слова и произвести сравнение семантической близости, не требуя узкоспециализированной подготовки;

- масштабироваться под любые размеры текстов и применяться для различных языков мира.

Векторное представление слов производится с помощью специальных моделей компьютерной обработки естественного языка.

Одним из этапов обработки является преобразование на основе нейронной сети слов к некоторому вектору. На выходе моделей при правильно выбранных параметрах и архитектуре нейронной сети получаются векторы слов, которые в случае высокого косинусного сходства между ними имеют похожую семантику применения.

Таким образом, на основе качественно настроенной и обученной модели векторного представления находятся семантически похожие слова. Существует различные модели векторных представлений слов. Наиболее известные из них: BERT [15], Word2vec [16], FastText [17].

BERT (Bidirectional Encoder Representations from Transformers) – модель-трансформер, основанная на глубоких нейронных сетях, которая характеризуется наиболее высокими результатами при решении различных задач машинного обучения. В частности, использование BERT с нейронной сетью LSTM показывает выдающиеся результаты на различных соревнованиях по классификации текстов. Однако высокие показатели связаны с высокой сложностью реализации (модель BERT-base имеет 110 миллионов параметров) и необходимостью обучения на больших текстовых корпусах [15]. Поэтому применение данной модели для решения поставленной задачи методически сложно и экономически дорогостояще.

В настоящей работе эксперименты проводились на моделях Word2vec с архитектурой Skip-gram и FastText, хорошо обучаемых на малых выборках и не

требующих больших вычислительных ресурсов. Как показали исследования [16-19], указанные модели удовлетворительно вычисляют семантическую связь между словами.

В основе группы моделей Word2vec лежит искусственная нейронная сеть с одним скрытым слоем, базирующаяся на двух различных архитектурах для обучения и преобразования слов в векторное представление: Continuous Bag of Words (CBOW) и Skip-gram. При создании модели помимо выбора архитектуры важными параметрами являются размер вектора и размер окна обучения. Рассмотрим подробнее каждый из них.

CBOW архитектура используется, когда необходимо по имеющемуся контексту предсказать слово, находящееся в его середине. Skip-gram архитектура наоборот по вектору слова предсказывает окружающий его контент. Из результатов, полученных в [20, 21], сделан вывод, что при использовании моделей Word2vec архитектуру CBOW целесообразно использовать для классификации текстов, а для определения семантической близости и определения тональности – архитектуру Skip-gram. Поэтому для проведения экспериментов выбрана архитектура Skip-gram, как наиболее подходящая для решения поставленной задачи. При реализации Skip-gram на вход модели Word2vec подается вектор слова размерности  $V$ :  $x = (x^1, x^2, \dots, x^V)$ ,  $i = 1 \dots h$ , где  $h$  – соседние слова, а  $x^j = 1$  в случае, если данное слово является  $j$ -ым и  $x_i^k = 0$  в случае если  $k \neq j$ . Выходными данными являются  $h$  векторов размерностью  $V$ :  $y_i = (y_i^1, y_i^2, \dots, y_i^V)$ ,  $i = 1 \dots h$ . В случае, если  $i$ -ое предсказываемое слово является  $j$ -ым словом из словаря, то  $y_i^j = 1$ , иначе  $y_i^k = 0$ ,  $k \neq j$ . Веса нейронов обозначаются как  $W$  и  $W'$ , соответственно. Архитектура нейронной сети представлена на рис. 3.

FastText – модель, разработанная в 2016 году [16], по своим принципам схожа с моделями Word2Vec. Основные отличия FastText в том, что векторизируемые слова нарезаются на  $n$ -граммы – фиксированные части слов. Допустим для слова «контент» его три-граммами будут ['кон',

'онт', 'нте', 'тен', 'ент']. Далее производится расчет векторов для всех  $n$ -грамм, а вектор слова вычисляется суммированием полученных векторов  $n$ -грамм.

В качестве архитектуры сети используется Skip-gram, аналогичная Word2Vec. За счет особенностей векторизации слов FastText позволяет учитывать морфологию и обучаться на словах, отсутствующих в обучающей выборке.




Рис. 3. Схема нейронной сети модели Word2vec с архитектурой Skip-gram

Выбор размера вектора при векторизации каждого слова осуществляется, исходя из итогов исследований [22]. Наиболее высокие результаты при относительно невысокой вычислительной сложности дает размер вектора каждого слова, равного 300.

Размер окна обучения – максимальное расстояние между текущим и предсказанными словами в предложении. Т.е. в случае выбранной нами архитектуры размер



окна, равного 5, предсказывает 2 предыдущих слова и 2 последующих от поданного вектора. Такой размер выбран, исходя из статистических данных анализируемых корпусов текстов: среднее количество предложений в тексте равно 7, в связи с чем охват окна, равного 5, позволяет адекватно обучить модели.

Для обучения моделей векторных представлений слов и получения семантически близких слов необходимо сформировать нейтральный корпус текста, результаты которого будут восприниматься экспертами в качестве эталонных

«семантических соседей».

Нейтральный (эталонный) корпус текстов выбирался, исходя из того, что в него очень сложно попасть деструктивному контенту, поскольку его материалы предварительно тщательно контролируются. К материалам с такими свойствами относятся корпуса текстов с классической литературой, а также корпуса сайтов официальных СМИ. В связи с этим авторами выбран в качестве обучающей выборки корпус публикаций из новостного ресурса «Лента» [23]. Указанный корпус обладает следующими характеристиками (табл. 1).

Таблица 1

Свойства нейтрального (эталонного) корпуса текстов

| Свойства                                   | Значение                   |
|--------------------------------------------|----------------------------|
| Формат файла                               | comma separate value (csv) |
| Объем файла                                | 106 622 КБ                 |
| Количество новостей                        | 30000                      |
| Количество предложений (обучающая выборка) | 246584                     |

Перед тем, как формировать ключевые слова деструктивности и эталонные семантически близкие к ним слова, определим исследуемые классы деструктивности. В работе выбраны следующие классы:

- реабилитация нацизма;
- радикальный ислам;
- антисемитизм.

Указанные классы выбраны как несущие ярко выраженную агрессивную окраску в соответствующих высказываниях, а также несущие наибольшие угрозы общественной безопасности.

Для каждого выбранного класса необходимо выбрать ключевые слова представления деструктивности, с помощью которых далее будет проводиться анализ.

Одним из наиболее интересных свойств векторных моделей является то, что над словами после их преобразования можно

производить векторные операции сложения и вычитания. В качестве известного примера можно привести следующее выражение: «король» - «мужчина» + «женщина» = «королева». Воспользуемся этой возможностью для создания ключевых выражений деструктивности.

Для различных классов деструктивности выбраны слова и выражения, приведенные в табл. 2. Данные выражения и слова выбраны так, чтобы по их семантическим соседям в векторном представлении была явно видна окраска употребления этих слов и словосочетаний в тексте.

Программная реализация моделей, их обучение с формированием семантических соседей к ключевым словам по классам деструктивности производились с использованием языка программирования Python и соответствующих встроенных библиотек.

Таблица 2

| Классы деструктивности и ключевые слова |                                   |
|-----------------------------------------|-----------------------------------|
| Класс деструктивности                   | Ключевое слово деструктивности    |
| Реабилитация нацизма                    | Германия                          |
|                                         | «национал»+«социализм»            |
|                                         | «Германия»+«Гитлер»+«война»-«мир» |
| Радикальный ислам                       | «джихад»+«Россия»                 |
|                                         | «террор»+«народ»                  |
|                                         | кафир                             |
| Антисемитизм                            | еврей                             |
|                                         | иудей                             |

Представим пошаговую работу созданной программы:

Шаг 1. Загрузка корпуса данных и его представление в виде фрейма. Используются библиотеки «os» для загрузки данных и «pandas» для формирования фрейма.

Шаг 2. Очистка загруженных данных. Используется библиотека регулярных выражений «re» с помощью которых производится фильтрация слов.

Шаг 3. Лемматизация и удаление стоп-слов. Реализуется с использованием библиотеки морфологического анализатора «rmmorphology2» [24] и библиотеки компьютерной обработки текста «NLTK».

Шаг 4. Создание моделей векторного представления слов и формирование семантически близких слов к ключевым словам деструктивности. Реализуется с помощью библиотеки «gensim», включающей в себя модели Word2vec и Fasttext.

Шаг 5. Вывод результатов. Реализуется встроенными библиотеками языка Python.

После построения и обучения векторных моделей слов, выбора нейтральных корпусов текстов и получения эталонных результатов можно приступить к анализу деструктивных текстов.

Работа комбинированного метода оценки деструктивности больших текстов в социальных медиа представлена на рис. 4.



Рис. 4. Блок-схема работы комбинированного метода оценки деструктивности больших массивов в социальных медиа

**Обсуждение результатов**

В целях проверки работоспособности предложенного комбинированного метода для поиска деструктивного контента выбраны социальная сеть «ВКонтакте» и публичные интернет-форумы. Посты и текстовые файлы выбирались исходя из того, что исследуемые материалы на момент проведения поиска (10.05.2021) долгое время находились в открытом доступе – сделан экспертный вывод об отсутствии выявления деструктивного контента автоматизированными методами.

В качестве тестового деструктивного текста для класса «Реабилитация нацизма» выбран пост, содержащий отрывки из

запрещенной в соответствии с законодательством Российской Федерации одной из книг, находящейся в списке экстремистских материалов).

В табл. 3 приведены результаты моделирования и формирования семантически близких к ключевым словам деструктивности по классу «Реабилитация нацизма», с применением модели Word2vec, а в табл. 4 с FastText. В таблице указаны первые 10 семантически близких слов, а в соседнем столбце приведено также вычисленное косинусное расстояние в соответствии с формулой (1).

Таблица 3

Результаты анализа деструктивности в классе 1 на основе Word2vec

| Ключевые слова и выражения                                | Семантически близкие слова в Word2vec |                |                   |                |
|-----------------------------------------------------------|---------------------------------------|----------------|-------------------|----------------|
|                                                           | Эталонный корпус                      |                | Исследуемый текст |                |
|                                                           | Слова                                 | $\cos(\theta)$ | Слова             | $\cos(\theta)$ |
| Германия                                                  | Италия                                | 0,6670         | Нация             | 0,9998         |
|                                                           | Франция                               | 0,6566         | Германский        | 0,9997         |
|                                                           | Швеция                                | 0,6510         | Звание            | 0,9986         |
|                                                           | Нидерланды                            | 0,6509         | Ответ             | 0,9974         |
|                                                           | ФРГ                                   | 0,6505         | Достаточно        | 0,9954         |
|                                                           | Финляндия                             | 0,6424         | Удаться           | 0,9932         |
|                                                           | Австрия                               | 0,6418         | Называть          | 0,9833         |
|                                                           | Голландия                             | 0,6274         | Пройти            | 0,9611         |
|                                                           | Польша                                | 0,6112         | Вопрос            | 0,9534         |
|                                                           | Англия                                | 0,6095         | История           | 0,9502         |
| «национал»<br>+<br>«социализм»                            | Большевистский                        | 0,9075         | Хотеть            | 0,9998         |
|                                                           | Праворадикальный                      | 0,8899         | Успех             | 0,9943         |
|                                                           | Ортодоксальный                        | 0,8854         | Честь             | 0,9831         |
|                                                           | Радикал                               | 0,8850         | Усилие            | 0,9786         |
|                                                           | Ультраортодоксальный                  | 0,8577         | Норма             | 0,9511         |
|                                                           | Раскольнический                       | 0,8557         | Родина            | 0,9503         |
|                                                           | Леворадикальный                       | 0,8504         | Воля              | 0,9448         |
|                                                           | Националистический                    | 0,8431         | Сражаться         | 0,9358         |
|                                                           | Правоецентристский                    | 0,8424         | Стремление        | 0,9278         |
| «Германия»<br>+<br>«Гитлер»<br>+<br>«война»<br>-<br>«мир» | Ультрарадикальный                     | 0,8420         | Мужество          | 0,9087         |
|                                                           | Фашистский                            | 0,7134         | Фронтной          | 0,9932         |
|                                                           | Нацист                                | 0,6934         | Сражаться         | 0,9905         |
|                                                           | Нацистский                            | 0,6849         | Соответствовать   | 0,9796         |
|                                                           | Адольф                                | 0,6689         | Стремление        | 0,9497         |
|                                                           | Концлагерь                            | 0,6425         | Армия             | 0,9326         |
|                                                           | Престол                               | 0,6410         | Нация             | 0,9319         |
|                                                           | Гестапо                               | 0,6025         | Героизм           | 0,8944         |
|                                                           | Холокост                              | 0,5864         | Успех             | 0,8858         |
|                                                           | Колониальный                          | 0,5464         | Осознавать        | 0,8778         |
|                                                           | Геноцид                               | 0,5439         | Благо             | 0,8750         |



Таблица 4

Результаты анализа деструктивности в классе 1 на основе FastText

| Ключевые слова и выражения                                | Семантические близкие слова в FastText |                |                   |                |
|-----------------------------------------------------------|----------------------------------------|----------------|-------------------|----------------|
|                                                           | Эталонный корпус                       |                | Исследуемый текст |                |
|                                                           | Слова                                  | $\cos(\theta)$ | Слова             | $\cos(\theta)$ |
| Германия                                                  | Румыния                                | 0,8498         | Германский        | 0,9998         |
|                                                           | Мания                                  | 0,8328         | Германец          | 0,9978         |
|                                                           | Жвания                                 | 0,8184         | Дать              | 0,9955         |
|                                                           | Амелия                                 | 0,7846         | Мать              | 0,9932         |
|                                                           | Япония                                 | 0,7763         | Значительный      | 0,9912         |
|                                                           | Алания                                 | 0,7758         | Приходиться       | 0,9900         |
|                                                           | Юлия                                   | 0,7658         | Проводить         | 0,9864         |
|                                                           | Финляндия                              | 0,7584         | Совершать         | 0,9777         |
|                                                           | Фобия                                  | 0,7531         | Призвать          | 0,9756         |
|                                                           | Бельгия                                | 0,7526         | Приходить         | 0,9733         |
| «национал»<br>+<br>«социализм»                            | Национализм                            | 0,8998         | Поприветствовать  | 0,9998         |
|                                                           | Социала                                | 0,7874         | Собственный       | 0,9974         |
|                                                           | Нацизм                                 | 0,7846         | Приводить         | 0,9957         |
|                                                           | Националист                            | 0,7745         | Незначительный    | 0,9939         |
|                                                           | Национализация                         | 0,6721         | Присутствовать    | 0,9912         |
|                                                           | Социалист                              | 0,6498         | Составлять        | 0,9909         |
|                                                           | Национальность                         | 0,6277         | Соответствовать   | 0,9864         |
|                                                           | Национальный                           | 0,6147         | Образовать        | 0,9776         |
|                                                           | Эмоционально                           | 0,5090         | Существовать      | 0,9753         |
|                                                           | интернационал                          | 0,4944         | Понимать          | 0,9731         |
| «Германия»<br>+<br>«гитлер»<br>+<br>«война»<br>-<br>«мир» | Кибервойна                             | 0,6756         | Получить          | 0,9995         |
|                                                           | Философия                              | 0,6493         | Получать          | 0,9978         |
|                                                           | Пьер                                   | 0,6152         | Народный          | 0,9977         |
|                                                           | Филармония                             | 0,6120         | Оказать           | 0,9976         |
|                                                           | Лазер                                  | 0,6085         | Совершать         | 0,9956         |
|                                                           | Кибер                                  | 0,6082         | Подобный          | 0,9944         |
|                                                           | Фишер                                  | 0,6072         | Предъявлять       | 0,9832         |
|                                                           | Англия                                 | 0,6049         | Оказаться         | 0,9798         |
|                                                           | Канцлер                                | 0,6021         | Солдатский        | 0,9745         |
|                                                           | Карман                                 | 0,5978         | Указать           | 0,9731         |

Анализ табл. 4 показывает, что модель, основанная на FastText формирует, как правило, не семантически близкие слова, а паронимы - сходные по звучанию и морфемному составу, но различающиеся лексическим значением. Это может быть связано с тем, что в модель в качестве обучающей выборки подаются n-граммы, а не слова целиком, в связи с чем качественное решение поставленной задачи не достигается. Поэтому в последующих экспериментах представлены результаты только модели Word2vec, в целом удовлетворяющей условиям формирования необходимых слов.

Из результатов анализа, приведенных в табл. 4, можно заметить, что по слову

Германия в нейтральном корпусе близкими являются наименования стран, а для исследуемого текста данное слово ассоциируется с нацией, призывами и ответственностью.

Однако, как можно заметить, по одному только слову «Германия» нельзя делать вывода о деструктивности в текстах, так как они могут содержать патриотичные или позитивные настроения, восхваляющие страну и не несущих негативную окраску.

Рассмотрим результаты, в которых семантика близких слов отражается наиболее ярко. Если сложить в векторном представлении слова «Германия», «Гитлер» и «война», и при этом вычесть из такого

вектора «мир», то на выходе получаем слова с негативной окраской: холокост, фашизм и нацизм, геноцид и т. п. Исходя из такого вывода могут видаться адекватными, однако при повторении аналогичной операции на исследуемом тексте находятся слова, наоборот, позитивно окрашенные, призывающие к благим действиям: героизм, благо, сражаться, соответствовать и т.д., что явно указывает на деструктивную семантику.

По результатам моделирования можно сделать вывод, что исследуемый текстовый массив данных несет в себе деструктивную составляющую, в целом направленную на рекультивацию национал-социалистического строя гитлеровской Германии.

Для анализа деструктивности по классу «Радикальный ислам» взята публикация, размещенная на одном из публичных форумов, предположительно содержащая деструктивный контент (текст находится в

открытом доступе с 2014 года). Результаты анализа по данному классу приведены в табл. 5.

Анализ сформированных слов, представленных в табл. 5, позволяет однозначно сделать вывод о деструктивности исследуемого текста. Семантически близкие слова к векторным выражениям «джихад»+«Россия» и «террор»+«народ» не могут иметь никакой окраски, кроме как деструктивной, что явно показывает эталонный корпус. В исследуемом корпусе для таких векторных выражений близкие слова призывают, указывают, каким образом совершать преступления террористической направленности, а также провоцируют к их совершению. Слово «кафир» вообще настолько специфическое для деструктивных текстов, что его попросту нет в эталонном словаре.

Таблица 5

Результаты анализа деструктивности в классе 2 на основе Word2vec

| Ключевые слова и выражения | Семантические близкие слова в Word2vec |                |                   |                |
|----------------------------|----------------------------------------|----------------|-------------------|----------------|
|                            | Эталонный корпус                       |                | Исследуемый текст |                |
|                            | Слова                                  | $\cos(\theta)$ | Слова             | $\cos(\theta)$ |
| Кафир                      | Отсутствует в словаре                  |                | Выступать         | 0,9089         |
|                            |                                        |                | Безбожие          | 0,8876         |
|                            |                                        |                | <b>Нападение</b>  | 0,8863         |
|                            |                                        |                | <b>Убийство</b>   | 0,8812         |
|                            |                                        |                | Возражение        | 0,8810         |
|                            |                                        |                | Безбожник         | 0,8741         |
|                            |                                        |                | <b>Воевать</b>    | 0,8729         |
|                            |                                        |                | Нападать          | 0,8640         |
|                            |                                        |                | Агрессия          | 0,8559         |
| «джихад»<br>+<br>«Россия»  |                                        |                | <b>Враг</b>       | 0,8462         |
|                            | Плацдарм                               | 0,7109         | Муджахид          | 0,9996         |
|                            | Кашмирский                             | 0,7053         | <b>Должный</b>    | 0,9967         |
|                            | Кабульский                             | 0,7014         | <b>Борьба</b>     | 0,9959         |
|                            | Антинародный                           | 0,7008         | Действие          | 0,9468         |
|                            | Талибан                                | 0,6922         | Место             | 0,9345         |
|                            | Фундаменталистский                     | 0,6876         | Человек           | 0,9187         |
|                            | Ичкерийский                            | 0,6868         | <b>Поджог</b>     | 0,9091         |
|                            | Хезболл                                | 0,6855         | <b>Метод</b>      | 0,8916         |
|                            | Мятежный                               | 0,6847         | Интернет          | 0,8812         |
|                            | Неофашистский                          | 0,6772         | Использовать      | 0,8723         |

Продолжение табл. 5

| Ключевые слова и выражения | Семантические близкие слова в Word2vec |                |                   |                |
|----------------------------|----------------------------------------|----------------|-------------------|----------------|
|                            | Эталонный корпус                       |                | Исследуемый текст |                |
|                            | Слова                                  | $\cos(\theta)$ | Слова             | $\cos(\theta)$ |
| «террор»<br>+<br>«народ»   | Экстремизм                             | 0,7686         | Должный           | 0,9997         |
|                            | Сепаратизм                             | 0,7630         | Муджахид          | 0,9984         |
|                            | Антисемитизм                           | 0,7333         | Действие          | 0,9861         |
|                            | Фашизм                                 | 0,7166         | <b>Борьба</b>     | 0,9844         |
|                            | Международный                          | 0,7025         | Акция             | 0,9798         |
|                            | Искоренение                            | 0,7046         | Режим             | 0,9711         |
|                            | Разжигание                             | 0,6782         | <b>Взрывчатка</b> | 0,9709         |
|                            | Беззаконие                             | 0,6726         | <b>Оружие</b>     | 0,9659         |
|                            | Антинародный                           | 0,6715         | <b>Русский</b>    | 0,9681         |
|                            | Предательство                          | 0,6673         | Джихад            | 0,9335         |

Для исследования 3 класса антисемитскими взглядами на одном из деструктивности «Антисемитизм» выбрана популярных социальных медиа. Результаты веб-страница, содержащая анализа указанного текста приведены в предположительно контент с табл. 6.

Таблица 6

Результаты анализа деструктивности в классе 3 на основе Word2vec

| Ключевые слова и выражения | Семантические близкие слова в Word2vec |                |                      |                |
|----------------------------|----------------------------------------|----------------|----------------------|----------------|
|                            | Эталонный корпус                       |                | Исследуемый текст    |                |
|                            | Слова                                  | $\cos(\theta)$ | Слова                | $\cos(\theta)$ |
| Еврей                      | Христианин                             | 0,7708         | Убивать              | 0,9812         |
|                            | Католик                                | 0,7707         | Каждый               | 0,9726         |
|                            | Мусульманин                            | 0,7319         | <b>Убить</b>         | 0,9773         |
|                            | Верующий                               | 0,7030         | <b>Обязать</b>       | 0,9691         |
|                            | Последователь                          | 0,7016         | <b>Замучить</b>      | 0,9058         |
|                            | Концентрационн<br>ый                   | 0,6952         | Делать               | 0,8955         |
|                            | Узник                                  | 0,6903         | Талмуд               | 0,8873         |
|                            | Иудаизм                                | 0,6877         | Обряд                | 0,8897         |
|                            | Почитать                               | 0,6862         | Случай               | 0,8719         |
|                            | Концлагерь                             | 0,6859         | Опреснок             | 0,7946         |
| Иудей                      | Ханука                                 | 0,7851         | <b>Жидомасонский</b> | 0,9982         |
|                            | Буддист                                | 0,7550         | <b>Захват</b>        | 0,9773         |
|                            | Жертвоприноше<br>ние                   | 0,7213         | Конгресс             | 0,9591         |
|                            | Населять                               | 0,7001         | Жидовский            | 0,9156         |
|                            | Чтить                                  | 0,6843         | Сионист              | 0,9088         |
|                            | Поклонение                             | 0,6852         | Тайный               | 0,8937         |
|                            | Празднество                            | 0,6850         | Соппротивление       | 0,8894         |
|                            | Народность                             | 0,6799         | <b>Разрушение</b>    | 0,8726         |
|                            | Господний                              | 0,6792         | <b>Выступать</b>     | 0,8551         |
|                            | Писание                                | 0,6776         | Фашизм               | 0,8598         |

Как можно видеть, ключевые слова в основном ассоциируются с религиозностью и верой, в то время как семантически близкие слова исследуемого текста содержат оскорбительные и призывающие к расправам синонимы. По выявленным семантически близким словам исследуемого текста и эталонными значениями новостного корпуса следует однозначный вывод о деструктивности текста и его ксенофобской направленности.

### Выводы

В рамках проведенного исследования разработана методика определения деструктивности больших текстовых данных в социальных медиа. Экспериментально показано, что в качестве базовой модели для формирования векторного представления слов целесообразно использовать модель Word2vec, наиболее точно оценивающей семантическую составляющую формируемых слов по сравнению с моделью FastText.

Эффективность предложенного подхода показана на текстовых массивах большого объема, которые на момент исследования не были выявлены автоматизированными методами, находясь в открытом доступе в различных социальных медиа. Разработанная методика может использоваться для выявления, по крайней мере, трех классов деструктивности: реабилитация нацизма, радикальный ислам, антисемитизм.

Практическое использование разработанного метода позволяет, вместо анализа больших по объему публикаций и текстов, оценить первые 10 слов, семантически близких к ключевым словам и выражениям, для определения деструктивности текста. Данное решение позволяет значительно ускорить определение деструктивного контента и упростить работу экспертов.

Данное решение необходимо применять в качестве дополнения комбинированных методов выявления деструктивного контента в социальных медиа. Возникающее при этом улучшение аналитического инструментария позволит снизить нагрузку на экспертов и ошибки второго рода автоматизированных методов. Такой инновационный

инструментарий даст возможность усовершенствовать работу автоматизированных систем по выявлению деструктивного контента применительно к задачам государственных органов, общественных организаций, а также владельцев ресурсов социальных медиа.

Перспективы же расширения обоснованной и реализованной методики для анализа и оценки других классов деструктивности видятся в автоматизации исследования тональности семантики больших текстовых массивов и ускорения их автоматизированной классификации [25].

### Список литературы

1. Доктрина информационной безопасности Российской Федерации. URL: <http://kremlin.ru/acts/bank/41460> (дата обращения 15.05.2021).
2. Федеральный закон № 149-ФЗ от 37.07.2006 «Об информации, информационных технологиях и о защите информации». URL: <http://www.kremlin.ru/acts/bank/24157> (дата обращения 15.05.2021).
3. Общественная организация «Лига безопасного интернета». URL: <http://www.ligainternet.ru/> (дата обращения: 15.05.2021).
4. Федеральный закон № 530-ФЗ от 30.12.2020 «О внесении изменений в Федеральный закон «Об информации, информационных технологиях и о защите информации». URL: <http://publication.pravo.gov.ru/Document/View/0001202012300062> (дата обращения: 15.05.2021).
5. Мониторинг сети Интернет. URL: <https://ncpti.su/report/monitoring-seti/monitoring-seti-internet.php> (дата обращения: 15.05.2021).
6. Минаев В.А., Симонов А.В. Выявление контента террористического и экстремистского характера в информационных системах с помощью DLP технологий. // Информационная безопасность: вчера, сегодня, завтра. Сб. статей по материалам III Междунар. науч.-практ. Конф., Москва, 23 апреля 2020 года. М.: Российский государственный гуманитарный университет, 2020. С. 99-105.

7. Прикладная и компьютерная лингвистика / Под ред. И.С. Николаева, О.В. Митрениной, Т.М. Ландо. Изд. 2-е. М.: ЛЕНАНД, 2017. 320 с.
8. Ikonomakis M., Kotsiantis S., Tampakas V. Text Classification Using Machine Learning Techniques // WSEAS Transactions on Computers. 2005. Т. 4. №. 8. Pp. 966-974.
9. Yao L., Mao C., Luo Y. Graph Convolutional Networks for Text Classification // Proceedings of the AAAI Conference on Artificial Intelligence. 2019. Т. 33. No 1. Pp. 7370-7377.
10. Zhang X., Zhao J., Lecun Y. Character-level Convolutional Networks for Text Classification // Advances in Neural Information Processing Systems. 2015. Т. 2015. Pp. 649-657.
11. Минаев В.А., Реброва А.Д., Симонов А.В. Выявление деструктивного контента в социальных медиа на основе моделей машинного обучения // Информация и безопасность. 2021. Т. 24. № 1. С. 7-20.
12. Социальные сети в России: цифры и тренды, осень 2020. URL: <https://br-analytics.ru/blog/social-media-russia-2020/> (дата обращения: 15.05.2021).
13. Технологии искусственного интеллекта повышают оперативность и эффективность выявления незаконной информации в Интернете. URL: <https://rkn.gov.ru/news/rsoc/news73266.htm> (дата обращения: 15.05.2021).
14. Векторная модель. URL: [https://ru.wikipedia.org/wiki/Векторная\\_модель#cite\\_note-1](https://ru.wikipedia.org/wiki/Векторная_модель#cite_note-1) (дата обращения: 15.05.2021).
15. Devlin J. Bert: Pre-training of Deep Bidirectional Transformers for Language Understanding / Devlin J. [et al.] // arXiv Preprint arXiv:1810.04805. 2018.
16. Bojanowski P. Enriching Word Vectors with Subword Information / Bojanowski P. [et al.] // Transactions of the Association for Computational Linguistics. 2017. Т.5. Pp. 135-146.
17. Mikolov T. Efficient Estimation of Word Representations in Vector Space / Mikolov T. [et al.] // arXiv preprint arXiv:1301.3781. 2013.
18. Аверченков, В. И. Анализ применения моделей векторного представления текстовой информации для русскоязычных текстов / В. И. Аверченков, Д. В. Будыльский, А. Г. Подвесовский // Вестник компьютерных и информационных технологий. 2016. № 3(141). С. 31-37.
19. Семенова А. В., Курейчик В. М. Ансамбль классификаторов для автоматического пополнения онтологий // Известия ЮФУ. Технические науки. 2018. № 2 (196). С. 163-173.
20. Bansal B., Srivastava S. Sentiment Classification of Online Consumer Reviews Using Word Vector Representations // Procedia Computer Science. 2018. Т. 132. Pp. 1147-1153.
21. Acosta J. Sentiment Analysis of Twitter Messages Using Word2vec. / Acosta J. [et al.] // Proceedings of Student-faculty Research Day, CSIS, Pace University. 2017. Т. 7. Pp. 1-7.
22. Pennington J. Global Vectors for Word Representation / J. Pennington, R. Socher, C. Manning, D. Glove // Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014. Pp. 1532-1543.
23. Corpus of News Articles of Lenta.ru. URL: <https://github.com/yutkin/Lenta.Ru-News-Dataset> (дата обращения: 15.05.2021).
24. Korobov M. Morphological Analyzer and Generator for Russian and Ukrainian languages // International Conference on Analysis of Images, Social Networks and Texts. Springer, Cham, 2015. Pp. 320-332.
25. Минаев В. А. Простые числа: новый взгляд на закономерности формирования. М.: Логос Пресс, 2011. 80 с.

Московский университет МВД России им. В.Я. Кикотя  
V. Ya. Kikot Moscow University of the Russian Internal Affairs Ministry

Московский государственный технический университет  
Bauman Moscow State Technical University

Поступила в редакцию 20.05.2021



**Информация об авторах**

**Минаев Владимир Александрович** – д-р техн. наук, профессор кафедры специальных информационных технологий, Московский университет МВД РФ им. В.Я. Кикотя, e-mail: m1va@yandex.ru

**Симонов Александр Валерьевич** – аспирант кафедры защиты информации, Московский государственный технический университет им. Н. Э. Баумана, e-mail: san.siman@yandex.ru

**QUANTIFICATION OF LARGE TEXT  
ARRAYS DESTRUCTIVENESS IN SOCIAL MEDIA**

**V.A. Minaev, A.V. Simonov**

The aim of the study is to develop a method that allows us to identify the destructiveness of large text arrays in social media. The analysis of existing approaches to determining the destructive nature of text data is carried out, and their advantages and disadvantages are described. A method for determining the destructiveness of a text using vector representations of words is described. The formation of vector representations of words is considered and the possibility of their application in solving problems of identifying text content is evaluated. The application of the Word2vec and FastText algorithms is justified. Keywords and expressions of vector representations of words defining three classes of texts are proposed: rehabilitation of Nazism, radical Islam, and anti-Semitism. Models are implemented to identify the destructiveness of the content of large text arrays using neutral news text corpora and texts containing possible destructive content. The results of the analysis of text arrays are interpreted and Word2vec is justified as the most suitable model for the vector representation of words. The conclusion is made about the directions of using the obtained results in the analytical activities of state authorities, public organizations and social media to identify illegal content.

Keywords: information security, social media, destructive content, monitoring, identification.

Submitted 20.05.2021

**Information about the authors**

**Vladimir A. Minaev** – Dr. Sc. (Technical), Professor of the Department of Special Information Technologies, Moscow University of the Ministry of Internal Affairs of Russia, e-mail: m1va@yandex.ru

**Alexander V. Simonov** – Post-graduate Student of the Department of Information Security, Bauman Moscow State Technical University, Moscow, Russian Federation, e-mail: san.siman@yandex.ru