

ПРИМЕНЕНИЕ ГЛУБИННЫХ НЕЙРОННЫХ СЕТЕЙ ДЛЯ ВЫЯВЛЕНИЯ ДЕСТРУКТИВНОГО КОНТЕНТА В СОЦИАЛЬНЫХ МЕДИА

В.А. Минаев, Е.С. Поликарпов, А.В. Симонов

Цель исследования состоит в разработке методики и поиске эффективного алгоритма выявления деструктивного контента в кратких публикациях и комментариях в социальных медиа. Проведен обзор существующих решений для выявления деструктивного контента, описаны их преимущества и недостатки в контексте решаемой задачи. Сформированы составные экспериментальные корпуса текстов по темам: реабилитация нацизма, антисемитизм, радикальный ислам. Проведена нормализация корпусов, используя методы стемминга и лемматизации. Осуществлена операция векторизации нормализованных корпусов методами мешка слов (BoW), TF-IDF и слоем искусственных нейронных сетей (ИНС). Построены архитектуры глубоких ИНС: сверточной нейронной сети (CNN), рекуррентной нейронной сети с долгой краткосрочной памятью (LSTM), рекуррентной нейронной сети с механизмом вентилей (GRU). Проведены эксперименты по классификации сформированных корпусов текстов с использованием созданных ИНС и традиционных методов машинного обучения. Произведена интерпретация полученных результатов экспериментов и обосновано применение глубоких ИНС при решении поставленной задачи. Сделан вывод о целесообразности использования полученных результатов структурами, занятыми выявлением и удалением деструктивного контента.

Ключевые слова: информационная безопасность, социальные медиа, деструктивный контент, нейронные сети, глубокое обучение, классификация текста.

Введение

Сегодня одним из мощнейших инструментов межличностных коммуникаций и анализа общественного поведения стали социальные медиа (СМ).

К СМ относятся социальные сети, тематические форумы, средства для обмена сообщениями (мессенджеры), живые журналы, интернет-блоги и другие возможности.

Однако СМ используются не только для обмена обычными сообщениями, публикаций различного рода бытовой информации и общения, но и для злобных целей. Одной из них является распространение деструктивного контента. С его помощью преступными группировками производится вербовка новых членов в свои структуры (например, террористические организации, радикальные националистические сообщества, А.У.Е.) и распространение негативной идеологии в социуме.

Деструктивный контент, запрещенный к распространению в Российской Федерации, включает в себя три наиболее распространенных класса:

- возбуждение ненависти или вражды по

отношению к определенным слоям общества, а равно унижение человеческого достоинства. Примерами такого контента являются различные шовинистические, антисемитские, русофобские материалы и книги;

- отрицание фактов, установленных приговором Международного военного трибунала по результатам Великой Отечественной Войны (ВОВ), оправдание или одобрение действий главных военных преступников ВОВ. Примерами такого контента служат агитационные плакаты Третьего Рейха, книги и высказывания политической элиты нацистской Германии, их пропагандистские речи и публикации;

- публичные призывы к осуществлению экстремистской деятельности и свержению конституционного строя Российской Федерации. К ним можно причислить массовые призывы к осуществлению противоправных действий, призывы к нарушению территориальной целостности, массовым беспорядкам, терактам.

Государство уделяет особое внимание борьбе с деструктивными воздействиями на население, в связи с чем в Доктрине

информационной безопасности Российской Федерации, утвержденной Указом Президента Российской Федерации № 646 от 05.12.2016, такие воздействия названы в числе основных информационных угроз.

Распространять деструктивный контент возможно с использованием различных материалов (видео, аудио, фотоизображения и т.п.), но наиболее популярным видом остается текст. Текстовый формат привлекает:

- доступностью – для чтения текста не требуются какие-то особые вычислительные ресурсы и техника, его удобно читать в любом месте и на любых устройствах;
- легкостью распространения – небольшой размер позволяет рассылать и распространять его достаточно дешево;
- простотой создания – не требуется производить сложные операции и действия, таких как монтаж видеороликов, записи аудио или создание фотоизображений.

Этими возможностями активно пользуются радикально настроенные элементы для создания и распространения деструктивного контента.

Необходимо при этом отметить, что распространять объемные деструктивные текстовые публикации и статьи в эпоху клипового мышления, когда у большинства людей внимание на тексте фокусируется не более, чем на полминуты, малоэффективно.

Более удобными для распространения являются краткие публикации, не превышающие трех-четырёх предложений. К таким публикациям относятся короткие посты, на примере социальной сети «Twitter», и краткие комментарии к публикациям.

В связи с этим возникает задача поиска эффективных алгоритмов и методов, позволяющих выявлять деструктивный контент в кратких текстовых публикациях и комментариях.

Основные методы и этапы анализа текста

Анализ текста на наличие деструктивной составляющей может осуществляться различными способами. Рассмотрим три основных из них.

Традиционным способом является обычная экспертная оценка. Специально

обученные сотрудники государственных органов, ответственных за выявление деструктивного контента (МВД, ФСБ, Генеральная Прокуратура, Роскомнадзор) [1], или штатные работники социальных медиа, для исполнения не так давно введенных дополнений в законодательные акты [2], экспертно “вручную” оценивают публикации в СМ как самостоятельно, так и при наличии жалоб. Сегодня имеются различные методики для выявления и идентификации запрещенной информации [3].

В контексте поставленной задачи плюсами “ручного” способа является достаточно точная оценка семантики текстов, а также таких косвенных показателей как профиль пользователя, место публикации, формат общения и др. К существенным минусам, в свою очередь, относятся: возрастающая зависимость от количества привлекаемых специалистов, их квалификации и ошибок, которые трудно контролировать.

С учетом количества ежемесячного создаваемого текстового контента (более миллиарда новых публикаций и комментариев по данным Brand Analytics [4]) “ручной” способ анализа контента видится крайне неэффективным. Использовать его целесообразно для подтверждения противоправности текста в пограничных случаях [5], когда необходимо улучшить работу специализированных систем мониторинга.

Автоматизированный способ статистического анализа текста позволяет производить поиск в СМ как по уникальным, так и по часто используемым словам в текстах, находящихся в Федеральном списке экстремистских материалов (ФСЭМ). Статистические модели позволяют находить похожие по смыслу и содержанию текстовые документы согласно поисковым запросам [6].

В то же время, применение статистического способа для выявления деструктивного контента в коротких публикациях малоэффективно по двум причинам:

1. Не учитывается семантика искомых слов, что приводит к росту ложных срабатываний, ошибкам первого рода. Например, в случае поиска публикаций,

реабилитирующих нацизм, результатом станут легитимные тексты, использующие набор слов исторического содержания о ВОВ.

2. В публикациях небольшого объема («твиты» и комментарии) могут не содержаться часто используемые слова, что приведет к ошибкам второго рода – пропуску деструктивных публикаций.

Третьим способом является *применение методов машинного обучения*. С их помощью решается широкий спектр задач в различных областях: выявление аномалий и противодействие банковскому мошенничеству [7], медицинских исследованиях [8], распознавании образов в различных сферах [9] и многих других.

Основными задачами в области обработки естественного языка с применением методов машинного обучения являются кластерный анализ и классификация.

Кластерный анализ – это задача разбиения заданного множества объектов (ситуаций) на непересекающиеся подмножества, называемые кластерами, так, чтобы каждый однородный кластер состоял из похожих объектов, а объекты разных кластеров существенно бы отличались. Задача кластеризации относится к классу задач обучения без учителя [10].

При обработке естественного языка кластерный анализ применяется для разделения на группы сходных по смыслу текстов научной направленности [11], группировки новостных статей по рубрикам [12], комментариев по эмоциональной окраске [13].

Одной из задач кластерного анализа является тематическое моделирование как одно из современных приложений машинного обучения к анализу текстов, активно развивающееся с конца 90-х годов.

Тематическая модель коллекции текстовых документов определяет, к каким темам относится каждый документ, и какие слова (термины) образуют каждую тему [14]. Основными используемыми алгоритмами являются вероятностный латентно-семантический анализ и латентное размещение Дирихле.

Тематическое моделирование находит своё применение в задачах выявления

тематик постов в популярных онлайн-сообществах СМ [15] и присвоения тем постам в социальной сети «Twitter» [16].

Классификация – это задача отнесения объектов к заданным классам (группам) [17]. Наиболее распространенными задачами текстовой классификации являются:

- выявление токсичных комментариев в Интернет [18, 19].

- типологизация спама и постов «Twitter» [20-22];

- оценка эмоциональной окраски публикаций в СМ [23, 24];

Для отбора эффективных алгоритмов классификации составлена табл. 1, в которой указана частота их встречаемости f в указанных работах.

Таблица 1

Частота встречаемости алгоритмов классификации в работах [18-24]

Алгоритм	f
Метод опорных векторов (SVM)	5
Сверточная нейронная сеть (CNN)	3
Байесовский классификатор (NB)	3
Рекуррентная нейронная сеть с долгой краткосрочной памятью (LSTM)	3
Рекуррентная нейронная сеть с механизмом вентилей (GRU)	3
Логистическая регрессия (LR)	3
Многослойный персептрон (MLP)	2
Деревья решений (DT)	2
Алгоритм К-ближайших соседей (KNN)	2
Случайный лес (RF)	1
XG бустинг (XGB)	1
Простая рекуррентная нейронная сеть (RNN)	1

Алгоритмы в приведенных источниках условно можно подразделить на два типа:

- традиционные методы обучения с учителем (метод опорных векторов, логистическая регрессия, Байесовский классификатор и др.);

- глубинные нейронные сети (CNN, LSTM, GRU, RNN), имеющие в своей структуре несколько внутренних слоев.

Стоит отметить, что в задачах обработки коротких текстовых публикаций (в т.ч. – комментариев) использование сложно структурируемых нейронных сетей и

увеличение внутренних слоев, как правило, не повышают результативность построенных классификаторов [20].

Таким образом, первый и второй способ малоэффективны при поиске деструктивного текстового контента в силу высокой вероятности ошибок первого и второго рода.

Применение методов кластерного анализа, применяемых в третьем способе, не подходит в связи с неопределенными результатами работы алгоритмов: сложно предугадать, к какому кластеру алгоритм отнесет тексты, используемые в выборке.

Методы тематического моделирования также не всегда подходят в связи с тем, что не дают в сложных ситуациях конкретного ответа о деструктивной составляющей текста, т.к. могут присваивать твиту, комментарию несколько тем (групп).

Представляется, что задачу выявления деструктивного контента в кратких текстовых публикациях и комментариях целесообразно решать с использованием нейронных сетей с небольшим количеством скрытых слоев [18-24].

Построение классификатора деструктивного контента в СМ связано со следующими этапами:

- Определение деструктивных тем.
- Формирование экспериментальных корпусов текстов и их предварительная обработка.
- Векторизация корпусов текстов.
- Применение алгоритмов машинного обучения.

Рассмотрим указанные этапы более детально.

Первый этап. В целях формирования деструктивных тем выбраны три:

- антисемитизм;
- реабилитация нацизма;
- радикальный ислам.

Материалы по указанным темам запрещены согласно российским законам для распространения в СМ как несущие наиболее агрессивную контекстную составляющую.

Второй этап. По каждой избранной деструктивной теме сформирован свой текстовый корпус. В качестве текстов использовались публикации, максимально схожие с материалами, находящимися в реестре ФСЭМ, но ещё незаблокированные и

доступные в СМ.

Для унификации предлагаемого в статье метода и уменьшения ошибок второго рода при использовании полученного классификатора на реальных СМ сформированы вспомогательные корпуса текстов (ВКТ) путем использования публикаций, по статистическому набору слов близких к деструктивному контенту, но имеющих иную эмоциональную окраску и семантическую нагрузку. В качестве таких ВКТ сформированы:

- Корпус материалов на еврейском языке, в который включены книги, описывающие историю еврейского народа, его быт, обычаи и мировоззрение. Материалы взяты из [25].

- Исторический корпус составлен из двенадцати томов серии «История второй мировой войны 1939 – 1945» [26].

- Исламский корпус сформирован на основе книг и публикаций, одобренных муфтиятами России.

Для уменьшения ошибок второго рода и повышения качества работы классификатора также созданы нейтральные корпуса (НК), которые отражают циркулирующий в СМ контент, подразделяющийся на 2 типа – новостной и созданный пользователями в процессе общения.

В связи с описанными особенностями нейтрального контента, соответствующий ему корпус создан на основе двух массивов данных: русскоязычных публикаций в «Twitter» [27], который часто используется для оценки эмоциональной окраски постов, и новостных публикаций интернет-издания «Lenta.ru».

Поскольку в исследовании решалась задача выявления деструктивного контента в кратких сообщениях и комментариях, все текстовые массивы корпусов были разбиты на предложения, средняя длина которых соответствовала длине среднего комментария или поста в «Twitter». Количество предложений вспомогательных корпусов текстов выровнено с количеством предложений в деструктивных корпусах.

Три экспериментальных корпуса созданы путем смешивания четырех корпусов: «деструктивный» + «вспомогательный» + «новостной» + «корпус твитов».

Объемы экспериментальных корпусов приведены в табл. 2

Таблица 2

Объем экспериментальных корпусов

Название корпуса	Количество предложений
Антисемитский (АС)	267860
Нацистский (НЦ)	284284
Террористический (ТР)	310064

После формирования корпусов осуществлена предварительная обработка текстов.

В целях улучшения результатов работы классификаторов и снижения шумовых эффектов проведены удаление знаков препинания, приведение букв к нижнему регистру и очистка корпуса от стоп-слов, часто встречающихся, но не несущих смысловой нагрузки.

Для нормализации текстов проведены операции стемминга и лемматизации.

Стемминг (ST) – это нахождение основы для исходного слова. Основа слова не обязательно совпадает с его морфологическим корнем [28].

Лемматизация (LM) – это метод морфологического анализа, который сводится к приведению словоформы к ее первоначальной словарной форме (лемме). Лемматизация применяется в поисковых алгоритмах в процессе схематизации веб-документов при их индексировании. В результате лемматизации возвращается основная или словарная форма слова [29].

После проведения указанных процедур образованы шесть экспериментальных корпусов, по три – на каждый метод нормализации.

С каждым экспериментальным корпусом проводится процесс токенизации – разделения текста на более мелкие части (предложения, слова).

Третий этап – векторизация полученного текста как процесс преобразования текстового массива в числовой вектор.

Каждый экспериментальный корпус подвергнут трем методам векторизации:

- Мешок слов (BoW) – представление текста в виде вектора размером в словарь

корпуса, в котором под каждым индексом слова выставляется количество его вхождений в исследуемый элемент выборки.

- TF-IDF – статистическая мера, состоящая из произведения отношения числа вхождения некоторого слова к общему числу слов документа $tf(t, d)$ и инверсии частоты $idf(t, D)$, с которой данное слово встречается в документах коллекции.

- Doc2Vec – это расширение алгоритма векторного представления слов Word2Vec для сохранения семантической связи между различными документами. Подобно Word2Vec, каждое слово представлено d -мерным вектором ($d \ll |V|$), где V – размер словаря в корпусе [30].

Для алгоритмов искусственных нейронных сетей использован внутренний слой векторного представления текста (Embedding layer, EL). На вход EL поступает вектор индексов слов, соответствующий словам в публикации. Данный вектор проходит через нейронную сеть с изначально случайно выставленными весами, где на выходе формируется вектор фиксированной длины. Через определенное количество итераций для каждой публикации формируется своё векторное представление.

Четвертый этап. На основе анализа предметной области авторами выбраны шесть наиболее известных алгоритмов классификации:

1. Логистическая регрессия (LR) – это метод построения линейного классификатора, позволяющий оценивать апостериорные вероятности принадлежности объектов классам [31]. Является одним из наиболее быстрых и простых в реализации, показывая при решении задач обработки текстовых данных хорошие результаты [32].

2. Метод опорных векторов (SVM) – один из наиболее распространенных методов обучения, применяемых для решения задач классификации. Основная идея заключается в построении гиперплоскости, разделяющей исследуемые объекты оптимальным способом. Алгоритм работает в предположении – чем больше расстояние между разделяющей гиперплоскостью и объектами разделяемых классов, тем меньше средняя ошибка классификатора [33].

3. Наивный байесовский классификатор,

основанный на теореме Байеса и строгих предположениях о независимости классов.

4. Сверточная нейронная сеть (CNN) – это однонаправленная глубинная искусственная нейронная сеть. Название «сверточная» получила из-за операции свертки входной информационной матрицы с максимальной длиной предложения не более 40. Далее формируется векторное представление предложения размерностью 100, поступающее на сверточный слой CNN, выходная размерность которого равна 250. Далее вектор поступает на два последовательно стоящие сети прямого распространения, с выходным вектором, равным количеству исследуемых классов – 4.

5. Рекуррентная нейронная сеть с долгой краткосрочной памятью (LSTM) имеет в своей структуре обратную связь и позволяет обрабатывать зависимые последовательности данных, что является плюсом для классификации текстов. Аналогично предыдущей сети на вход подается матрица предложений с максимальной длиной 40. Далее идет слой формирования векторного представления текста (предложения) с выходной размерностью 100. Следующим слоем является слой LSTM, выдающий вектор, размерностью 16. Последним в используемой архитектуре идет слой ИНС прямого распространения, сужающей вектор с 16 до 4 по количеству классов.

6. Рекуррентная нейронная сеть с механизмом вентилей (GRU) напоминает LSTM, но в некоторых задачах показывает аналогичные или более высокие результаты. В определенном смысле GRU можно рассматривать как упрощенную версию LSTM.

Точность всех названных алгоритмов оценивалась на экспериментальных корпусах по формуле:

$$Ac = \frac{1}{1 + \frac{FP + FN}{TP + TN}} \cdot 100\%$$

где

TP – количество верно определенных публикаций рассматриваемого класса;

TN – количество публикаций, которые верно не отнесены к рассматриваемому классу;

FP – количество неверно определенных публикаций рассматриваемого класса;

FN – количество публикаций, неверно не отнесённых к рассматриваемому классу.

Результаты экспериментов

Всего в рамках решения задачи по определению точности алгоритмов классификации произведено 72 эксперимента, учитывающего различные сочетания методов нормализации и векторизации. Результаты представлены по исследуемым темам в табл. 3-5.

Таблица 3

Результаты экспериментов по классификации корпуса текстов с нацистской тематикой

№	Нормализация + векторизация	Алгоритм классификации	Точность, %	№	Нормализация + векторизация	Алгоритм классификации	Точность, %
1	ST+EL	GRU	92,93	13	ST+BoW	SVM	91,36
2	LM+EL	GRU	92,80	14	LM+BoW	SVM	91,31
3	LM+EL	LSTM	92,74	15	ST+BoW	NB	90,66
4	ST+EL	LSTM	92,47	16	ST+TF-IDF	NB	90,66
5	LM+EL	CNN	92,46	17	LM+BoW	NB	90,56
6	ST+EL	CNN	92,34	18	LM+TF-IDF	NB	90,56
7	LM+TF-IDF	SVM	92,23	19	LM+Doc2Vec	LR	87,69
8	ST+TF-IDF	SVM	92,20	20	LM+Doc2Vec	SVM	87,56
9	ST+BoW	LR	91,73	21	ST+Doc2Vec	LR	87,52
10	ST+TF-IDF	LR	91,71	22	ST+Doc2Vec	SVM	87,39
11	LM+BoW	LR	91,70	23	LM+Doc2Vec	NB	82,26
12	LM+TF-IDF	LR	91,51	24	ST+Doc2Vec	NB	82,15

Из анализа табл. 3 следует вывод, что наиболее точной классификацией для корпуса деструктивных текстов по тематике нацизма обладают глубинные нейронные сети. При этом наилучшей является нейронная сеть GRU вне зависимости от методов нормализации текстов.

Наихудшие результаты показали связки методов машинного обучения с векторизацией по типу Doc2Vec.

В целом все методы, применяемые без векторизации Doc2Vec, показали точность определения класса публикаций выше 90%.

Из анализа соответствующей матрицы ошибок классификатора на основе алгоритма GRU со стемминговой нормализацией и векторизацией с использованием слоя EL следует, что основные ошибочные выводы при определении деструктивного контента с тематикой о реабилитации нацизма делаются на историческом корпусе текстов. Доля ложноположительных срабатываний здесь – 6,3%.

Второе место по ошибкам относится к корпусу твит публикаций – 3,8%, а доля ложноположительных срабатываний по

корпусу новостных публикаций – 1,9%. Лучше всего алгоритм GRU в корпусе с идеями реабилитации нацизма определяет новостные публикации. Точность определения деструктивного контента по рассматриваемому корпусу – 88%.

Результаты экспериментов по классификации текстового корпуса антисемитской направленности приведены в табл. 4. Они по точности несколько ниже результатов классификации текстов нацистского характера, рассмотренного выше. Разница по лучшему эксперименту – 2,51%.

В данной серии экспериментов наилучший результат показал алгоритм LSTM, использующий нейронную сеть с лемматизацией. Затем следует алгоритм GRU. В пятерку лучших в этом блоке экспериментов попал метод опорных векторов с TF-IDF векторизацией. В блоке экспериментов по корпусу текстов антисемитской направленности результаты выше 90% точности показали только 7 классификаторов, 6 из которых – глубинные ИНС.

Таблица 4

Результаты экспериментов по классификации корпуса текстов с антисемитской тематикой

№	Нормализация + векторизация	Алгоритм классификации	Точность, %	№	Нормализация + векторизация	Алгоритм классификации	Точность, %
1	LM+EL	LSTM	90,42	13	LM+BoW	SVM	89,27
2	ST+EL	GRU	90,39	14	ST+BoW	SVM	88,98
3	LM+EL	GRU	90,38	15	LM+BoW	NB	88,89
4	LM+TF-IDF	SVM	90,35	16	LM+TF-IDF	NB	88,89
5	ST+EL	LSTM	90,31	17	ST+BoW	NB	88,80
6	ST+TF-IDF	SVM	90,20	18	ST+TF-IDF	NB	88,80
7	LM+EL	CNN	90,13	19	LM+Doc2Vec	LR	86,09
8	ST+EL	CNN	89,97	20	LM+Doc2Vec	SVM	86,00
9	LM+TF-IDF	LR	89,94	21	ST+Doc2Vec	SVM	85,52
10	LM+BoW	LR	89,91	22	ST+Doc2Vec	LR	85,49
11	ST+BoW	LR	89,58	23	LM+Doc2Vec	NB	81,74
12	ST+TF-IDF	LR	89,37	24	ST+Doc2Vec	NB	81,47

Анализ матрицы ошибок по наилучшему способу классификации во втором блоке экспериментов, а именно LSTM с лемматизацией, позволяет сделать вывод о более существенном влиянии дополнительного шумового корпуса на

точность выявления деструктивного контента – 7,6% ложноположительных срабатываний классификатора. При этом работа классификатора с учетом твит публикаций и новостной ленты практически не изменилась.

Нужно отметить, что доля

ложноположительных срабатываний на дополнительном шумовом корпусе по признаку «антисемитский» больше – 9,8%. В целом точность определения деструктивного контента равна 87%.

Последний блок экспериментов произведен по корпусу текстов террористической направленности. Результаты представлены в табл. 5.

Таблица 5

Результаты экспериментов классификации корпуса текстов с террористической тематикой

№	Нормализация + векторизация	Алгоритм классификации	Точность, %	№	Нормализация + векторизация	Алгоритм классификации	Точность, %
1	LM+EL	GRU	89,25	13	ST+TF-IDF	LR	87,61
2	LM+EL	CNN	89,24	14	ST+BoW	SVM	87,56
3	ST+EL	GRU	89,22	15	LM+BoW	NB	87,18
4	LM+EL	LSTM	89,03	16	LM+TF-IDF	NB	87,18
5	ST+EL	CNN	88,96	17	ST+BoW	NB	86,55
6	LM+TF-IDF	SVM	88,95	18	ST+TF-IDF	NB	86,55
7	ST+EL	LSTM	88,80	19	LM+Doc2Vec	LR	83,50
8	ST+TF-IDF	SVM	88,52	20	LM+Doc2Vec	SVM	83,46
9	LM+BoW	LR	88,49	21	ST+Doc2Vec	LR	82,90
10	LM+BoW	SVM	88,20	22	ST+Doc2Vec	SVM	82,80
11	LM+TF-IDF	LR	88,10	23	LM+Doc2Vec	NB	79,45
12	ST+BoW	LR	87,96	24	ST+Doc2Vec	NB	79,39

Результаты точности классификаторов в третьем блоке ниже по всем проведенным экспериментам. Наилучшим алгоритмом является алгоритм GRU с лемматизацией – точность определения 89,25%. Причем точность не превышала 90% ни в одном из экспериментов.

Как и во втором блоке экспериментов (исследование корпуса текстов антисемитской направленности) лучшие результаты показали алгоритмы, использующие глубинные нейронные сети в связке с методами, указанными в таблице 5.

Анализ матрицы ошибок классификатора с применением алгоритма GRU с лемматизацией показывает, что в третьем блоке экспериментов зафиксировано 17% ложноположительных срабатываний при классификации дополнительного шумового корпуса текстов с упоминанием исламской терминологии.

Отметим, что точность классификации твит корпуса и новостных публикаций в сравнении с ранее рассмотренными блоками улучшилась.

Высокая доля ложноположительных срабатываний при исследовании дополнительных шумовых корпусов текстов свидетельствует о необходимости их более

точной подборке.

Наилучшие результаты классификаций (под номерами 1 в табл. 3-5) представлены для сравнения на рис. 1.




Рис. 1. Сравнительная диаграмма точности наилучших алгоритмов классификации

Из представленной на рис. 1 диаграммы видно, что хуже всего в рамках проведенных экспериментов из деструктивного контента распознается террористический (78%), при этом точность основного содержания СМ остается высокой, на уровне 95%. Антисемитские и нацистские публикации распознаются примерно с одинаковой точностью (87-88%), при этом наблюдается

снижение точности твит-публикаций (в сравнении результатами исследования террористического корпуса).

Обсуждение и выводы

В рамках проведенного в статье исследования найдены наиболее точные алгоритмы и методы выявления деструктивного контента в кратких публикациях и комментариях по трем темам:

- реабилитация нацизма;
- антисемитизм;
- радикальный ислам.

По каждой из рассмотренных тем сформированы корпуса текстов, отражающие наполнение СМ по этим направлениям, и имитирующие «шумовое» наполнение – контент, содержащий похожие слова и синтаксис, но при этом не имеющий деструктивной семантической составляющей.

Проведена предварительная обработка и векторизация корпусов различными методами с целью оценки их влияния на результаты итоговой классификации.

Исследованы распространённые алгоритмы классификации, с применением которых проведены серии экспериментов по трем исследуемым темам распространения деструктивного контента: прославление нацизма, антисемитизм, террористические призывы. В рамках указанных тем выявлены наиболее точные алгоритмы классификации, сочетаемые с использованием различных методов нормализации и векторизации.

Показано, что наиболее эффективными алгоритмами является применение глубинных нейронных сетей. В частности, для выявления текстов по реабилитации нацизма лучшим является сочетание ИНС GRU и стемминга, для выявления антисемитизма – ИНС LSTM и лемматизация, для текстов, содержащих радикальные исламистские взгляды и призывы к терроризму – связка ИНС GRU и лемматизации.

Точность классификации деструктивных текстов зависит от следующего обстоятельства – чем синтаксически ближе шумовой (дополнительный) корпус к деструктивному, тем выше вероятность ошибок первого рода.

Даже с учетом ложноположительных срабатываний автоматизированные методы, использующие алгоритмы машинного обучения, показывают высокие результаты. Борьба с ложноположительными срабатываниями возможно методами, представленными в работе [5].

Рассмотренные методы выявления деструктивного контента целесообразно применять в аналитической деятельности соответствующих государственных органов, общественных организаций, сотрудников социальных медиа.

Дальнейшее развитие и перспективы исследований по рассматриваемой проблематике видятся в:

- разработке и поиске эффективных методов и алгоритмов, позволяющих оценивать деструктивность текстов любого объема;
- разработке моделей, позволяющих оценивать многоцелевой деструктивный контент.
- оценке эффективности алгоритмов, базирующихся на новых структурах искусственных нейронных сетей.

Список литературы

1. Федеральный закон № 149-ФЗ от 37.07.2006 «Об информации, информационных технологиях и защите информации». URL: <http://www.kremlin.ru/acts/bank/24157> (дата обращения 18.08.2021).
2. Федеральный закон № 530-ФЗ от 30.12.2020 «О внесении изменений в Федеральный закон «Об информации, информационных технологиях и защите информации». URL: <http://publication.pravo.gov.ru/Document/View/0001202012300062> (дата обращения: 18.08.2021).
3. Красинский В. В. Методика работы в социальных сетях по выявлению экстремистского и иного противоправного контента / В. В. Красинский // Современное право. – 2020. – № 2. – С. 65-68. – DOI 10.25799/NI.2020.83.61.008.
4. Социальные сети в России: цифры и тренды, осень 2020. URL: <https://branalytics.ru/blog/social-media-russia-2020/> (дата обращения: 18.08.2021).

5. Минаев, В. А. Количественная оценка деструктивности больших текстовых массивов в социальных медиа / В. А. Минаев, А. В. Симонов // *Информация и безопасность*. – 2021. – Т. 24. – № 2. – С. 267-280. – DOI 10.36622/VSTU.2021.24.2.011.
6. He B., Huang J. X., Zhou X. Modeling term proximity for probabilistic information retrieval models // *Information Sciences*. – 2011. – Т. 181. – №. 14. – С. 3017-3031.
7. Фомичева, Т. Л. Применение методов интеллектуального анализа данных и machine learning в борьбе с мошенничеством в банках / Т. Л. Фомичева, Р. М. Магомедов, Е. А. Викулина // *Самоуправление*. – 2019. – Т. 2. – № 3(116). – С. 337-339.
8. Deo R. C. Machine learning in medicine // *Circulation*. – 2015. – Т. 132. – №. 20. – С. 1920-1930.
9. Методология создания автоматизированных информационных систем коллективной обработки разнородной информации от средств аэрокосмического мониторинга / Г. В. Кузьмин, И. В. Макарьин, В. Н. Николаев, Н. Р. Стратилатов. – Курск: Закрытое акционерное общество "Университетская книга", 2018. – 245 с. – ISBN 9785907049697.
10. Кластеризация. MachineLearning.ru URL: <http://www.machinelearning.ru/wiki/index.php?title=Кластеризация> (дата обращения: 18.08.2021)
11. Осипова, Ю. А. Применение кластерного анализа методом k-средних для классификации текстов научной направленности / Ю. А. Осипова, Д. Н. Лавров // *Математические структуры и моделирование*. – 2017. – № 3(43). – С. 108-121.
12. Burscher B., Vliegthart R., Vreese C. H. Frames beyond words: Applying cluster and sentiment analysis to news coverage of the nuclear power issue // *Social Science Computer Review*. – 2016. – Т. 34. – №. 5. – С. 530-545.
13. Nugroho A. et al. Is It A Relational Marketing Strategy? Cluster Analysis@ Universitasmercubuanajakarta Facebook Post and Comment // *MIX: Jurnal Ilmiah Manajemen*. – 2015. – Т. 5. – №. 2. – С. 206-218.
14. Воронцов К. В. Вероятностное тематическое моделирование. URL: www.machinelearning.ru/wiki/images/2/22/Vor on-2013-ptm.pdf (Дата обращения: 18.08.2021).
15. Методы тематического моделирования, их развитие и применение для контента, циркулирующего в региональных онлайн-сообществах / Е. Н. Телегин, Е. Ю. Чапурин, К. А. Разинкин [и др.] // *Информация и безопасность*. – 2019. – Т. 22. – № 3. – С. 325-344.
16. Hong L., Davison B. D. Empirical study of topic modeling in twitter // *Proceedings of the first workshop on social media analytics*. – 2010. – С. 80-88.
17. Классификация // MachineLearning.ru URL: <http://www.machinelearning.ru/wiki/index.php?title=Классификация> (дата обращения: 18.08.2021).
18. Georgakopoulos S. V. et al. Convolutional neural networks for toxic comment classification // *Proceedings of the 10th hellenic conference on artificial intelligence*. – 2018. – С. 1-6.
19. Van Aken B. et al. Challenges for toxic comment classification: An in-depth error analysis // *Proceedings of the 2nd Workshop on Abusive Language Online (ALW2)*. – 2018. – С. 33-42.
20. Ayo F. E. et al. Machine learning techniques for hate speech classification of twitter data: State-of-the-art, future challenges and research directions // *Computer Science Review*. – 2020. – Т. 38. – С. 1-34.
21. Wang X. et al. Drifted Twitter spam classification using multiscale detection test on KL divergence // *IEEE Access*. – 2019. – Т. 7. – С. 108384-108394.
22. Смирнова, О. С. Выбор топологии нейронных сетей и их применение для классификации коротких текстов / О. С. Смирнова, В. В. Шишков // *International Journal of Open Information Technologies*. – 2016. – Т. 4. – № 8. – С. 50-54.
23. Hasan M., Rundensteiner E., Agu E. Emotex: Detecting emotions in twitter messages // *Proceedings of the 2014 ASE BIGDATA/SOCIALCOM/CYBERSECURITY Conference*– 2014. – С. 27-31.
24. Jabreel M., Moreno A. A deep learning-based approach for multi-label emotion classification in tweets // *Applied Sciences*. – 2019. – Т. 9. – №. 6. – С. 59-74.

25. Циклы материалов // Иудаизм и евреи. URL: <https://toldot.ru/cycles/> (дата обращения: 18.08.2021).
26. Истории второй мировой войны 1939—1945 // Военная литература URL: <http://militera.lib.ru/h/12/index.html> (дата обращения: 18.08.2021).
27. Рубцова, Ю. В. Построение корпуса текстов для настройки тонового классификатора / Ю. В. Рубцова // Программные продукты и системы. – 2015. – № 1. – С. 72-78.
28. Стемминг // Википедия URL: <https://ru.wikipedia.org/wiki/Стемминг> (дата обращения: 18.08.2021).
29. Лемматизация // PromoPult URL: <https://promopult.ru/library/Лемматизация> (18.08.2021).
30. Le Q., Mikolov T. Distributed representations of sentences and documents //International conference on machine learning. – PMLR, 2014. – С. 1188-1196.
31. Логистическая регрессия // MachineLearning.ru URL: [http://www.machinelearning.ru/wiki/index.php?title=Логистическая регрессия](http://www.machinelearning.ru/wiki/index.php?title=Логистическая_регрессия) (дата обращения: 18.08.2021).
32. Минаев, В. А. Выявление деструктивного контента в социальных медиа на основе моделей машинного обучения / В. А. Минаев, А. Д. Реброва, А. В. Симонов // Информация и безопасность. – 2021. – Т. 24. – № 1. – С. 7-20. – DOI 10.36622/VSTU.2021.24.1.001.
33. Метод опорных векторов (SVM) // Университет ИТМО URL: [https://neerc.ifmo.ru/wiki/index.php?title=Метод опорных векторов \(SVM\)](https://neerc.ifmo.ru/wiki/index.php?title=Метод_опорных_векторов_(SVM)) (дата обращения: 18.08.2021).

Московский университет МВД России им. В.Я. Кикотя
V.Ya. Kikot Moscow University of the Internal Affairs Ministry of Russia

Московский государственный технический университет им. Н. Э. Баумана
Bauman Moscow State Technical University

Поступила в редакцию 02.09.2021

Информация об авторах

Минаев Владимир Александрович – д-р техн. наук, профессор, Московский университет МВД России им. В.Я. Кикотя, e-mail: mlva@yandex.ru;

Поликарпов Евгений Сергеевич – канд. техн. наук, доцент, Московский университет МВД России им. В.Я. Кикотя, e-mail: binox@mail.ru

Симонов Александр Валерьевич – аспирант кафедры защиты информации, Московский государственный технический университет им. Н. Э. Баумана, e-mail: san.siman@yandex.ru

APPLICATION OF DEEP NEURAL NETWORKS TO IDENTIFY DESTRUCTIVE CONTENT IN SOCIAL MEDIA

V.A. Minaev, E.S. Polikarpov, A.V. Simonov

The purpose of the research is to develop a methodology and search for an effective algorithm for identifying destructive content in short publications and comments in social media. The review of existing solutions for identifying destructive content is carried out, their advantages and disadvantages are described in the context of the problem being solved. Composite experimental corpuses of texts on the following topics were formed: rehabilitation of Nazism, anti-Semitism, and radical Islam. The normalization of the cases was carried out using the methods of stemming and lemmatization. The operation of vectorization of normalized corpora by the methods of a bag of words (BoW), TF-IDF and a layer of artificial neural networks (INS) is carried out. The architectures of deep INS are constructed: convolutional neural network (CNN), recurrent neural network with long short-term memory (LSTM), recurrent neural network with a gate mechanism (GRU). Experiments were conducted on the classification of the generated text corpora using the created INS and traditional machine learning methods. The interpretation of the obtained experimental results is made and the use of deep INS in solving the problem is justified. The conclusion is made about the expediency of using the obtained results by structures engaged in identifying and removing destructive content.

Keywords: information security, social media, destructive content, neural networks, deep learning, text classification.

Submitted 02.09.2021

Information about the authors

Vladimir A. Minaev – Dr. of Engineering, Professor, V.Ya. Kikot Moscow University of the Internal Affairs Ministry of Russia, e-mail: m1va@yandex.ru

Evgeny S. Polikarpov – Cand. Sc (Technical), Professor, V.Ya. Kikot Moscow University of the Internal Affairs Ministry of Russia, e-mail: binox@mail.ru

Alexander V. Simonov – Post-graduate Student of the Department of Information Security, Bauman Moscow State Technical University, e-mail: san.siman@yandex.ru