

РАСПОЗНАВАНИЕ ЛИЦ С ИСПОЛЬЗОВАНИЕМ НЕЙРОСЕТЕВЫХ ТЕХНОЛОГИЙ ПРИ ПОСТРОЕНИИ СИСТЕМ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ

Ю.Ю. Громов, П.И. Карасев, Ю.А. Губсков

Распознавание лиц - это процесс идентификации одного или нескольких людей на изображениях или видео. Это важная часть биометрических систем, систем безопасности и наблюдения, а также систем индексации изображений. В литературе были предложены различные методы распознавания лиц, такие как собственные векторы, методы, основанные на выделении признаков, скрытая модель Маркова и методы, основанные на нейронных сетях. Первые три метода в основном включают фазу извлечения или предварительной обработки объектов, тесно связанную с типом распознаваемого изображения. С другой стороны, технология нейронных сетей не требует конкретных данных о типе изображения, поэтому может быть применена к любому типу изображения и в то же время обеспечивает лучшую точность. В этой статье была предпринята попытка объединить технологии нейронной сети с нечеткой логикой. Экспериментальный результат показывает, что сочетание этих двух методов обеспечивает лучшую точность по сравнению с другими методами, упомянутыми выше.

Ключевые слова: распознавание лиц, нейронная сеть, нечеткая логика

Введение

Распознавание лиц – это задача для автоматической идентификации или проверки личности по цифровой базе данных изображений. Это важная отрасль распознавания образов, которая имеет множество приложений, таких как безопасность и наблюдение, биометрическая посещаемость, система индексации посетителей и т.д. Существуют различные подходы к области распознавания лиц, такие как:

Собственные векторы – этот подход является хорошо изученным методом распознавания лиц, основанным на Анализе главных компонент (РСА). Чтобы повысить точность этого подхода, необходимо увеличить число собственных векторов. Хотя этот подход обеспечивает хорошую точность, он имеет очень высокие вычислительные затраты, поэтому этот подход не используется. Собственные векторы - хорошо известный метод распознавания лиц, основанный на РСА. РСА - это метод преобразования множества коррелированных переменных в множество некоррелированных переменных меньшего размера [1]. Подобно тому, как анализ Фурье используется для разложения сигнала на набор аддитивных ортогональных синусоид различных частот, РСА разлагает сигнал (или

изображение) на набор аддитивных ортогональных базисных векторов или собственных векторов. Основное отличие состоит в том, что, в то время как анализ Фурье использует фиксированный набор базовых функций, базовые векторы РСА извлекаются из набора данных с помощью обучения без учителя. РСА может быть применен к задаче распознавания лиц путем преобразования пикселей изображения в ряд векторов признаков собственных векторов, которые затем можно использовать в сравнении для измерения сходства двух изображений лиц. Наблюдение за этим результатом показывает, что первый собственный вектор соответствует 50% дисперсии в наборе данных, в то время как первые 20 собственных векторов вместе соответствуют чуть более 85%, а первые 30 собственных векторов – 90%. Увеличение числа собственных векторов обычно повышает точность распознавания, но также увеличивает вычислительные затраты. Хотя этот подход в настоящее время в значительной степени устарел, он по-прежнему часто используется в качестве эталона для сравнения производительности других методов и служит хорошим введением в задачу к распознаванию лиц [2].

На основе выделения признаков. Для этого подхода требуются точки на

изображении лица с высоким содержанием информации. Интересные характерные точки на изображении лица обнаруживаются с помощью фильтра Габора (Gabor), который помогает однозначно идентифицировать лица. Система, основанная на выделении признаков, требует наличия точек на изображении лица с высоким информационным содержанием. Как правило, они расположены вокруг глаз, носа и рта. Как правило, не интересуют контур лица или волосы, так как наиболее стабильные и информативные черты человеческого лица расположены в центре лица. Существует несколько возможных способов определения точек с высоким содержанием информации, для этого рассматривается подход с использованием фильтра Габора. Фильтры Габора генерируются из вейвлет-разложения ядра Габора, параметризованного (определяющего длину волны и ориентацию) вектором. Этот фильтр помогает в распознавании лиц [3-4].

Скрытая Марковская модель. Этот подход использует стратегию сканирования для моделирования последовательности, подобной человеческой. Система сканирования сканирует лицо и сохраняет информацию о точках в обработчике данных, в котором применяются определенные методы для распознавания лиц. У этого метода есть недостаток, заключающийся в том, что он не учитывает важные характерные особенности лица. Скрытые Марковские модели (НММ) представляют собой класс статистических моделей, используемых для характеристики наблюдаемых свойств сигнала. НММ состоит из двух взаимосвязанных процессов:

1. Лежащая в основе ненаблюдаемая цепь Маркова с конечным числом состояний, управляемых матрицей вероятностей перехода состояний и распределением вероятностей начального состояния.

2. Набор наблюдений, определяемых функциями плотности наблюдений, связанными с каждым состоянием. Скрытую Марковскую модель с дискретным временем можно рассматривать как Марковскую модель, состояния которой нельзя явно наблюдать. Каждое состояние имеет связанную функцию распределения

вероятностей, моделирующую вероятность появления образов из этого состояния.

Основная проблема этих подходов, основанных на НММ, заключается в том, что методология сканирования фиксирована (обычно используется растровое сканирование), а важность (значимость) особенностей лица игнорируется [5].

Нейронная сеть. Этот подход использует нейронную сеть для обучения распознаванию наборов данных. Обучающий набор данных состоит из входных сигналов, которым присвоена соответствующая цель (желаемый выход). Затем нейронная сеть обучается с использованием одного из методов обучения с учителем [6].

При анализе вышеперечисленных методов было установлено, что методы нейронных сетей обладают преимуществами высокой скорости, лучшей точности и низких требований к оборудованию. Поэтому в этой статье было сначала проверено, какой метод нейронной сети является лучшим, в дополнение к нему проведено сравнение метода с нечеткой методологией, чтобы получить более высокие значения точности. Для реализации были использованы `nn toolbox` и `fuzzy tool` из набора инструментов MATLAB. Задача распознавания лиц выполняется на наборе данных изображений лиц K людей (значение K варьировалось от 20 до 80 с шагом 20). Сеть была создана с использованием базы данных, и упомянутый метод помог решить, относится ли тестовое изображение к базе данных или нет, на основе сравнения с более высоким значением точности, как показано в наших результатах. Цель нейронных сетей состоит в том, чтобы обучить сеть распознавать лицо на изображении. Для обучения нейронной сети требуется обучающий набор данных. Обучающий набор данных состоит из входных сигналов, которым присвоена соответствующая цель (желаемый выход). Затем нейронная сеть формируется с использованием одного из методов обучения с учителем, который использует данные для настройки весов и пороговых значений сети, чтобы минимизировать ошибку в ее прогнозах на обучающем наборе. Если сеть правильно структурирована, то она научилась моделировать функцию, которая связывает

входные переменные с выходными переменными, и впоследствии может использоваться для прогнозирования там, где выходные данные неизвестны. Этот метод обеспечивает наилучший результат для распознавания лиц. Для доказательства этой теории, были проведены эксперименты сравнения с тремя методами нейронных сетей, которые будут описаны ниже [7].

Из всех рассмотренных выше методов методы нейронных сетей имеют преимущества высокой скорости, лучшей точности и низких требований к оборудованию. Чтобы доказать это, проведен эксперимент с базой данных, состоящей из 20 изображений с разрешением 260x400. Результаты для этой задачи показаны в табл. 1.

Таблица 1

Сравнение с точки зрения точности (%)

Векторы	На основе признаков	Модель Маркова	Нейронная сеть

Из табл. 1 видно, что метод собственных векторов имеет лучшую точность при более чем 30 собственных значениях. Увеличение числа собственных значений повышает точность, но также увеличивает вычислительные затраты. В то время как из-за высокой скорости, низких требований к оборудованию и низкой стоимости нейронные методы более выгодны. Таким образом, можно сделать вывод, что методы нейронных сетей являются лучшими для распознавания лиц. Таким образом, теперь мы проверили, какой метод нейронных сетей является лучшим, который можно использовать в нашем предложении. Для этого мы использовали три популярных метода, а именно:

Нейронная сеть с обратным распространением ошибки (BPNN): В этом методе сеть имеет слоистую структуру. Основными слоями являются входной, скрытый и выходной слои. Эта сеть отличается от других тем, как вычисляются веса во время обучения. Когда количество скрытых слоев увеличивается, обучение становится более сложным. В сети может быть более одного скрытого слоя, но одного слоя достаточно, чтобы решить данную

задачу. Обучение BPNN проводится в три этапа:

- Прямая передача входных данных;
- Расчет весов и ошибок;
- Обратное распространение ошибки.

Входной слой состоит из узлов, которые получают внешний сигнал. Внутри слоя нет никаких соединений. Вход подается на первый слой скрытых узлов. Скрытый узел применяет функцию активации и получает взвешенное смещение, вывод скрытых узлов распределяется по следующему слою скрытых узлов. Этот процесс продолжается до последнего слоя скрытых узлов. Выходы подаются в слой выходных узлов. Хотя обучение BPNN проходит очень медленно, как только сеть обучена, она быстро дает результаты [8].

Рекуррентная нейронная сеть: RNN – это метод нейронной сети, в котором связи между узлами образуют направленный цикл. Простая рекуррентная сеть должна иметь активную обратную связь, обладающую кратковременной памятью. Среди слоев Рекуррентной сети несколько скрытых слоев. Каждый скрытый слой зависит не только от внешнего входного слоя, но и от активации предыдущего прямого распространения. Для формирования RNN в структуру добавляется контекстный слой для хранения информации. Каждый раз, когда в RNN подается новый входной набор, предыдущее содержимое скрытого слоя сохраняется в контекстном слое и предоставляется в качестве обратной связи скрытому слою. Обратная связь также имеет возможность изменять набор весов. RNN - это нейронная сеть, основанная на времени, которая принимает входные данные на каждом временном шаге. Здесь функция активации, используемая для вычисления выходных данных, является чисто нелинейной. Уровень обратной связи оказывает непосредственное влияние на выходные данные, поскольку ошибка, однажды введенная в сеть, влияет на конечный результат по пути обратной связи.

Каскадная нейронная сеть прямого распространения: также имеет слоистую структуру, в которой каждый скрытый слой включает соединение с входным слоем и всеми предыдущими слоями. Сеть растет по запросу, новые нейроны в скрытом слое

добавляются и обучаются один за другим. Обучение сети начинается только с входного и выходного слоев и не содержит нейронов скрытого слоя. В процессе обучения новые нейроны добавляются в сеть и обучаются. Этот недавно добавленный нейрон называется нейроном-кандидатом, который имеет связь со всеми нейронами входного и скрытого слоев. Корректировка весов может выполняться только с нейроном-кандидатом, в то время как все остальные веса в сети фиксированы. CNN начинает с одного входного узла, а затем продолжает добавлять новые входные и скрытые нейроны. Обученная CNN имеет минимальное количество входов, скрытых нейронов и соединений [9].

Теперь требуется проверить, какая нейронная сеть дает наилучшую точность. Для этого был проведен эксперимент, в ходе которого рассчитали точность и временную сложность. Результаты приведены в табл. 2.

Таблица 2

Сравнение видов нейронных сетей

	BPNN	CNN	RNN
Время(с)	3,02	12,02	3,20
Точность(%)	83,09	65,1	61

На основе приведенной выше общей сравнительной табл. 2 можно сделать следующие выводы:

- Метод сети с обратным распространением ошибки лучше всего подходит с точки зрения точности. Точность, полученная в нашем эксперименте по этой методике, составляет почти 83,09%.

- Время, затраченное BPNN, также очень мало (3,02с). Таким образом, использование этого метода ускоряет распознавание образов.

- Порядок методов нейронной сети по степени точности - BPNN, CNN и RNN, а с точки зрения прошедшей настройки - BPNN, RNN и затем CNN.

Для повышения точности были объединены методы нейронных сетей с системой нечеткого вывода, результаты оказались намного лучше и точнее.

Предложение

В настоящее время доступно множество методов распознавания изображений, но большинство из них включают функции извлечения или обработки, связанные с типом изображения. Метод, предложенный в этой статье, может быть применен к любому типу изображений. Предложение разделено на два этапа: этап обучения и этап распознавания.

Обучение нейронной сети состоит из следующих шагов, как показано на рис. 1.

- Первым шагом при формировании представления является предоставление сети набора данных. Для этого идентичная строка из матрицы изображения рассматривается как вход для проектирования структуры.




Рис. 1. Обучение нейронной сети

Набор данных, полученный на шаге 1, теперь используется для проектирования архитектуры нейронной сети, как показано на рис. 2. Спроектированная сеть имеет количество входных данных, равное количеству столбцов в матрице набора данных. Здесь BPNN работает в режиме прямого распространения. Эта сеть имеет слоистую структуру. Основными слоями являются входной, скрытый и выходной слои. Это отличается от других, основанных на способе расчета весовых коэффициентов во

время обучения, методов. Когда количество скрытых слоев увеличивается, обучение становится более сложным. В сети может быть более одного скрытого слоя, но одного слоя достаточно для решения данной цели. Обучение BPNN проводится в три этапа:

- Прямое распространение входных данных.

- Расчет весов и ошибок.

- Обратное распространение ошибок.

Входной слой состоит из узлов, которые получают внешний сигнал. Внутри слоя нет

никаких соединений. Эти входные узлы своими выходами соединены с первым слоем скрытых узлов. Скрытый узел применяет функцию активации и получает взвешенное пороговое смещение, выход скрытых узлов соединен со следующим слоем скрытых узлов. Этот процесс продолжается до

последнего слоя скрытых узлов. Выходы последнего скрытого слоя соединяются со слоем выходных узлов. Хотя обучение BPNN проходит очень медленно, как только сеть обучена, она быстро дает результаты.




Рис. 2. Схема типичной обработки нечетких изображений

На заключительном этапе выполняется обучение нейронной сети, после создания базы данных устанавливается цель, соответствующая изображениям, которые необходимо сохранить в базе данных. Затем разработанная выше сеть обучается таким образом, чтобы выходные данные сети хорошо соответствовали целевым значениям. Чем ближе значение к обученному значению, тем выше точность. Таким образом, для этой цели сеть может быть обучена за 4-5 циклов. Этот шаг завершает первую фазу.

Распознавание данных с использованием нечеткой логики:

Точность нейронной сети рассчитывается по двум параметрам, а именно:

- Эпохи (Epochs) – меньшее количество эпох означает, что сеть учится с небольшими

повторениями. Меньшее время означает, что сеть достигла цели легко и быстро. Чем меньше значение эпох, тем выше точность сети.

- Градиентный спуск – низкое значение градиента указывает на то, что сеть в значительной степени обучена, что означает более точную корректировку весов и порогового смещения. Это, в свою очередь, делает сеть более точной и надежной, уменьшая вероятности ложных прогнозов.

На рис. 3 изображены два выходных параметра нейронной сети, на основе которых вычисляется точность, которые передаются системе нечеткого вывода (FIS) в качестве входных данных. Два входных узла на рисунке показывают схожий результат.




Рис. 3. Проектирование системы нечеткого вывода

Входные данные для FIS определяются функцией принадлежности, которая определяется между границами, в которых находятся два входных значения. Здесь диапазон выбирается от 0 до 50. Возможно выбрать любую функцию принадлежности,

которая уже определена, или настроить собственную структуру принадлежности.

На рис. 4 показана функция принадлежности, выбранная для входных наборов, полученных методом Градиентного спуска и методом Эпох (Epochs).




Рис. 4. Функция принадлежности наборов, полученных методом градиента и эпох (epoch)

Центральный блок состоит из правил для сети, которые основаны на комбинации двух входных параметров для обеспечения желаемого вывода. Нечеткие правила избыточны для каждого ввода, необходимо

повторить набор правил для входного параметра. В эксперименте использовались следующие правила. На рис. 5 показано выходное значение функции принадлежности.




Рис. 5. Функция принадлежности для выходной переменной Точность (Assurasy)

Третий и последний блок на этапе распознавания – это выходная функция принадлежности, которая определяется в диапазоне скорости распознавания от [0 100]. Когда два входа имеют значения в низком

диапазоне, точность вычисляется лучше, чем определено правилами.

Комбинированный алгоритм обеих фаз показан на рис. 6:




Рис. 6. Алгоритм предлагаемого метода

Настройка параметров моделирования. После компиляции двух этапов спроектированная сеть показана на рис. 7. На рисунке показана комбинация нейронной сети и нечеткой системы. Первые два блока на рисунке показывают вход в сеть. К входным данным применяется функция

принадлежности. Правила реализуются на основе определенной входной и выходной функции принадлежности. Конечный выходной блок обеспечивает точность всей сети и является конечным выходом объединенных сетей.




Рис. 7. Спроектированная архитектура нечеткой нейронной сети

Выход вышеупомянутой сети изучается с помощью рис. 8. На рисунке представлена база правил и соответствующие входные и выходные данные. Использование нечеткого

вывода делает систему более гибкой, поскольку она принимает все значения в указанном диапазоне.




Рис. 8. Правила нечеткой системы

Показатели эффективности

Таблица 3

Производительность системы анализируется на основе двух показателей:

Точность – способность согласовывать измеренное значение количества с фактическим значением называется точностью. Точность здесь измеряется методами Эпох и Градиента, меньшее количество эпох означает, что сеть обучается с небольшими повторениями, а меньший градиент означает точную настройку весов и пороговых смещений, которые позволяют избежать ложного предсказания.

Коэффициент ошибок – это термин, который описывает количество ошибок, возникающих при передаче данных или при подключении к сети. Чем выше коэффициент ошибок, тем менее надежна будет система.

Параметры настройки. В заключение были проведены тесты с базой данных, состоящей из 20, 40, 60 и 80 изображений с разрешением 260x400. Это изображения 10 человек, снятых в разное время, с разными выражениями лица и вариациями освещения. В табл. 3 показаны различные параметры настройки моделирования, использованные в нашем эксперименте.

Параметры настройки

Кол-во изображений	
Изображений каждого человека	
Разрешение изображения	x
Фон	Светло Зеленый
Варианты освещения	Да
Вариант выражения	Да

Результаты моделирования


Влияние на точность

На рис. 9 (а) и 9 (б) показана точность методов нейронных сетей и предлагаемого метода. Можно сделать следующий вывод:


- Метод BPN является лучшим с точки зрения точности, за которым следуют CNN и RNN.

- Легко увидеть, что когда методы нейронных сетей сочетаются с методами нечеткой логики, результат точности улучшается.

- По мере увеличения числа изображений точность методов нейронных сетей повышается, но она почти такая же, когда метод нейронной сети сочетается с нечеткой логикой.



(а) Сравнение методов нейронных сетей



(б) Сравнение методов объединения нейронных сетей и нечеткой логики

Рис. 9. Графики точности для методов нейронных сетей и объединения методов нечеткой логики и нейронных сетей

Ошибки первого и второго рода

Частота ошибок для методов нейронных сетей и методов нейронных сетей в сочетании с нечеткой логикой показана в табл. 4: В

таблице показан гибридный метод, то есть сочетание нечетких методов с нейронными сетями имеет сравнительно меньшую

погрешность, чем метод только нейронных сетей.

Таблица 4

Частота ошибок

Нейронные сети			
Нечеткая логика + нейронные сети			

В табл. 5 показано общее сравнение предлагаемых методик с методами, доступными в литературе. Можно сделать следующие выводы:

- Нейронная сеть в сочетании с Нечеткой логикой имеет более высокую точность, чем любой другой метод, описанный в литературе.
- Метод собственных векторов обеспечивает хорошую точность за счет дополнительных вычислительных затрат.

Таблица 5

Сравнение с другими методами

Векторы	На основе признаков	Модель Маркова	Нейронная сеть	Новый метод

6. Заключение

В этой статье была предпринята попытка улучшить существующие методы распознавания лиц с учетом скорости распознавания путем реализации нечеткой логики с использованием наиболее эффективных методов, то есть методов нейронных сетей. Можно сделать вывод, что если использовать наиболее эффективный метод с нечеткой логикой, он может дать гораздо лучшие результаты. В этой статье рассматриваются две части сети: одна – нейронная сеть для обучения, вторая – система нечеткого вывода, которая помогает улучшить результат при распознавании лиц. Нечеткая логика оказалась инструментом, который может улучшить производительность существующей системы.

Список литературы

1. Сегментация клинических эндоскопических изображений, основанная на классификации векторных топологических признаков / О.А. Дунаева, Д.Б. Малкова, М.Л. Мячин, Х.Эдельсбруннер // Моделирование и

анализ информационных систем. 2013. Т. 20, № 6. С.162–173.

2. Карасев П.И., Поляков Д.В., Попов А.И., Матвеева А.С., Балюков Д.А. Оценка семантической значимости нечетких коллокаций на основе обобщенной векторно-пространственной модели текстовой коллекции // Прикаспийский журнал: управление и высокие технологии. 2016. № 1(33). С. 10-25.

3. Маматов, Е.М. Об автоматической классификации объектов и распознавании образов с использованием весов признаков и репрезентативностей классов / Е.М. Маматов / Научные ведомости. 2008. № 10 (50). С. 48-57.

4. Петровский, А.Б. Методы групповой классификации многопризнаковых объектов (часть 1) / А.Б. Петровский // Искусственный интеллект и принятие решений. 2009. № 3. С. 3-14.

5. Demonceaux, C. Markov random fields for catadioptric image processing / C. Demonceaux, P. Vasseur // Pattern Recognition Letters. 2008. No. 27 (16). P. 1957-1967. Марковские области для обработки изображений.

6. Карасев П.И., Минина Е.Н., Стародубов К.В. Применение нейронных сетей для распознавания образов в автоматизированных системах управления // Научный вестник воронежского государственного архитектурно-строительного университета. Серия: управление строительством. 2015. № 2. С. 190-195.

7. Micheloni, C. Real-time image processing for active monitoring of wide areas / C. Micheloni, G.L. Foresti // Journal of Visual Communication and Image Representation. 2006. No. 17 (3). P. 589-604 Обработка изображения в реальном времени для активного контроля широких областей.

8. A weighted fuzzy classifier and its application to image processing tasks / T. Nakashima, G. Schaefer, Y. Yokota, H. Ishibuchi // Fuzzy Sets and Systems. 2007. No. 158 (3). P. 284-294. Взвешенный нечеткий классификатор и его применение к задачам обработки изображения.

9. Bloch, I. Fuzzy sets for image processing and understanding / I. Bloch // Fuzzy Sets and

Systems. 2015. No. 281. P. 280-291 Нечеткие множества для обработки изображения и понимания.

Тамбовский государственный технический университет
Tambov State Technical University

МИРЭА – Российский технологический университет
MIREA – Russian Technological University

Поступила в редакцию 21.01.2022

Информация об авторах

Громов Юрий Юрьевич – д-р техн. наук, профессор, Тамбовский государственный технический университет, e-mail: gromovtambov@yandex.ru

Карасев Павел Игоревич – канд. техн. наук, МИРЭА - Российский технологический университет, e-mail: karasev@mirea.ru

Губсков Юрий Анатольевич – канд. техн. наук, Тамбовский государственный технический университет, e-mail: gromovtambov@yandex.ru

FACE RECOGNITION USING NEURAL NETWORK TECHNOLOGIES IN THE CONSTRUCTION OF INFORMATION SECURITY SYSTEMS

Y.Y. Gromov, P.I. Karasev, Y.A. Gubskov

Face recognition is the process of identifying one or more people in images or videos. It is an important part of biometric systems, security and surveillance systems, and image indexing systems. Various face recognition methods have been proposed in the literature, such as: eigenvectors, feature-based methods, hidden Markov model, and neural network-based methods. The first three methods mainly include an object extraction or pre-processing phase, closely related to the type of image being recognized. On the other hand, neural network technology does not require specific data about the image type, so it can be applied to any type of image and at the same time provides better accuracy. In this article, an attempt was made to combine neural network technologies with fuzzy logic. The experimental result shows that the combination of these two methods provides better accuracy compared to the other methods mentioned above.

Keywords: face recognition, neural network, fuzzy logic.

Submitted 21.01.2022

Information about the authors

Yurii Y. Gromov – Dr. Sc. (Technical), Professor, Tambov State Technical University, e-mail: gromovtambov@yandex.ru

Pavel I. Karasev – Cand. Sc. (Technical), MIREA – Russian Technological University, e-mail: karasev@mirea.ru

Yurii A. Gubskov – Cand. Sc. (Technical), Tambov State Technical University, e-mail: gromovtambov@yandex.ru