

ОЦЕНКА РИСКА С ИСПОЛЬЗОВАНИЕМ НЕЙРО-НЕЧЕТКОЙ СИСТЕМЫ

С.А. Ермаков, А.А. Болгов

В работе предлагается использование нейро-нечеткой системы в методике оценки риска. Проводится подробный обзор нейро-нечеткой системы, выделяя основные свойства этой системы в области методов оценки рисков. Рассмотрены типы нейро-нечетких систем. Приведены основные преимущества использования модели на основе нейро-нечеткой системы. Представлен алгоритм внедрения нейро-нечеткой системы в метод оценки риска. Предложен метод обучения на основе алгоритма Левенберга-Марквардта. Проведены различные эксперименты с использованием модели на основе нейро-нечеткой системы с применением выбранного алгоритма обучения для разного количества запросов на доступ. Полученные результаты экспериментов по оценке риска при использовании модели на основе нейро-нечеткой системы сравнивались с результатами, полученными при помощи модели на основе нечеткой логики. Также было выполнено сравнение результатов экспериментов с результатами, полученными при использовании модели на основе адаптивной нейро-нечеткой системы вывода.

Ключевые слова: нечеткая логика, нейро-нечеткая система, обучение, алгоритм обучения, искусственная нейронная сеть, риск, Интернет вещей.

Введение

Нейро-нечеткая система (ННС) является результатом интеграции искусственной нейронной сети (ИНС) с системой нечеткой логики. Оно объединяет человекоподобное мышление систем нечеткой логики с обучением и коннекционизмом ИНС [1]. Несколько моделей на основе нейро-нечеткой системы были успешно реализованы в различных социальных и технологических приложениях. Нейро-нечеткая система обладает мощными и гибкими универсальными аппроксимациями с возможностью распознавания интерпретируемых правил «ЕСЛИ-ТО» [2].

Нейро-нечеткая система – это по своей сути система нечеткой логики, которая обучается с помощью алгоритма, основанного на теории искусственных нейронных сетей. Система нечеткой логики и искусственная нейронная сеть обладают рядом преимуществ, как независимые системы. Но при этом у них также есть недостатки, которые побудили исследователей разработать гибридную нейро-нечеткую систему, которая способна свести к минимуму эти недостатки.

Одним из наиболее важных преимуществ ИНС является возможность учиться на примерах. Однако трудно доказать, что ИНС

работает правильно. Для пользователя это как «черный ящик», в котором не раскрывается способ получения выходных данных [3].

Значимым преимуществом системы нечеткой логики является то, что ее легко построить и понять, используя лингвистические выражения для разрешения неточной информации [3, 4]. Однако нелегко гарантировать, что система нечеткой логики с рядом сложных правил обеспечит надлежащую степень осмысленности. К тому же, система нечеткой логики использует статические нечеткие правила, которым не хватает адаптивности для разрешения непредсказуемых изменений в окружающей среде [4].

Интеграция искусственной нейронной сети с системой нечеткой логики решила некоторые из этих проблем. Полученная в результате гибридная нейро-нечеткая система сочетает в себе возможности параллельных вычислений и обучения ИНС с человеческими рассуждениями о нечетких системах и понятным представлением системы. Таким образом, ИНС становится более прозрачным, а система нечеткой логики обретает способность к обучению [5].

Модель многослойного персептрона

Модель многослойного персептрона (МСП) представляет собой искусственную нейронную сеть с прямой связью. Это наиболее распространенная и широко используемая модель ИНС в различных приложениях [6]. МСП используется для исследования сложных и нелинейных моделей. Она основана на методе контролируемого обучения, который заключается в том, чтобы желаемый результат для каждого ввода был известен заранее для того, чтобы вычислить ошибку по полученным данным на выходе [7].

Как правило, модель МСП состоит из трех слоев: входного слоя, скрытого слоя и выходного слоя, как показано на рис. 1. Входной слой представляет входные переменные системы в виде круга (нейрона) для каждой переменной. В то время как выходная переменная представлена одним кругом в выходном слое. Средний слой – это скрытый слой, который не виден снаружи. Этот уровень отвечает за выполнение промежуточных вычислений. Определение количества скрытых слоев, скрытых нейронов и типа передаточной функции играет важную роль в реализации эффективной модели МСП [8].




Рис. 1. Слои модели многослойного персептрона (МСП)

Контролируемое обучение многократно используется для регулировки веса каждого соединения, чтобы получить точный результат [9]. Это достигается за счет использования алгоритма обучения с обратным распространением, который оценивает производные ошибки сети по всем ее весам и корректирует эти веса, чтобы получить небольшую ошибку, где ошибка представляет собой разницу между выходом сети и целевым выходом для одних и тех же входных данных [10].

Построение модели ННС требует использования одной из распространенных моделей ИНС. В этой работе была выбрана модель МСП для реализации модели на основе нейро-нечеткой системы для оценки риска, поскольку эта модель эффективна и широко используется в различных приложениях.

Типы нейро-нечетких систем

Как правило, термин ННС относится ко всем системам, которые появились в результате интеграции искусственной нейронной сети с системой нечеткой логики. Эта интеграция может быть осуществлена тремя различными способами: совместным, параллельным и гибридным.

Совместная нейро-нечеткая система

Совместная ННС используется для описания интеграции искусственной нейронной сети с системой нечеткой логики, в которой ИНС используется для настройки системы нечеткой логики без изменения функциональности переменных. Другими словами, ИНС используется в качестве этапа предварительной обработки, на котором алгоритм обучения ИНС используется для определения некоторых переменных нечеткой логики. Например, алгоритмы

кластеризации могут быть использованы для определения нечетких множеств и нечетких правил. После определения переменных системы нечеткой логики, алгоритм обучения ИНС удаляется, а система нечеткой логики

работает сама по себе [11]. Следовательно, ИНС используется только на начальной стадии настройки системы нечеткой логики [12]. Архитектура совместной ННС показана на рис. 2.




Рис. 2. Совместная нейро-нечеткая система

Параллельная нейро-нечеткая система

Параллельная ННС относится к системе, в которой искусственная нейронная сеть и система нечеткой логики работают вместе. Входные данные предварительно обрабатываются системой нечеткой логики. После этого данные попадают в ИНС, которая проходит обучение, а затем формирует выходные данные, как показано на рис. 3.

Один из недостатков, связанный с параллельной ННС заключается в том, что результаты на выходе данной системы не могут быть полностью интерпретированы. Веса заменяются функциями принадлежности, в которых результатом каждого процесса взвешивания является значение принадлежности соответствующего входного сигнала к нечеткому множеству [11, 13].




Рис. 3. Параллельная нейро-нечеткая система

Гибридная нейро-нечеткая система

В работе [14] гибридная ННС определяется как: «Нечеткая система, которая использует алгоритм обучения, основанный на градиентах или вдохновленный теорией нейронных сетей (эвристические стратегии обучения), для определения своих параметров (нечетких множеств и нечетких правил) посредством обработки шаблонов (ввода и вывода)».

В гибридной ННС модель нечеткой логики и модель искусственной нейронной сети используются независимо. Каждая модель в системе используется для выполнения определенной задачи для достижения общей цели. Концепция гибридной ННС относится к объяснению системы нечеткой логики относительно ИНС. Следовательно, нечеткие множества могут быть интерпретированы как веса, а нечеткие

правила, входные и выходные переменные могут быть интерпретированы как нейроны. Другими словами, одним из преимуществ гибридной ННС является ее архитектура, поскольку как нечеткой системе, так и нейронной сети больше не нужно взаимодействовать друг с другом. Они представляют собой одну полностью слитую сущность [12].

Существует несколько различных способов разработки гибридных нейро-нечетких систем, поэтому существуют различные модели, которые строятся на основе контекста. Эти модели схожи по своей сути, но в них есть принципиальные различия. Многие типы ННС представлены нейронными сетями, которые реализованы с помощью логических функций. Это не обязательно для применения алгоритма обучения в нечеткой системе, однако представление в виде нейронной сети более удобно, поскольку позволяет визуализировать поток данных через систему и сигналы ошибок, которые используются для обновления ее параметров [11].

Внедрение нейро-нечеткой системы

Гибридная ННС была выбрана для реализации метода оценки рисков предлагаемой модели контроля доступа. Для реализации методики оценки риска использовалась система нечеткой логики с экспертными оценками. Информация, собранная от экспертов по безопасности Интернета вещей, была использована для подтверждения и построения точных нечетких правил. Результаты продемонстрировали, что сочетание системы нечеткой логики с экспертными оценками может обеспечить точные и реалистичные

результаты при оценке рисков безопасности операций контроля доступа. Однако модель контроля доступа для системы Интернета вещей обслуживает тысячи пользователей. При этом масштабируемость системы нечеткой логики представляется сомнительной. Поэтому была выбрана нейро-нечеткая система, которая позволила сократить время обработки каждого запроса на доступ за счет параллельных вычислений ИНС и добавления возможности обучения к предлагаемому методу оценки рисков для адаптации к изменениям среды Интернета вещей.

Внедрение гибридной ННС выполняется в два отдельных этапа. Сначала внедряется система нечеткой логики и создается база данных. Затем ИНС будет использовать этот набор данных для обучения системы и повышения быстродействия. Поскольку предложенный метод оценки риска с использованием системы нечеткой логики был реализован ранее, то в этой работе основное внимание уделяется только использованию набора данных, созданного с помощью системы нечеткой логики, для обучения модели на основе нейро-нечеткой системы.

Реализация модели на основе ННС предлагаемого метода оценки риска состоит из трех слоев: входного слоя, скрытого слоя и выходного слоя. Входной слой включает в себя четыре входных параметра контроля доступа предлагаемой модели на основе рисков (рис. 4):

- контекст пользователя;
- оценка критичности ресурса;
- оценка критичности операции;
- историю рисков.




Рис. 4. Реализация модели на основе ННС с помощью нейронного ввода

Выходной уровень представляет результат процесса оценки риска. Средний выходное значение риска, полученное в выходной уровень – это скрытый уровень, который

отвечает за выполнение вычислений и обновление весов между различными соединениями.

Одна из проблем, связанных с внедрением модели на основе ННС для оценки риска, заключается в определении соответствующего количества скрытых слоев и соответствующего количества нейронов для каждого скрытого слоя. Количество скрытых слоев, необходимых для модели на основе ННС, зависит от сложности взаимосвязи между входными и целевыми параметрами. Это оказывает серьезное влияние на процесс обучения. Однако сеть прямой связи обратного распространения (ПСОР), охватывающая более одного скрытого слоя, встречается очень редко [15]. В работе [16] авторы доказали, что сети ПСОР с одним скрытым слоем достаточно для большинства задач в различных приложениях.

Также стоит отметить, что определение оптимального количества нейронов в скрытом слое играет значительную роль в реализации модели на основе ННС. Если используется недостаточное количество нейронов, модель на основе ННС не сможет моделировать сложные данные, и результирующее соответствие будет плохим. В то время как использование большого количества нейронов в скрытом слое влияет на его быстродействие при обработке новых данных, и его способность предоставлять обобщенную модель будет поставлена под угрозу [12]. Действительно, увеличение количества нейронов обеспечивает правильное обучение, но это также влияет на быстродействие нейро-нечеткой системы. Следовательно, необходимо достичь компромисса между большим и малым количеством нейронов в скрытом слое.

Сбор данных

Реализация модели на основе нейро-нечеткой системы предлагаемого метода оценки риска требует наличия набора данных для обучения. После реализации предложенной методики оценки рисков с использованием системы нечеткой логики на основе экспертных оценок, как обсуждалось в работе [17], был создан набор данных для обучения ННС. Чтобы избежать возможного

смещения выборки данных в сторону модели на основе ННС, набор данных был рандомизирован и разделен на два набора с использованием метода перекрестной проверки.

- Обучающий набор – этот набор содержит 60% от общего набора данных для обучения модели.

- Тестовый набор – этот набор содержит 20% от общего набора данных для тестирования модели.

- Проверочный набор – этот набор содержит 20% от общего набора данных для проверки модели.

Экспериментальные результаты

Реализация модели на основе нейро-нечеткой системы предлагаемого метода оценки риска требует определения количества скрытых слоев и количества нейронов в скрытых слоях. Основываясь на источниках [16, 18–20], для выполнения большинства задач достаточно одного скрытого слоя. Таким образом, для реализации метода оценки риска на основе ННС был использован один скрытый слой. Чтобы определить соответствующее количество нейронов в скрытом слое, модель на основе ННС была обучена с использованием четырех алгоритмов обучения. Было проведено несколько экспериментов для определения соответствующего количества нейронов и наилучшего алгоритма обучения. После определения соответствующего количества нейронов в скрытом слое была обучена модель на основе ННС, а затем обученная модель была протестирована с различным количеством запросов доступа с точки зрения времени обработки. Все обучающие функции и эксперименты были выполнены с использованием программного обеспечения MATLAB.

Обучение на основе алгоритма Левенберга-Марквардта

Алгоритм Левенберга-Марквардта (ЛМ) – это итерационный метод, который определяет локальный минимум многомерной функции. Он выражается как сумма квадратов нескольких нелинейных и вещественнозначных функций. Алгоритм ЛМ

широко применяется в различных дисциплинах для решения задач подгонки данных. Он также стал стандартным методом для нелинейных задач наименьших квадратов. Алгоритм обучения Левенберга-Марквардта можно рассматривать как комбинацию наискорейшего спуска и метода Гаусса-Ньютона [21]. Он также считается самым быстрым алгоритмом обучения. Единственным ограничением, связанным с этим алгоритмом, является то, что он потребляет большое количество памяти [22, 23].

Нейро-нечеткая система и нечеткая система

Предложенный метод оценки риска был впервые реализован с помощью системы нечеткой логики с использованием нечеткого интерфейса (НИС) Мамдани и протестирован с различным количеством запросов на доступ. Одна из проблем, с которой столкнулось внедрение предложенного метода нечеткой оценки рисков в реальных

приложениях Интернета вещей, заключается в том, что он требует достаточно большого количества времени на обработку, а его масштабируемость представляется сомнительной. Чтобы решить эту проблему, предложенная методика оценки риска была реализована с использованием нейро-нечеткой системы с методом обучения алгоритмом Левенберга-Марквардта (ЛМ). Возможности параллельных вычислений и обучения модели ННС добавили неоспоримые улучшения в методику оценки рисков.

Результаты показали, что использование ННС с алгоритмом обучения ЛМ для реализации предлагаемого метода оценки риска обеспечивает меньшее время обработки, поскольку оно использует только одну шестую времени, используемого НИС Мамдани, как показано в табл. 1. Оба метода линейно зависимы, так как увеличение числа запросов на доступ приводило к увеличению времени обработки.

Таблица 1

Характеристики моделей основе ННС и АННСВ предлагаемого метода оценки риска

Количество запросов на доступ	ННС с использованием алгоритма ЛМ		НИС Мамдани	
	Общее время, с	Время на один запрос, с	Общее время, с	Время на один запрос, с
100	1.438	0.01438	5.770.3	0.05773
1000	10.886	0.01089	57.396	0.05740
10000	81.557	0.00816	572.136	0.05721
20000	146.573	0.00733	1140.5	0.05703
30000	211.432	0.00705	1713.7	0.05712
40000	277.620	0.00694	2286.5	0.05716
50000	341.776	0.00683	2860.6	0.05721
60000	407.198	0.00679	3436.3	0.05727
70000	472.135	0.00674	4012.5	0.05732
80000	537.245	0.00671	4588.9	0.05736
90000	602.241	0.00669	5167.1	0.05741
100000	667.139	0.00667	5746.3	0.05746
125000	831.247	0.00665	7185.6	0.05748
150000	995.479	0.00664	8625.4	0.05750

Кроме того, результаты показали, что время на запрос доступа для модели на основе ННС с использованием алгоритма обучения ЛМ составило очень короткое время по сравнению со временем на запрос доступа,

выданный НИС Мамдани, как показано на рис. 5. Обученная модель на основе ННС с алгоритмом обучения ЛМ доказала, что она позволяет значительно сократить время на обработку.




Рис. 5. Время для одного запроса на доступ модели на основе ННС и НИС Мамдани

Нейро-нечеткая система и адаптивная нейро-нечеткая системы вывода

Модель АННСВ, предлагаемого метода оценки риска, была реализована для настройки различных функций принадлежности и определения наиболее подходящей из них. Выбранная функция принадлежности должна обеспечить наименьшую ошибку и наилучшим образом соответствовать процессу обучения для повышения быстродействия процесса оценки риска. Модель на основе АННСВ была обучена как гибридным методом обучения, так и методом обратного распространения при трех разных эпохах (20, 100 и 300). После обучения результаты экспериментов показали, что трапецевидная функция принадлежности с гибридным методом обучения при 20 эпохах является лучшей функцией принадлежности, которая позволяет получить наименьшую ошибку и наилучшим образом соответствует процессу обучения.

В данной работе модель на основе нейро-нечеткой системы, предлагаемого метода оценки риска, была обучена с использованием четырех алгоритмов обучения, чтобы уменьшить временные издержки, связанные с системой нечеткой логики, и добавить возможность обучения методу оценки риска для повышения

точности и эффективности процесса оценки риска. Было проведено несколько экспериментов, чтобы определить соответствующее количество нейронов в скрытом слое для каждого обучающего алгоритма. После сравнения корреляции четырех алгоритмов обучения и ошибок обучения, тестирования и проверки результаты показали, что использование алгоритма Левенберга-Марквардта выдает наименьшую ошибку и наилучшим образом соответствует процессу обучения.

Результаты, полученные после внедрения моделей на основе АННСВ и ННС предлагаемого метода оценки риска, были сопоставлены в табл. 2. Быстродействие модели на основе нейро-нечеткой системы лучше, чем у модели на основе адаптивной нейро-нечеткой системы вывода. Модель на основе ННС обеспечивает более низкие значения RMSE как в обучающих, так и в тестовых данных, что указывает на то, насколько близки наблюдаемые и прогнозируемые данные. При этом модель на основе ННС обеспечивает более высокую корреляцию 0.999 и 0.997 в R и R^2 соответственно, которая демонстрирует, что она наилучшим образом соответствует процессу обучения, поскольку значения R и R^2 максимально близки к 1.

Таблица 2

Характеристики моделей основе ННС и АННСВ предлагаемого метода оценки риска

Модель	RMSE обучения	RMSE проверки	R	R ²
Модель на основе ННС с алгоритмом Левенберга-Марквардта	0.999	1.114	0.999	0.997
Модель на основе АННСВ с трапецевидной функцией принадлежности	4.654	4.665	0.983	0.957

Основываясь на этих результатах, модель на основе нейро-нечеткой системы с методом обучения Левенберга-Марквардта является наилучшим подходом к реализации предложенной методики оценки рисков для повышения точности, сокращения времени обработки, необходимого для принятия решений о доступе, и адаптации к различным изменениям реальных приложений Интернета вещей.

Заключение

Результатом данной работы является реализация процесса оценки рисков с использованием нейро-нечеткой системы. ННС объединяет лингвистические переменные системы нечеткой логики с искусственной нейронной сетью для повышения точности и быстродействия. ННС была использована для сокращения времени обработки за счет параллельных вычислений ИНС и добавления возможности обучения в предложенной методике оценки рисков. Это позволяет методике адаптироваться к новым изменениям в среде Интернета вещей. Чтобы определить соответствующее количество нейронов в скрытом слое, модель на основе ННС была обучена с использованием метода обучения на основе алгоритма Левенберга-Марквардта. Было проведено несколько экспериментов для разного количества запросов на доступ. Полученные в ходе экспериментов значения MSE, RMSE и R для обучения, тестирования и проверки были использованы для определения соответствующего количества нейронов для модели на основе ННС. Результаты экспериментов показали, что алгоритм обучения ЛМ выдает наименьшую ошибку и самую высокую корреляцию, равную 0.999, результат которой указывает на то, что

модель на основе нейро-нечеткой системы хорошо обучена и соответствует процессу обучения. Помимо этого, модель на основе нейро-нечеткой системы с методом обучения алгоритма Левенберга-Марквардта показала, что она позволяет сократить время обработки, поскольку ей требуется только одна шестая времени, используемого системой нечеткой логики.

Таким образом, нейро-нечеткая система с методом обучения алгоритма Левенберга-Марквардта является наилучшим сочетанием для реализации предложенной методики оценки рисков. Она позволяет повысить точность системы, сократить время обработки, необходимого для принятия решений о доступе, и быть адаптированной к новым изменениям различных приложений Интернета вещей.

Список литературы

1. Jang, J. S. R. ANFIS: Adaptive- Network-Based Fuzzy Inference System. IEEE Transactions on Systems, Man and Cybernetics, 1993, no. 23(3), pp. 665–685.
2. Kar S., Das S., Ghosh P.K. Applications of neuro fuzzy systems: A brief review and future outline. Applied Soft Computing Journal, 2014, no. 15, pp. 243–259.
3. Jang J. R., Sun C., Mizutani E. Neuro-Fuzzy and Soft-Computing. Prentice Hall, Upper Saddle River, NJ, 1997.
4. Gray A. R., MacDonell S. G. A comparison of techniques for developing predictive models of software metrics. Information and Software Technology, 1997, no. 39(6), pp. 425–437.
5. Shaf J., Angelov P., Umair M. Prediction of the Attention Area in Ambient Intelligence Tasks. In: Sgurev V., Yager R., Kacprzyk J., Jotsov V. (eds) Innovative Issues in

Intelligent Systems. Studies in Computational Intelligence, Springer, Cham, 2016, vol 623.

6. Okut H. Bayesian Regularized Neural Networks for Small Big Data. Artificial Neural Networks - Models and Applications, 2016, pp. 28–48.

7. Werbos P. J. Beyond Regression: New Tools for Prediction and Analysis in the Behaviour Sciences. Harvard University, Cambridge, 1974.

8. White H. Artificial neural networks: approximation and learning theory. Cambridge, USA: Blackwell, 1992.

9. Kohonen T. Self-organized formation of topologically correct feature maps. Biological Cybernetics, 1982, no. 43(1), pp. 59–69.

10. Viharos Z. J., Kis K. B. Survey on Neuro-Fuzzy systems and their applications in technical diagnostics and measurement. Journal of the International Measurement Confederation, 2015, no. 67, pp. 126–136.

11. Vieira J., Dias F. M., Mota A. Neuro-Fuzzy Systems: A Survey. In: 5th WSEAS NNA International Conference on Neural Networks and Applications, 2004, pp. 1–6.

12. Abraham, Ajith. Neuro-Fuzzy Systems: State-of-the-art Modeling Techniques. International Work-Conference on Artificial Neural Networks, 2001, pp. 269–276.

13. Naidu D. S., Sun C. T. Neuro-Fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence. IEEE Transactions on automatic control, 1997, pp. 1520–1533.

14. Nauck D., Kurs R. Neuro-Fuzzy Systems for Function Approximation. 4th International Workshop Fuzzy-Neuro Systems, 1997.

15. Konaté A. A., Pan H., Khan N., Yang J. H. Generalized regression and feed-forward back propagation neural networks in modelling porosity from geophysical well logs. Journal of Petroleum Exploration and Production Technology, 2015, no. 5(2), pp. 157–166.

16. Hornik K., Stinchcombe M., White H. Multilayer feedforward networks are universal approximators. Neural Networks, 1989, no. 2(5), pp. 359–366.

17. Болгов А.А., Ермаков С.А., Парина Л.В., Баранников Н.И. Оценка риска безопасности в сетях интернета вещей. // Информация и безопасность: Регион. науч. - техн. журнал. – Воронеж, 2020. – Т. 23. – №4. – С. 561-566.

18. Al-Hmouz A., Jun Shen, Al-Hmouz R., Jun Yan. Modeling and Simulation of an Adaptive Neuro-Fuzzy Inference System (ANFIS) for Mobile Learning. IEEE Transactions on Learning Technologies, 2012, no. 5(3), pp. 226–237.

19. Gao P., Xue L., Lu Q., Dong C. Effects of alkali and alkaline earth metals on N-containing species release during rice straw pyrolysis. Energies, 2015, no. 8(11), pp. 13021–13032.

20. Saduf M., Wani A. Comparative Study of Back Propagation Learning Algorithms for Neural Networks. International Journal of Advanced Research in Computer Science and Software Engineering, 2013, no. 3(12), pp. 1151–1156.

21. Lourakis M. I. A., Argyros A. A. Is Levenberg-Marquardt the most efficient optimization algorithm for implementing bundle adjustment. In: Proceedings of the IEEE International Conference on Computer Vision, 2005, pp. 1526–1531.

22. Demuth H. B., Beale M. Neural Network Toolbox for Use with MATLAB, Users Guide. The Mathworks, Inc., Massachusetts, USA, 1998.

23. Pramanik N., Panda R. K. Application of neural network and adaptive neuro-fuzzy inference systems for river flow prediction. Hydrological Sciences Journal, 2009, no. 54(2), pp. 247–260.

24. Suparta W., Alhasa K. M. Adaptive Neuro-Fuzzy Interference System. In Modeling of Tropospheric Delays Using ANFIS, Springer International Publishing Inc, 2016, pp. 5-19.

Концерн «Созвездие», г. Воронеж
Concern «Sozvezdie», Voronezh

Воронежский государственный технический университет
Voronezh State Technical University

Поступила в редакцию 14.11.2022

Информация об авторах

Ермаков Сергей Александрович – канд. техн. наук, начальник отдела, АО «Концерн «Созвездие», e-mail: mnac@comch.ru

Болгов Андрей Александрович – аспирант, Воронежский государственный технический университет, e-mail: mnac@comch.ru

RISK ASSESSMENT USING A NEURO-FUZZY SYSTEM

S.A. Ermakov, A.A. Bolgov

The work proposes the use of a neuro-fuzzy system in the risk assessment methodology. A detailed review of the neuro-fuzzy system is carried out, highlighting the main properties of this system in the field of risk assessment methods. The types of neuro-fuzzy systems are considered. The main advantages of using a model based on a neuro-fuzzy system are given. An algorithm for implementing a neuro-fuzzy system into a risk assessment method is presented. A learning method based on the Levenberg-Marquardt algorithm is proposed. Various experiments were carried out using a model based on a neuro-fuzzy system using the selected learning algorithm for a different number of access requests. The obtained results of risk assessment experiments using a model based on a neuro-fuzzy system were compared with the results obtained using a model based on fuzzy logic. The results of the experiments were also compared with the results obtained using a model based on an adaptive neuro-fuzzy inference system.

Keywords: fuzzy logic, neuro-fuzzy system, learning, learning algorithm, artificial neural network, risk, Internet of Things.

Submitted 14.11.2022

Information about the authors

Sergey A. Ermakov – Cand. Sc. (Technical), Concern «Sozvezdie», Voronezh, Head of Department, e-mail: mnac@comch.ru

Andrey A. Bolgov – graduate student, Voronezh State Technical University, e-mail: mnac@comch.ru