

МОДЕЛИРОВАНИЕ И ПРОГНОЗИРОВАНИЕ ФИШИНГОВЫХ АТАК

В.А. Минаев, А.О. Фаддеев, Ю.В. Броненкова

В статье рассматриваются вопросы моделирования динамики фишинговых атак в киберпространстве Российской Федерации на основе рекуррентной нейронной сети. Поставлена и решена задача получения прогнозной информации о количестве атак подобного вида. Проведено исследование структуры динамического ряда фишинговых атак на предмет выявления в нём трендовой, сезонной и случайной составляющих. Рассмотрены два вида моделей, использованных при проведении прогностических оценок фишинговых атак – *LSTM*-модель и *Auto ARIMA*. Анализ результатов прогностических оценок убедительно свидетельствует о значительном преимуществе *LSTM*-модели. Точность прогноза, полученного с ее помощью, в среднем не более 6%. Делается вывод, что представляемый на данном этапе прогноз, основываясь на реально существующих, но пока не объясненных закономерностях реализации фишинговых атак, требует для своего уточнения более сложных математических моделей, учитывающих многих факторов, определяющих это новое криминальное явление. Рекуррентные нейронные сети при этом могут весьма полезными на первом этапе исследований и других видов киберпреступлений.

Ключевые слова: фишинговая атака, моделирование, прогнозирование, рекуррентная нейронная сеть, *LSTM*-модель.

Введение

Преступность является одной из острейших проблем современности, оказывающей существенное негативное влияние на многие сферы жизнедеятельности современного общества. Достаточно указать на такие серьёзные угрозы и тяжёлые последствия для него, как разрушение социальных связей, ухудшение общественного климата, формирование обстановки страха и неуверенности, снижение безопасности граждан, экономический ущерб, потеря доверия к государственным институтам [1].

В то же время, повсеместное внедрение новых информационных технологий и стремительная цифровизация общества создают благоприятные обстоятельства для дополнительного осложнения обстановки в связи с развитием киберпреступности [2].

Растёт число кибератак, цель которых – не только получить конфиденциальную информацию или дестабилизировать работу того или иного предприятия, но и расшатать сами устои современного российского государства [3].

Спектр кибератак включает фишинговые атаки, методы социальной инженерии,

использование вредоносного программного обеспечения, атаки, базирующиеся на эксплуатации уязвимостей программного обеспечения (ПО), а также другие криминальные способы применения информационно-телекоммуникационных технологий [3]. Поэтому защита информационных систем, баз и банков данных, персональной информации выступают приоритетными задачами в контексте обеспечения безопасности как государства и общества, так и каждого его гражданина [4, 5].

Рассмотреть в одной статье вопросы, связанные с оценками всего спектра киберугроз нереально, поэтому уделим внимание только фишинговым атакам, являющимися доминирующим видом киберпреступлений в России [3].

Фишинг (от англ. fishing – выуживать) определяется как вид кибератаки, используемой членами криминальной среды для организации доступа к информации конфиденциального характера юридического или физического лица, с целью получения данных о логине или пароле электронной почты, о закрытых финансовых атрибутах (счета, номера банковских карт,

осуществленные транзакции), промышленной тайне или персональной информации.

При этом злоумышленники активно манипулируют такими эмоциями человека, как страх и любопытство, используя открытые источники для сбора информации о том или ином индивиде. Именно человеческий фактор становится доминирующим в цепочке «приманка – забрасывание удочки – подсечка» в фишинговых атаках, доводя в утечке данных ее успешность до 90%.

Конечно, организации и конкретные пользователи могут распознавать и блокировать фишинговые атаки с помощью различных программ, фильтров спама и других современных инструментов. Но фишинг-технологии стремительно развиваются, интегрируясь с социальной инженерией, и это требует более глубоких научных исследований явления, разработки более эффективных способов практического противодействия электронному криминалу.

Весьма перспективным направлением в этом отношении выступают программы-имитаторы фишинговых атак, позволяющие воспроизводить разные сценарии их реализации и дающие возможность повышать осведомленность пользователей, выявлять среди них наиболее уязвимых, нуждающихся в дополнительном индивидуальном обучении.

Среди таких программ-имитаторов известны Phished AI, Gophish, SafeTitan, Phishing box и ряд других. Это автоматизированные программные системы моделирования, которое обеспечивают оценку риска поведения сотрудников, целенаправленно обучать наиболее уязвимых из них определению вредоносных файлов и ссылок. Некоторые из программ-имитаторов, например, Phished AI, используют технологии искусственного интеллекта для разработки персонализированных тренингов.

Однако, несмотря на появление инструментов подобного рода, необходимо существенно углублять осведомленность пользователей о безопасности в борьбе с фишингом. Одним из способов предотвращения угроз и рисков фишинга выступает их моделирование с учетом

интенсивно развивающихся факторов, определяющих это опасное социально-экономическое явление.

Постановка задачи

Одним из важных аспектов превентивной оценки фишинговых атак является получение данных о том, каков характер её динамики применительно к киберпространству России. Для оценки к динамическому ряду, отражающему количественные значения фишинговых атак в стране, следует применить довольно развитый аппарат статистического анализа [6].

В таком случае задача прогнозирования представляет собой получение на основе имеющихся последовательных данных о фишинговых атаках в прошлом, прогнозной информации об их количестве на заранее определённом временном интервале упреждения.

В качестве такого интервала выбран первый квартал 2025 года. Этот выбор обусловлен тем, что на момент проведения исследований уже имелась необходимая информация для подтверждения точности прогнозирования о количестве фишинговых атак, произошедших в указанный период времени.

Первой процедурой, которая произведена с динамическим рядом фишинговых атак, является выявление в нём случайной и детерминированной компонент [7].

После определения структуры динамического ряда, необходимо определиться с видом моделей, которые следует использовать для получения прогнозной информации [8].

Далее следует этап непосредственных прогностических оценок по отобранным моделям количества фишинговых атак на определённом временном интервале.

Наконец, на заключительном этапе необходимо произвести сравнительный анализ прогнозной информации, полученной на основе различных моделей.

Согласно представленной краткой методике, решим задачу прогнозирования на реальных данных количества фишинговых атак в киберпространстве страны.

Теоретические модели

При оценке структуры динамического ряда фишинговых атак использована модель, в которой значение $Y(t_i)$ предопределяется значениями $Y(t)$ в предыдущие моменты времени [9]:

$$Y(t_i) = f[Y(t_{i-1}), Y(t_{i-2}), \dots] + \varepsilon(t_i),$$

где $\varepsilon(t_i)$ – случайная составляющая.

Степень статистической связи между последовательностями $Y(t_1), Y(t_2), \dots, Y(t_n)$ и $Y(t_{1+l}), Y(t_{2+l}), \dots, Y(t_{n+l})$ (сдвинутых относительно друг друга на l моментов времени, или, как говорят, с лагом l) может быть определена с помощью коэффициента автокорреляции. Для этого необходимо вычислить значения автокорреляционной функции ряда по формуле [9, 10]:

$$r(l) = \frac{(n-l) \sum_{i=1}^{n-l} y_i y_{i+l} - \left(\sum_{i=1}^{n-l} y_i \right) \cdot \left(\sum_{i=1}^{n-l} y_{i+l} \right)}{\sqrt{(n-l) \sum_{i=1}^{n-l} y_i^2 - \left(\sum_{i=1}^{n-l} y_i \right)^2} \cdot \sqrt{(n-l) \sum_{i=1}^{n-l} y_{i+l}^2 - \left(\sum_{i=1}^{n-l} y_{i+l} \right)^2}}$$

где l – величина лага,

n – длина динамического ряда.

Требуется проверить значимость отдельно взятых коэффициентов и всей их совокупности [6]. Значимость отдельного коэффициента определим по формуле [10]:

$$-1.96 \cdot \frac{1}{\sqrt{n}} \leq r_l \leq 1.96 \cdot \frac{1}{\sqrt{n}} \quad (1)$$

Значимость всей совокупности коэффициентов автокорреляции конкретного динамического ряда проверяется по Q -критерию Бокса-Пирса [6]:

$$Q = n \cdot \sum_{i=1}^m r_i^2 \approx \chi^2(m), \quad (2)$$

где m – максимальный рассматриваемый лаг.

Статистика (2) имеет распределение χ^2 с m степенями свободы, и поэтому в случае, когда расчетное значение Q превосходит критическое значение χ^2 , то вся группа

коэффициентов для лагов, не превосходящих m , считается значимой [11].

Для анализа структуры динамического ряда применялась аддитивная модель вида [6, 9]:

$$Y(t_i) = q(t_i) + \varepsilon(t_i), \quad i = 1, 2, \dots, n, \quad (3)$$

где $q(t_i)$ детерминированная составляющая включает трендовую и сезонную компоненты.

С целью прогнозирования фишинговых атак использована рекуррентная нейронная сеть *LSTM* (*Long Short-Term Memory*) [12], специально разработанная для обработки длинных динамических последовательностей данных. *LSTM* отличается от классических рекуррентных нейронных сетей использованием управляющих механизмов – ворот забывания (*forget gate*), входных ворот (*input gate*) и выходных ворот (*output gate*) [13]. Управляющие механизмы описываются уравнениями, регулирующими поток информации о прошлом и выводящими ее из обработки по мере старения.

Теперь охарактеризуем модели, которые использовались для сравнения результатов получения прогнозной информации.

В первую очередь, выбрана модель прогнозирования *ARIMA*, представляющая собой комбинацию двух моделей, используемых для анализа динамических рядов: авторегрессионную модель (*AR*-модель) и модель скользящего среднего (*MA*-модель) [14].

Помимо классической модели *ARIMA* рассмотрены две её модификации – *SARIMA* и *Auto ARIMA* [14]. Важной особенностью модели *SARIMA* является то, что она учитывает сезонность, что делает её особенно эффективной при анализе последовательных данных с выраженной периодичностью.

В отношении модификации *Auto ARIMA* отметим, что она обеспечивает автоматизацию подбора параметров, позволяющую избежать их ручного перебора при выполнении прогностических оценок, что значительно сокращает временные затраты при расчетах.

Отметим такие важные элементы, необходимые для обучения нейронной сети, как функцию потерь и метод оптимизации. В

качестве функции потерь использована среднеквадратическая ошибка:

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2,$$

где y_i и $\hat{y}_i$ – истинное и предсказанное значения;

m – число точек сравнения на интервале прогноза.

Для оптимизации выбран метод *Adam*, сочетающий преимущества методов *AdaGrad* и *RMSProp*.

Экспериментальные результаты

На первом этапе экспериментальных исследований поквартального количества фишинговых атак в России за период 2019 – 2024 гг. (рис. 1), выполнен расчёт значений автокорреляционной функции (рис. 2) и произведена оценка значимостей коэффициентов автокорреляции на основании выражений (1) и (2).

Количество значимых коэффициентов – два из восемнадцати, при этом значение максимального коэффициента из них составляет 0.704.




Рис. 1. Исходный динамический ряд количества фишинговых атак




Рис. 2. Коррелограмма распределения фишинговых атак. Ломаной линией обозначены средние значения автокорреляционной функции

Таблица 1

Значения сезонной компоненты
для динамического ряда фишинговых атак

Год	Номер квартала			
	I	II	III	IV
2019	0	0	-208,75	-5,88
2020	49,13	133,88	-288,13	-8,63
2021	-24	-86,25	737	-123
2022	-555,63	-620,63	1891,75	-1412,38
2023	533,13	39,25	-141	-12,5
2024	-131,5	237,25	0	0

Таблица 2

Скорректированные значения
сезонной компоненты

Квартал	I	II	III	IV
Скоррект. оценка	-10,8	-24,8	165,9	-130,3
Итоговая сумма	0			

График сезонных колебаний
фишинговых атак на временном интервале
2023-2024 гг. приведён на рис. 3.




Рис. 3. Сезонная компонента для фишинговых атак

Исходя из графика, представленного на рис. 3, можно заключить, что максимальная активность фишинговых атак приходится на июль-сентябрь. С чем это связано?

Можно предположить, что фишинговые атаки наиболее интенсивны в период отпусков наибольшего количества россиян, когда они получили отпускные, накопили

перед отпуском больше средств, планируя различные туристские, развлекательные и иные поездки, отложенные дела – ремонт квартир, дач, автотранспорта и т.д.

Но это, заметим, только предположения, требующие своего исследования и фактического подтверждения. В этой связи подчеркнем, что представляемый в статье прогноз на данном этапе основывается на внутренних, реально существующих, но пока не объясненных закономерностях реализации фишинговых атак. Которые определяются

целым комплексом факторов, требующих своего учета в специальных, довольно сложных математических моделях. Как, впрочем, и другие виды киберпреступлений, возникшие в качестве новых явлений в современном криминальном мире.

Далее, элиминируя влияние сезонной компоненты, посредством вычитания её значений из исходного динамического ряда, получим в каждый момент времени данные, содержащие для этого ряда трендовую (рис. 4) и случайную компоненты (рис.5).




Рис. 4. Трендовая компонента динамического ряда фишинговых атак

Судя по трендовой компоненте на рис. 4., взлёт числа фишинговых атак наблюдался в 2024 году при общей тенденции роста их количества на протяжении 2020-2022 гг. Вопрос о том, произойдёт ли значительный рост количества этих инцидентов в 2025 или в 2026 годах, остаётся пока открытым.

Для этого необходимы дальнейшие исследования динамики этого вида кибератак. Обратимся к результатам моделирования динамики фишинговых атак на основе использования рекуррентной нейронной сети *LSTM*.




Рис. 5. Случайная компонента динамического ряда фишинговых атак

Программное исполнение модели выполнено на языке *Python*. При этом для выполнения прогностических оценок применен ряд стандартных библиотек. Результаты прогностических оценок представлены на рис. 6. Линией синего цвета на рис. 6

обозначены фактические данные исходного динамического ряда фишинговых атак за первые три месяца 2025 года, линией красного цвета – значения количества фишинговых атак, полученные на основании прогностических оценок по *LSTM*-модели.




Рис. 6. Реальная динамика и прогноз фишинговых атак в первом квартале 2025

Точность прогноза в среднем составляет 5.95%, то есть прогнозные и реальные данные о количестве фишинговых атак в первый квартал 2025 года весьма близки между собой. Отметим при этом, что прогноз фишинговых атак, выполненный на основании *LSTM*-модели значительно превышает точность модели *Auto ARIMA* и моделей, базирующихся на аппарате обычной экстраполяции.

Выводы и обсуждение

В статье поставлена и решена задача прогнозирования фишинговых атак в киберпространстве Российской Федерации. Для этого проведено исследование структуры динамического ряда фишинговых атак, показано, что он четко подразделяется на трендовую, сезонную и случайную компоненты.

При проведении прогностических оценок фишинговых атак использовалась рекуррентная нейронная сеть *LSTM*, обладающая развитыми механизмами постепенного забывания прошлой информации и замещения ее актуальной.

Это дало возможность с высокой точностью (5.95%) по сравнению с моделью

ARIMA и моделями аппроксимационного характера осуществлять краткосрочные прогнозы фишинговых атак.

Заключение

Развиваемые в статье подходы ориентированы на построение системы моделей прогнозирования кибератак, позволяющих на первом этапе использовать нейросетевые модели типа *LSTM* для формирования рабочих гипотез относительно факторного комплекса, определяющего сложные взаимодействия при реализации криминальных явлений в современном информационно-телекоммуникационном пространстве, позволяя затем перейти ко второму этапу – аналитического и имитационного моделирования в сфере противодействия компьютерным атакам в Российской Федерации.

При этом надо понимать, что сегодня отмечается существенное усложнение кибератак, как инструментальное, так и сценарное с появлением множества новых качеств стратегического и тактического характера, а именно:

- за счет предварительной интеллектуальной разведки вторжения

становятся подготовленными, тем самым повышая вероятность успеха и потенциальный ущерб от реализации атаки;

- сочетание множества техник и векторов вторжения атаки становятся многоуровневыми и используют искусственный интеллект;

- машинное обучение не успевает за темпом появления уязвимостей нулевого дня, особенно в части средств искусственного интеллекта.

К тому же, интенсивное применение в противоборстве искусственного интеллекта и средств автоматизации эксплуатации уязвимостей значительно усложняет выработку эффективных мер противодействия атакам злоумышленника, которые становятся все более разнообразными, адаптируясь под известные системы обеспечения информационной безопасности.

Переход сценариев атак от простых к многоэтапным произошел из-за активного развития средств защиты информации, дабы повысить эффективность вторжения на много увеличивая шанс достижения цели. Буквально несколько лет назад сценарии атак ограничивались простым фишингом или DDoS, но за последние годы реализация таких атак перестала приносить успех вследствие разработки эффективных мер обнаружения и реагирования на инциденты информационной безопасности. Это повлекло за собой переход атакующих к более совершенным и продуманным методам атаки, которые позволяют злоумышленникам достигать своей цели с наибольшей вероятностью успеха, так как искусственный интеллект генерирует сценарии кибератаки, который позволяет совершать последовательные продуманные действия, начиная от разведки и проникновения в сеть и заканчивая хищением данных и даже уничтожением системы.

Атаки, основанные на искусственном интеллекте, являются скрытными и адаптивными, так как допускают изменения атакующих техник злоумышленника в реальном времени, в зависимости от реакции систем обеспечения информационной безопасности и применяемых мер противодействия.

Здесь одним из главных факторов усложнения атак является развитие искусственного интеллекта и машинного обучения, что позволяет злоумышленникам автоматизировать рутинные процедуры и также разрабатывать новые методы, тем самым повышая их эффективность, скрытность и масштабируемость, что значительно увеличивает уровень угрозы, как для обычных пользователей, так и для крупных организаций. Наиболее важными и популярными являются следующие направления применения искусственного интеллекта в проведении кибератак:

- целенаправленность атаки: при помощи искусственного интеллекта злоумышленники все чаще подготавливаются к атакам на конкретные организации, что достигается путем нейросетевого анализа большого объема открытых данных об объекте, выявляя уязвимых сотрудников, их интересы, круг общения и другую важную информацию, которая позже будет применена для атаки средствами соинженерии;

- эксплуатация уязвимостей: с помощью машинного обучения для злоумышленника раскрываются большие возможности в области анализа программного обеспечения атакуемых организаций с целью выявления уязвимостей для последующей эксплуатации слабостей системы в ходе атаки;

- адаптивность атаки: искусственный интеллект, обрабатывая информация о текущем ходе выполнения сценария и реакции систем безопасности организации, имеет возможность быстрого анализа ситуации и принятию верных решений, которые приведут атакующего к наибольшей вероятности успеха.

Обобщая вышеизложенное, можно утверждать, что противодействие современным кибератакам, в том числе и фишинговым, не представляется возможным без активного и всестороннего внедрения искусственного интеллекта и машинного обучения.

Список литературы

1. Лунеев, В. В. Преступность XX века: мировые, региональные и российские тенденции: Монография / В. В. Лунеев. 2-е

- изд., переработанное и дополненное. М.: Норма, 2021. 912 с.
2. Авсентьев А.О., Винокуров С.А., Минаев В.А. и др. Основы кибербезопасности: Учебник. М.: ГУРПС МВД России, 2024. 408 с.
 3. Минаев В. А., Бондарь К. М., Андреев А.А. Терроризм и экстремизм: моделирование информационного противодействия: Монография. Хабаровск: РИО ДВЮИ МВД России, 2020. 248 с.
 4. О Стратегии национальной безопасности Российской Федерации / Указ Президента Российской Федерации от 02.07.2021 № 400. Доступ из справочной правовой системы «КонсультантПлюс».
 5. О Стратегии развития информационного общества в Российской Федерации на 2017-2030 годы / Указ Президента Российской Федерации от 09.05.2017 № 203. Доступ из справочной правовой системы «КонсультантПлюс».
 6. Кильдишев Г.С., Френкель А.А. Анализ временных рядов и прогнозирование. Издание 2-е. М. URSS, 2021. 101 с.
 7. Бриллинджер Д. Р. Временные ряды: обработка данных и теория / Пер. с англ. А. В. Булинского, И. Г. Журбенко. М.: Мир, 1980. 536 с.
 8. Нильсен Эйлин. Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение. М., СПб.: Диалектика, 2021. 538 с.
 9. Shumway R.H., Stoffer D.S. Time Series Analysis and Its Applications. With Examples. Second edition. New York: Springer, 2006. 576 p.
 10. Плотников А.Н. Элементарная теория анализа и статистическое моделирование временных рядов. 2-е изд., исправленное и дополненное. СПб.: Лань, 2021. 212 с.
 11. Гмурман В.Е. Теория вероятностей и математическая статистика: Учебник для вузов. 12-е издание. М.: Издательство Юрайт, 2024. 479 с.
 12. Brownlee J. Time Series Prediction with LSTM Recurrent Neural Networks in Python with Keras. Machine Learning Mastery. 2016. URL: <https://machinelearningmastery.com/time-series-prediction-lstm-recurrent-neural-networks-python-keras> (дата обращения 21.09.2025).
 13. Deep Learning Memory Option by Alex Nguyen. URL: <https://dev.to/alex-nguyen-duyanh/deep-learning-memory-option-by-alexnguyen-2ha6> (дата обращения 21.09.2025).
 14. Кратович П.В. Нейронные сети и модели АРИМА для прогнозирования котировок // Программные продукты и системы. 2011. №1. С. 95-98.

Московский университет МВД РФ им. В.Я. Кикотя
Moscow University of the Ministry of Internal Affairs of Russia

Академия управления МВД России
The Academy of Management of the Ministry of Internal Affairs of Russia

Поступила в редакцию 10.09.25

Информация об авторах

Минаев Владимир Александрович – д-р техн. наук, профессор, профессор кафедры специальных информационных технологий, Московский университет МВД РФ им. В.Я. Кикотя, Москва, e-mail: mlva@yandex.ru

Фаддеев Александр Олегович – д-р техн. наук, доцент, профессор кафедры экономической безопасности Рязанского филиала, Московский университет МВД РФ им. В.Я. Кикотя, Москва, e-mail: fao1@mail.ru

Броненкова Юлия Васильевна – заместитель начальника кафедры информационных технологий Академии управления МВД России, e-mail: bronenkova87@mail.ru

MODELING AND FORECASTING PHISHING ATTACKS

V.A. Minaev, A.O. Faddeev, Yu.V. Bronenkova

The article discusses the issues of modeling the phishing attacks dynamics in the cyberspace of the Russian Federation based on a recurrent neural network. The task of obtaining predictive information about the number of attacks of this type has been set and solved. A study of the dynamic series structure of a phishing attacks has been conducted to identify its trending, seasonal and random components. Two types of models used in predictive assessments of phishing attacks are considered: the LSTM model and Auto ARIMA. The analysis of the predictive assessments results strongly indicates the significant advantage of the LSTM model. The accuracy of the forecast obtained with its help is on average no more than 6 %. It is concluded that the forecast presented at this stage, based on the actual, but not yet explained patterns of phishing attacks, requires more complex mathematical models for its refinement, taking into account many factors determining this new criminal phenomenon. Recurrent neural networks can be very useful on the first stage of research on other types of cybercrime.

Keywords: phishing attack, modeling, forecasting, recurrent neural network, LSTM model.

Submitted 10.09.25

Information about the authors

Vladimir A. Minaev – Dr. Sc. (Technical), Professor, Professor of the Special Information Technologies Department, V. Ya. Kikot Moscow University of the Ministry of Internal Affairs of Russia, Moscow, e-mail: mlva@yandex.ru

Alexander O. Faddeev – Dr. Sc. (Technical), Associate Professor, Professor of the Economic Security Department of the Ryazan Branch, V. Ya. Kikot Moscow University of the Ministry of Internal Affairs of Russia, Moscow, e-mail: faol@mail.ru

Julia V. Bronenkova – Deputy Head of the Information Technology Department of the Academy of Management of the Ministry of Internal Affairs of Russia, Moscow, e-mail: bronenkova87@mail.ru