

АТАКУЕМЫЕ СРЕДСТВА ИСКУССТВЕННОГО ИНТЕЛЛЕКТА: ПОСТРОЕНИЕ РИСК-ШАНС ЛАНДШАФТА СЦЕНАРИЕВ АТАК НА ИНФОРМАЦИОННО-ТЕЛЕКОММУНИКАЦИОННЫЕ СИСТЕМЫ

В.П. Лось, Д.А. Нархов, В.В. Молокеедова, Я.С. Федюков, П.Д. Чунта

В статье описывается методика оценки шанса успешного внедрения мер защиты информации и трехмерный риск-шанс ландшафт для анализа атак на средства искусственного интеллекта в информационно-телекоммуникационных системах. Ландшафт объединяет три ключевых измерения: вероятность реализации атакующей техники (шанс успешного внедрения мер), конкретные техники атак, включая описанные в фреймворке MITRE ATLAS, и применяемые меры по защите информации. Модель обеспечивает визуальное представление критических зон, где высока вероятность успеха атаки при слабой защите. Это позволяет структурировать угрозы, объективно сравнивать контрмеры и выстраивать обоснованную стратегию защиты ИИ-компонентов на всех этапах их жизненного цикла – от проектирования до эксплуатации и реагирования на инциденты.

Ключевые слова: искусственный интеллект, информационно-телекоммуникационные системы, шанс, риск, оценка, анализ, информационная безопасность

Введение

В условиях стремительного развития технологий искусственного интеллекта (ИИ) в информационно-телекоммуникационных системах (ИТКС) усложняются структура обрабатываемых данных и количество уникальных пакетов сетевого трафика, что характеризует новые возможности нарушителя для реализации атак [1-3].

Особое внимание стоит обратить на расширение спектра потенциальных целей для направленных атак, осуществляемых в отношении ИИ-моделей и среды, где они функционируют. Нарушители обладают развитыми методами, стремятся эксплуатировать уязвимости в различных средах, что приводит к повышению вероятности возникновению ущерба.

Параллельно с технологиями развиваются способы и методы, используемые нарушителями в ходе реализации атак на средства искусственного

интеллекта, что безусловно отражается в повышении величины риска обеспечения информационной безопасности (ИБ).

В связи с этим, организация должна грамотно оценить целесообразность внедрения средств и методов обеспечения защиты информации, что предоставит возможность определить шанс успешной имплементации мер. Для этого необходимо правильно оценить возможные последствия реализации атак, учитывая вышеизложенные аргументы, создаются условия для построения риск-шанс ландшафта.

Исследование проведено с целью повышения защищённости ИТКС за счет оценки риска реализации сценариев атак [4-5] и шанса успешного внедрения мер и защиты от них. Ландшафт позволит описать противостояние между стороной защиты и нарушителем, что поможет выявить потенциальные потери организации в случае реализации атаки и внедрения методов обеспечения безопасности.

Классификация мер по защите информации и оценка шанса их успешного внедрения

Для оценки шанса успешного внедрения мер по защите информации необходимо рассмотреть их классификацию. В рамках настоящего исследования рассматриваются три категории мер, соответствующие этапам жизненного цикла инцидента — до, во время и после реализации атак. Такая классификация развивает подходы, предложенные ранее в работах по организационно-правовой защите сетей и картографии защищаемого киберпространства [1-3].

Каждая категория подразделяется на организационно-правовые и технические компоненты:

Превентивные меры направлены на снижение вероятности возникновения инцидента до его реализации. Они включают:

- организационно-правовые: составление политик безопасности, регламентация процессов, обучение сотрудников, составление матриц доступа и риска, а также совершенствование методов сбора данных об актуальных угрозах;

- технические: системы обнаружения вторжений, межсетевое экранирование, управление привилегированным доступом, анализ сетевого трафика и системы управления событиями и информацией (SIEM).

Реактивные меры активируются при выявлении или подозрении на инцидент. Они включают:

- организационно-правовые: информирование сотрудников, привлечение внешних экспертов, а также создание планов реагирования;

- технические: идентификация угроз, мониторинг SOC, автоматизированное реагирование на инциденты, изоляция ресурсов, изменение аутентификационных данных и управление идентификацией и доступом.

Меры по ликвидации последствий призваны восстановить систему до предшествующего состояния, нарушенного нарушителем. Такие меры, зачастую, направлены на переоценку возможностей реализации подобных атак в целях повышения качества обнаружения и предотвращения реализуемых нарушителями техник, включая реагирование на них. Меры по ликвидации последствий включают:

- организационно-правовые: аудит информационной безопасности, расследование инцидента, уведомление регуляторов, в частности, ФСТЭК и ФСБ, проведение учений и совершенствование методов анализа;

- технические: полное устранение уязвимостей ПО, удаление вредоносного ПО, восстановление данных, перенастройка средств защиты и эксплуатация уязвимостей в изолированной среде.

Такая классификация (рис.1) позволяет систематизировать данные по средствам защиты, что является необходимым условием для корректной оценки метрики «шанса» и построения трёхмерного риск-шанс ландшафта.

Все перечисленные носят ситуативный характер, ибо их внедрение осуществляется только в ответ на конкретную угрозу или уже произошедший инцидент, что делает их ключевыми элементами динамической модели управления безопасностью ИТКС.

Шанс успешного внедрения меры защиты информации в ИИ-системах определяется как количественная метрика, отражающая ожидаемую эффективность принятия решения о реализации данной меры. Его предлагается рассчитывать по следующей формуле:

$$Chans = D \times v, \quad (1)$$

где D — разница между компенсирующим ущербом и средней стоимостью внедрения меры

$$D = U - M, \quad (2)$$




Рис. 1. Классификация мер по защите информации

M – средняя стоимость внедрения меры защиты информации, выраженная в десятках тысяч рублей. Для технических решений стоимость включает лицензирование, настройку и интеграцию в ML-конвейер. Для организационных мер стоимость рассчитывается по медианной зарплате специалиста по защите информации;

ν – частота использования конкретной меры, которая показывает, насколько востребована мера на практике.

Частоту использования рассчитаем по формуле:

$$\nu = \frac{N_m}{N_n}, \quad (3)$$

где N_m – количество внедрений меры, т. е. примерное число зафиксированных внедрений определенной меры;

N_n – общее количество подразделений, т. е. общее число организаций, в которых потенциально возможно применение данного класса мер.

Таким образом, «шанс» внедрения определенной меры принимает вид:

$$Chans = (U - M) \times \frac{N_m}{N_n}. \quad (4)$$

В случае, когда величина D принимает отрицательное значение, имеет место неэффективность мер по ЗИ, поскольку затраты на её внедрение превышают компенсирующий ущерб. Если значение D принимает значение гораздо больше M , это указывает на высокую целесообразность реализации меры.

Формирование риск-шанс ландшафта сценариев атак

Построение риск-шанс ландшафта в рамках исследования иллюстрируется на примере атаки «Небезопасная обработка вывода модели» (Improper Output Handling), которая не направлена на компрометацию самой большой языковой модели (LLM), а эксплуатирует некорректную обработку её

вывода внешними компонентами системы. Когда сгенерированный моделью текст автоматически вставляется без фильтрации в HTML, SQL, командную строку, API или другие интерфейсы, нарушитель может заставить LLM выдать вредоносный или манипулирующий контент, что к нарушению целостности, конфиденциальности или доступности машинного обучения (МО).

Атака реализуется через подбор специальных промптов, провоцирующих модель на генерацию опасного вывода, который при последующей интерпретации системой вызывает нежелательные последствия от XSS и SQL-инъекции до выполнения произвольного кода.

В сценарии атаки используются следующие техники из фреймворка MITRE ATLAS [6]:

– AML.T0063 «Обнаружение результатов модели ИИ». Злоумышленник анализирует, как система использует вывод LLM, чтобы выявить случаи прямой интерпретации без экранирования или фильтрации;

– AML.T0005.001 «Продукт или услуга с использованием МО». Через множественные запросы атакующий изучает паттерны генерации модели и собирает данные для дальнейшего моделирования её поведения;

– AML.T0047 «Создание прокси-модели через репликацию». На основе собранных «запрос–ответ» пар строится упрощённая имитационная модель, позволяющая безопасно тестировать вредоносные промпты.

– AML.T0043 «Создание атакующих данных». Во время использования прокси-модели разрабатываются входные данные, заставляющие LLM генерировать конструкции, опасные при последующей обработке (например, скрипты, команды, SQL);

– AML.T0015 «Обход модели МО». На финальном этапе злоумышленник отправляет целевой запрос в реальную систему; а LLM выдаёт вредоносный вывод, который

успешно проходит вектор обработки и приводит к компрометации.

Данные техники формируют логическую цепочку атаки, привязанную к уязвимостям (CVE).

Для оценки эффективности мер защиты на каждом этапе были рассчитаны метрики риска реализации атаки [4-5] и шанса успешного внедрения временных мер (4): превентивных, реактивных и ликвидирующих последствия. Результаты этих расчётов представлены в табл. 1.

Таблица 1

Результаты оценки риска и шанса для каждого сценария

Техника	Risk [4-5]	Chans(пр)	Chans(p)	Chans(лп)
AML.T0063	0,0530	0,058	0,12	0,23
AML.T0047	0,2008	0,36	0,24	0,43
AML.T0005.001	0,5651	0,71	0,59	0,58
AML.T0043	0,0873	0,153	0,053	0,047
AML.T0015	0,0938	0,09	0,15	0,11

Полученные в табл. 1 значения риска и шансов легли в основу построения трёхмерного риск-шанс ландшафта, т. е. визуально-аналитической модели, отражающей противоборства между действиями нарушителя и мерами защиты. Ландшафт формируется в трёхмерном пространстве и представлен на рис. 2.

На рис. 2 следующие обозначения осей:

– ось X представляет собой техники реализации атаки согласно фреймворку MITRE ATLAS [6] (например, AML.T0063 «Обнаружение результатов модели ИИ», AML.T0043 «Создание атакующих данных» и др.). Каждый столбец на этой оси соответствует отдельному этапу атаки;

– ось Y отражает количественные метрики риска и шанса. Риск (Risk) оценивает ожидаемый ущерб от успешной эксплуатации уязвимостей на данном этапе (серый цвет), а шанс (Chans) — целесообразность и эффективность внедрения защитных мер

(черный). Таким образом, для каждой техники на оси Y отображаются два ключевых значения: потенциальный вред и потенциальная выгода от защиты;

– ось Z моделирует категории защитных мер, соответствующих стадиям жизненного цикла инцидента.

Анализ построенного риск-шанс ландшафта выявляет критическую ситуацию на этапе AML.T0043 «Создание атакующих данных», где риск превышает шанс реактивных и постинцидентных мер. Это означает, что реагирование на инцидент после его обнаружения оказывается экономически и практически менее эффективным, чем профилактика. В таких условиях организациям целесообразно смещать фокус своей защиты на более ранние этапы, в частности, усиливать превентивные меры.




Рис. 2. Риск-шанс ландшафт сценариев атак

Заключение

В ходе данного исследования была разработана методика оценки риска сценариев атак и шанса успешного внедрения мер по защите информации на средства искусственного интеллекта, интегрированные в информационно-телекоммуникационные системы. Предложенный подход позволяет не только количественно оценивать риски, связанные с эксплуатацией уязвимостей ИИ-инфраструктуры, но и измерить экономическую и практическую целесообразность внедрения соответствующих мер защиты.

Ключевым достижением работы стало объединение вероятностной модели риска [4-5] (на основе нормализованных значений

EPSS и удельного ущерба) с оценкой «шанса», т. е. метрики, отражающей соотношение предотвращаемого ущерба, стоимости и востребованности защитных мер. Тем самым предлагается комплексный взгляд на проблему обеспечения информационной безопасности: от анализа угроз до принятия обоснованных управленческих решений.

Построенный риск-шанс ландшафт, визуализирующий взаимосвязь между потенциальными потерями и эффективностью контрмер, может служить практическим инструментом для специалистов по кибербезопасности, особенно в отношении специфических угроз, направленных на ИИ-системы.

Список литературы

1. Остапенко Г.А. Развитие и автоматизация методик организационно-правовой защиты сетей в контексте риск-анализа кибератак / Г.А. Остапенко, А.П. Васильченко, А.А. Остапенко, Е.А. Москалева, В.И. Белоножкин, Б.Г. Смирнов // *Информация и безопасность*. 2025. Т. 28. Вып. 1. С. 95-102.
2. Картография защищаемого киберпространства / Остапенко А. Г. [и др.]; Под ред. чл.-корр. РАН Д. А. Новикова. – М.: Горячая линия – Телеком, 2022. 372 с. (Серия «Теория сетевых войн»; Вып. 7).
3. Нархов Д.А. Атакуемые средства машинного обучения: автоматизация риск-анализа процессов реализации сценариев / Д.А. Нархов, Д.В. Кульшин, К.В. Козина, М.А. Неменуший // *Информация и безопасность*. 2025. Т. 28. Вып. 2. С. 237-242.
4. EPSS (Exploit Prediction Scoring System). https://www.first.org/epss/?spm=a2ty_o01.29997173.0.0.71665171B6r6D7 (дата обращения: 04.12.2025).
5. Калькулятор Common Vulnerability Scoring System v4.0. – Электрон. дан. – Режим доступа: <https://www.first.org/cvss/calculator/4-0>. URL: (дата обращения: 04.12.2025).
6. MITRE ATLAS (Adversarial Threat Landscape for AI Systems) URL: https://atlas.mitre.org/pdf-files/SAFEAI_Full_Report.pdf (дата обращения: 04.12.2025).

Российский государственный гуманитарный университет
Russian State University for the Humanities

Воронежский государственный технический университет
Voronezh State Technical University

Поступила в редакцию 7.12.2025

Информация об авторах

Лось Владимир Павлович – д-р воен. наук, профессор, Российский государственный гуманитарный университет, e-mail: alexanderostapenkoias@gmail.com

Нархов Дмитрий Андреевич – аспирант, Воронежский государственный технический университет, e-mail: alexanderostapenkoias@gmail.com

Молокоедова Виктория Витальевна – студент, Воронежский государственный технический университет, e-mail: alexanderostapenkoias@gmail.com

Федюков Ярослав Сергеевич – студент, Воронежский государственный технический университет, e-mail: alexanderostapenkoias@gmail.com

Чунта Полина Денисовна – студент, Воронежский государственный технический университет, e-mail: alexanderostapenkoias@gmail.com

**ATTACKED ARTIFICIAL INTELLIGENCE ASSETS:
CONSTRUCTING A RISK-OPPORTUNITY LANDSCAPE OF ATTACK SCENARIOS
AGAINST INFORMATION AND TELECOMMUNICATION SYSTEMS**

V.P. Los, D.A. Narhov, V.V. Molokoedova, Ya.S. Fedyukov, P.D. Chunta

This article describes a methodology for assessing the likelihood of successful implementation of information security measures and a three-dimensional risk-chance landscape for analyzing attacks on artificial intelligence (AI) systems in information and telecommunications systems. The landscape combines three key dimensions: the probability of implementing an attack technique (the chance of successful implementation of measures), specific attack techniques, including those described in the MITRE ATLAS framework, and the information security measures applied. The model provides a visual representation of critical zones where an attack has a high probability of success despite weak defenses. This allows for the structuring of threats, objective comparison of countermeasures, and the development of a sound strategy for protecting AI components at all stages of their lifecycle—from design to operation and incident response.

Keywords: artificial intelligence, information and telecommunication systems, opportunity, risk, assessment, analysis, information security (IS).

Submitted 7.12.2025

Information about the authors

Vladimir P. Los – professor, Doctor of Military Sciences, Russian State University for the Humanities, e-mail: alexanderostapenkoias@gmail.com

Dmitry A. Narhov – graduate student, Voronezh State Technical University, e-mail: alexanderostapenkoias@gmail.com

Victoria V. Molokoedova – student, Voronezh State Technical University, e-mail: alexanderostapenkoias@gmail.com

Yaroslav S. Fedyukov – student, Voronezh State Technical University, e-mail: alexanderostapenkoias@gmail.com

Polina D. Chunta – student, Voronezh State Technical University, e-mail: alexanderostapenkoias@gmail.com